

A. TRANG BÌA

ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

ĐỒ ÁN TỐT NGHIỆP ĐẠI HỌC

Đề tài:

XÂY DỰNG HỆ THỐNG NHẬN DIỆN BIỂN SỐ XE BẰNG TRÍ TUỆ NHÂN TẠO

Developing an AI-based vehicle license plate recognition system

Ngành: Trí tuệ nhân tạo

Chuyên ngành: Trí tuệ nhân tạo

Sinh viên thực hiện: **Phạm Công Thành** — MSSV **25410013**

Nguyễn Minh Hiếu — MSSV **25410007**

Lớp: AI503.F3.LT.TTNT

Khoá: 2025

Giảng viên hướng dẫn: ThS. Cáp Phạm Đình Thăng

TP. Hồ Chí Minh, tháng 9 năm 2026

B. MỤC LỤC

A. TRANG BÌA	1
ĐỒ ÁN TỐT NGHIỆP ĐẠI HỌC	1
XÂY DỰNG HỆ THỐNG NHẬN DIỆN BIỂN SỐ XE BẰNG TRÍ TUỆ NHÂN TẠO.....	1
B. MỤC LỤC	1

C. TÓM TẮT ĐỒ ÁN.....	3
CHƯƠNG 1. GIỚI THIỆU	5
1.1. Đặt vấn đề	5
1.2. Mục tiêu đề tài	6
1.3. Đối tượng và phạm vi nghiên cứu	8
1.4. Phương pháp nghiên cứu	9
1.5. Đóng góp của đề tài	10
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT	13
2.1. Phạm vi và bố cục cơ sở lý thuyết	13
2.2. Quy chuẩn biển số xe Việt Nam	13
2.3. Cơ sở lý thuyết về phát hiện đối tượng.....	15
2.4. Cơ sở lý thuyết về nhận dạng ký tự	18
2.5. Các công trình liên quan	21
CHƯƠNG 3. KHẢO SÁT CÔNG NGHỆ VÀ LỰA CHỌN MÔ HÌNH.....	23
3.1. Phương pháp khảo sát và tiêu chí lựa chọn.....	23
3.2. Mô hình phát hiện: YOLO11.....	23
3.3. Bộ nhận dạng ký tự	23
3.4. Nền tảng suy luận trên CPU: ONNX Runtime	26
3.5. Các lựa chọn công nghệ nền tảng khác	26
3.6. Độ phân giải đầu vào: 640 thay vì 416.....	27
CHƯƠNG 4. THIẾT KẾ VÀ CÀI ĐẶT HỆ THỐNG.....	28
4.1. Phân tích yêu cầu	28
4.2. Kiến trúc hệ thống	29
4.3. Môi trường và công cụ phát triển.....	32
4.4. Xây dựng bộ dữ liệu	33
4.5. Huấn luyện mô hình	34
4.6. Tầng AI — thiết kế và cài đặt	35
4.7. Máy chủ và cơ sở dữ liệu	43
4.8. Giao diện người dùng.....	46
4.9. Triển khai bằng Docker	47
4.10. Những chỗ cài đặt lệch khỏi thiết kế, và lý do.....	48
CHƯƠNG 5. THỰC NGHIỆM VÀ ĐÁNH GIÁ	49
5.1. Mục tiêu và phương pháp đánh giá	49

5.2. Môi trường thực nghiệm.....	52
5.3. Bộ dữ liệu thực nghiệm.....	52
5.4. Đánh giá bộ phát hiện biển số	53
5.5. Đánh giá khối OCR và hậu xử lý	54
5.6. Đánh giá hiệu năng.....	59
5.7. Đối chiếu toàn bộ chỉ tiêu phi chức năng.....	65
5.8. Phân tích lỗi.....	66
5.9. Bàn luận	66
CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	68
6.1. Kết quả đạt được.....	68
6.2. Hạn chế.....	69
6.3. Hướng phát triển	70
6.4. Kết luận chung.....	71
TÀI LIỆU THAM KHẢO	73
PHỤ LỤC	76
Phụ lục I. Mã vùng biển số	76
Phụ lục II. Ghi công giấy phép bộ dữ liệu.....	76
Phụ lục III. Nơi tra cứu phần chi tiết.....	76

C. TÓM TẮT ĐỒ ÁN

TÓM TẮT ĐỒ ÁN

Nhận dạng biển số xe tự động (ALPR) là bài toán nền tảng của bãi đỗ xe thông minh, thu phí không dừng và giám sát giao thông. Tại Việt Nam, biển số hai dòng chiếm tỷ lệ lớn do mật độ xe máy cao, trong khi đa số bộ dữ liệu quốc tế chỉ có biển một dòng, khiến các mô hình huấn luyện trên dữ liệu nước ngoài không áp dụng trực tiếp được. Khác biệt này đã được đo lường: trên bộ RodoSol-ALPR của Brazil, hệ thống OpenALPR đạt 94,3% với ô tô biển một dòng nhưng chỉ 45,7% với xe máy biển hai dòng [1].

Đồ án xây dựng một hệ thống ALPR hoàn chỉnh cho biển số xe Việt Nam theo hướng tiếp cận hai giai đoạn: phát hiện vùng biển số bằng YOLO11, nhận dạng ký tự bằng PaddleOCR, và hậu xử lý bằng bộ luật chuẩn hoá theo quy chuẩn hiện hành. Hệ thống hỗ trợ cả biển một dòng và hai dòng, nhận đầu vào là ảnh, video hoặc khung hình thời gian thực gửi qua API (endpoint POST /api/detect/frame), và suy luận hoàn toàn trên CPU.

Đóng góp chính là bộ luật hậu xử lý **ràng buộc theo vị trí ký tự**, xây dựng trên Thông tư 79/2024/TT-BCA [2] và QCVN 08:2024/BCA [3]: mã tỉnh thuộc 81 giá trị hợp lệ, chữ cái sê-ri thứ nhất và thứ hai thuộc hai tập ký tự khác nhau. Cách tiếp cận này khắc phục hạn chế của các hệ thống áp một danh sách ký tự phẳng cho toàn chuỗi.

Về mặt kỹ nghệ, đồ án cài đặt kiến trúc phân tầng tách biệt tầng AI khỏi tầng API, gồm backend FastAPI, giao diện web React và đóng gói Docker.

Trên tập kiểm tra của split v3 (1.514 ảnh, đã khử trùng lặp giữa các tập), bộ phát hiện YOLO11n đạt $mAP@0.5 = 0,9829$ và $mAP@0.5:0.95 = 0,7834$ (precision 0,9837; recall 0,9714). Khối nhận dạng đạt độ chính xác mức ký tự ($1 - CER$) 0,9483; độ chính xác toàn chuỗi tăng từ 0,6373 lên 0,7701 nhờ bộ luật hậu xử lý (sửa đúng 372 biển, không làm hỏng biển nào). Chỉ số end-to-end đo ở **mức ảnh toàn cảnh** đạt **0,563** (khoảng tin cậy 95% $[0,520 ; 0,607]$), ước lượng phân tầng trên 1.606 khung biển của 1.514 ảnh hiện trường — chưa đạt ngưỡng 0,82, và phải đọc kèm hạn chế nhãn do mô hình ngôn ngữ-thị giác sinh chữ không phải người gán. Khoảng cách lớn nhất nằm ở layout: biển một dòng đạt 0,9541 còn biển hai dòng chỉ đạt 0,7234 — chênh 23,07 điểm phần trăm, trong khi biển hai dòng chiếm 79,8% tập đánh giá. Độ trễ xử lý một ảnh ở phân vị 95 là 509,76 ms trên CPU (trung vị 150,07 ms), đạt cả ngưỡng tối thiểu 1.500 ms lẫn mục tiêu 800 ms sau đợt tối ưu tăng suy luận. Chưa đạt mục tiêu 800 ms — cái giá đã định lượng của bậc thang thử-lại dành cho biển nghiêng, méo. Chi tiết và phân tích lỗi được trình bày ở Chương 5.

Từ khoá: nhận dạng biển số xe, biển số Việt Nam, YOLO11, PaddleOCR, biển số hai dòng, hậu xử lý theo vị trí, suy luận trên CPU.

CHƯƠNG 1. GIỚI THIỆU

1.1. Đặt vấn đề

1.1.1. Bối cảnh giao thông Việt Nam và nhu cầu tự động hoá

Tính đến tháng 9/2024, Việt Nam có khoảng **77 triệu xe máy đã đăng ký, tương đương 770 xe trên 1.000 dân**; xe máy chiếm khoảng **85–90% lưu lượng phương tiện trên đường**.

Điều này kéo theo ba hệ quả (Chương 4): (i) biển hai dòng chiếm đa số vì mọi xe mô tô đều mang biển hai dòng; (ii) mật độ cao gây che khuất và nhiều biển trong một khung hình; (iii) biển xe mô tô chỉ 140 × 190 mm nên là đối tượng nhỏ. Vì vậy, ghi nhận thủ công không phù hợp và cần **nhận dạng biển số xe tự động (ALPR)** [1].

1.1.2. Ứng dụng thực tế của hệ thống ALPR

ALPR là lõi của bốn nhóm ứng dụng tại Việt Nam: **bãi đỗ xe thông minh; thu phí không dừng ETC; giám sát giao thông (xử phạt nguội); kiểm soát ra vào**. Cả bốn đo cùng một thứ: **không phải mAP của khâu phát hiện, mà là tỉ lệ đọc đúng toàn bộ chuỗi biển số** (plate-level exact match) — đọc đúng 9 trên 10 ký tự vẫn là đọc sai biển. Nhận định này định hình chỉ tiêu ở mục 1.2.2 và cách đánh giá ở Chương 5.

1.1.3. Vì sao không thể dùng trực tiếp giải pháp nước ngoài

(a) Biển hai dòng là điểm suy giảm đã đo được, không phải rủi ro giả định. Trên tập kiểm thử cân bằng có chủ ý của bộ **RodoSol-ALPR (Brazil)** — 4.000 ảnh ô tô biển **một dòng**, 4.000 ảnh xe máy biển **hai dòng** — hệ thống thương mại **OpenALPR** nhận đúng **94,3% biển một dòng nhưng chỉ 45,7% biển hai dòng, chênh 48,6 điểm phần trăm**, không biển số nào khác thay đổi ngoài bố cục biển [2]. Cũng nghiên cứu này: cả 12 phương pháp và 2 hệ thống thương mại đều **không vượt quá 70% recognition rate**, và có công trình phải **loại bỏ hoàn toàn xe máy** khỏi thí nghiệm [2].

Ghi chú về phạm vi áp dụng của số liệu. Cặp **94,3% / 45,7%** (chênh **48,6 điểm phần trăm**) đo trên **RodoSol-ALPR của Brazil, không phải trên dữ liệu Việt Nam**; dẫn như một *analogue* định lượng về độ khó của biển hai dòng, chọn Brazil vì cũng là nước có tỉ lệ xe máy cao. **Tuyệt đối không được trình bày cặp số này như số liệu Việt Nam** — số liệu Việt Nam do chính nhóm thực hiện đo nằm ở Chương 5.

(b) Căn cứ pháp lý và cấu trúc chuỗi ký tự là đặc thù quốc gia. Biển số Việt Nam theo **TT 79/2024/TT-BCA** (hiệu lực 01/01/2025) [3], sửa đổi bởi **TT 13/2025** [4] và **TT 51/2025** [5]; kích thước vật lý theo **QCVN 08:2024/BCA** [6]. (*Nhiều tài liệu trong nước vẫn viện dẫn TT 24/2023 — đã hết hiệu lực từ 01/01/2025.*) Ba đặc thù sau **không học được từ dữ liệu nước ngoài**. (i) **Tập ký tự sê-ri phụ thuộc vị trí**: vị trí thứ nhất thuộc một tập **20 chữ cái** có G không có R [7], còn vị trí thứ hai của biển mô tô thuộc **một tập 20 chữ khác** có R không có G; áp một danh sách phẳng chung sẽ **đọc sai toàn bộ lớp biển xe máy có R ở vị trí thứ hai**, và hậu xử lý không cứu được. (ii) **Mã địa phương hữu hạn, có lỗi hồng**: dài 11–99 chỉ **81 mã**

đang dùng, tám mã 13, 42, 44, 45, 46, 87, 91, 96 chưa gán — nên \{d\} cho qua tám chuỗi không bao giờ tồn tại. (iii) **Tỉ lệ khung hình phân tách rõ hai bố cục** [6]: $110 \times 520 \text{ mm} \rightarrow 4,727$ (một dòng); $165 \times 330 \rightarrow 2,000$ và $140 \times 190 \rightarrow 1,357$ (hai dòng). Không biến nào rơi vào khoảng mở **(2,000 ; 4,727)** — đó là cơ sở hình học để phân loại số dòng.

(c) Điều kiện thu nhận ảnh khác biệt: biến bị che, bám bụi, cong vênh, chụp nghiêng, ngược sáng, ảnh đêm — khác các bộ dữ liệu quốc tế lớn (CCPD, AOLP, SSIG) vốn lấy ô tô làm trung tâm. **Kết luận mục 1.1:** bài toán này cần **hệ thống huấn luyện trên dữ liệu Việt Nam và khối hậu xử lý xây theo quy chuẩn Việt Nam**.

1.2. Mục tiêu đề tài

1.2.1. Mục tiêu tổng quát

Xây dựng hệ thống nhận dạng biến số xe Việt Nam gồm mô hình phát hiện tự huấn luyện, nhận dạng ký tự, hậu xử lý theo quy chuẩn Việt Nam, REST API, giao diện web, cơ sở dữ liệu và đóng gói triển khai; hỗ trợ biến một dòng, hai dòng và suy luận trên CPU. Hệ thống phục vụ mục đích học thuật, không phải sản phẩm thương mại.

1.2.2. Mục tiêu cụ thể

Mỗi chỉ tiêu có **mục tiêu** và **ngưỡng tối thiểu** (bắt buộc đạt). Về chức năng và chất lượng phần mềm: **34 yêu cầu chức năng** (22 *Must*, 5 *Should*, 3 *Could*, 4 *Won't*) trong **sáu nhóm** (mục 4.1.3); **NFR-M1** mã đường ống AI **không import FastAPI**; **NFR-M5** thay được bộ OCR không sửa mã tầng API; **NFR-M2** độ bao phủ kiểm thử tầng nghiệp vụ $\geq 70\%$; **khởi động một lệnh** docker compose up, demo **không cần Internet**. **NFR-A5 và NFR-A6 đo tách bạch có chủ đích** — hiệu số là **đóng góp định lượng của khối hậu xử lý** (mục 1.5); thêm **NFR-A8** (tách riêng biến một dòng / hai dòng) và **NFR-A9** (theo điều kiện ảnh, nếu có nhãn phù hợp).

Bảng 1.1. Nhóm chỉ tiêu độ chính xác

Mã	Chỉ tiêu	Mục tiêu	Ngưỡng tối thiểu
NFR-A1	mAP@0.5 của bộ phát hiện biến số	$\geq 0,90$	$\geq 0,85$
NFR-A2	mAP@0.5:0.95 của bộ phát hiện	$\geq 0,65$	$\geq 0,55$
NFR-A3	Precision / Recall phát hiện	$\geq 0,92 / \geq 0,90$	$\geq 0,88 / \geq 0,85$
NFR-A4	Độ chính xác OCR mức ký tự (1 – CER)	$\geq 0,95$	$\geq 0,92$
NFR-A5	Độ chính xác biến đầy đủ trước hậu xử lý	$\geq 0,85$	$\geq 0,80$
NFR-	Độ chính xác biến đầy đủ sau hậu xử lý	$\geq 0,90$	$\geq 0,85$

Mã	Chỉ tiêu	Mục tiêu	Ngưỡng tối thiểu
A6			
NFR-A7	Độ chính xác E2E toàn trình (ảnh vào → biến đúng)	$\geq 0,88$	$\geq 0,82$

Bảng 1.2. Nhóm chỉ tiêu hiệu năng trên CPU

Mã	Chỉ tiêu	Mục tiêu	Ngưỡng tối thiểu
NFR-P1	Độ trễ E2E một ảnh (p95)	$\leq 800\text{ ms}$	$\leq 1500\text{ ms}$
NFR-P2	Tốc độ khung hình thời gian thực (webcam — đo ở tầng API)	$\geq 5\text{ FPS}$ hiệu dụng	$\geq 3\text{ FPS}$
NFR-P3	Tốc độ xử lý video	$\geq 0,3\times$ thời gian thực	$\geq 0,15\times$
NFR-P4	Thời gian nạp mô hình khi khởi động	$\leq 15\text{ s}$	$\leq 30\text{ s}$
NFR-P5	Overhead của tầng API (không tính suy luận)	$\leq 50\text{ ms}$	$\leq 100\text{ ms}$
NFR-P6	Thời gian truy vấn lịch sử (10.000 bản ghi)	$\leq 500\text{ ms}$	$\leq 1000\text{ ms}$
NFR-P7	Bộ nhớ thường trú của máy chủ	$\leq 2\text{ GB}$	$\leq 4\text{ GB}$

Các chỉ tiêu độ trễ "rộng rãi" hơn bài báo ALPR vì máy phát triển **không có GPU CUDA** (CON-02): huấn luyện trên GPU Colab/Kaggle, **toàn bộ suy luận và demo chạy trên CPU**, còn bài báo thường đo trên GPU RTX/V100. Mọi số liệu hiệu năng **bắt buộc kèm cấu hình phần cứng**.

Ghi chú về bốn yêu cầu mức *Won't*. Sáu yêu cầu từng chuyển xuống *Won't* qua ba đợt thu gọn phạm vi: đợt 1 gỡ trang Webcam (**FR-3.1, FR-3.4**: M → W); đợt 2 gỡ trang Tổng quan (**FR-4.1**: M → W, **FR-4.2**: S → W); đợt 3 đưa **FR-2.5** (xuất video đã chú thích, M → W) và **FR-2.6** (huỷ tác vụ, S → W) ra khỏi phạm vi vì cả hai đang dở dang. **Hai trong sáu đã quay lại**: FR-3.1 và FR-3.4 được dựng lại cùng chế độ quét trực tiếp (4.8.1) và trở về mức *Must*, nên hiện chỉ còn bốn *Won't*.

Trong bốn yêu cầu *Must* từng bị gỡ, **chỉ còn hai nằm ngoài phạm vi: FR-4.1 và FR-2.5** — và hai cái này mất hai thứ khác hẳn nhau. FR-4.1 chỉ mất **màn hình hiển thị**: thống kê vẫn truy vấn được ở tầng giao diện lập trình và vẫn có kiểm thử tích hợp. **Riêng FR-2.5 mất chính năng lực** — hệ thống không còn xuất được video đã chú thích. Đây là quyết định phạm vi có chủ đích, nêu lại ở mục 4.1.3 và 6.2.

1.2.3. Tiêu chí thành công

Đề tài thành công khi **đồng thời**: (1) toàn bộ yêu cầu *Must* hoạt động và demo được — theo bộ 20 *Must sau* ba đợt thu gọn phạm vi, sáu yêu cầu đã chuyển *Won't* (FR-2.5, FR-2.6, FR-3.1, FR-3.4, FR-4.1, FR-4.2) **không** tính là đạt; (2) mọi chỉ tiêu đạt **ngưỡng tối thiểu** và **có bằng chứng đo đạc**; (3) đủ 12 sản phẩm bàn giao; (4) khởi động trên máy sạch bằng một lệnh `docker compose up`; (5) demo trực tiếp không cần Internet.

Trạng thái tại thời điểm viết chương này. Các chỉ tiêu ở mục 1.2.2 là **chỉ tiêu đặt ra**; đối chiếu đầy đủ từng chỉ tiêu ở Chương 5. Hệ thống chạy đường ống thật với `models/best.pt`: nhóm phát hiện đạt cả bốn chỉ tiêu (`mAP@0.5` = 0,9829), NFR-P1 đạt mục tiêu (`p95` = 509,76 ms so với 800 ms), còn **độ chính xác đọc chuỗi trên biển hai dòng chưa đạt**.

1.3. Đối tượng và phạm vi nghiên cứu

1.3.1. Đối tượng nghiên cứu

Ba nhóm. **(1) Biển số xe cơ giới Việt Nam** theo TT 79/2024/TT-BCA [3] (sửa đổi bởi TT 13/2025 [4] và TT 51/2025 [5]) và QCVN 08:2024/BCA [6]; biển nền đỏ quân đội thuộc TT 169/2021/TT-BQP [8], chỉ xử lý ở mức nhận biết ký hiệu. **(2) Mô hình phát hiện họ YOLO** — cụ thể YOLO11 [9]. **(3) Bộ nhận dạng ký tự** không cần phân đoạn ký tự: PaddleOCR [10] là **phương án khởi điểm**, EasyOCR ngang hàng, Tesseract là mốc dưới, kèm bộ luật hậu xử lý theo vị trí. **Lựa chọn bộ nhận dạng ký tự chưa chốt ở giai đoạn thiết kế** — quyết định thuộc về benchmark do chính nhóm thực hiện chạy (mục 3.3, Chương 5).

1.3.2. Phạm vi trong nghiên cứu


Bốn nhóm. **(a) Trí tuệ nhân tạo**: huấn luyện YOLO11 trên dữ liệu Việt Nam, so sánh biến thể `n / s / m`, kèm YOLO26n đối chứng (mục 3.2); **benchmark các bộ nhận dạng ký tự** trên chính tập kiểm thử biển số Việt Nam rồi tích hợp bộ nhận dạng được chọn; hậu xử lý theo luật hợp lệ theo vị trí; **hỗ trợ cả biển một dòng và hai dòng**; đánh giá đầy đủ (`mAP`, `precision`, `recall`, `F1`, `ma` trận nhầm lẫn); đo hiệu năng trên CPU. **(b) Dữ liệu**: thu thập, gộp, làm sạch bộ công khai; sửa nhãn; loại ảnh trùng lặp; tăng cường; chia `train / val / test` **có kiểm soát rò rỉ dữ liệu**; thống kê. **(c) Phần mềm**: FastAPI + Swagger; nhận dạng ảnh, video và khung hình thời gian thực qua `POST /api/detect/frame`; lịch sử bằng SQLite + SQLAlchemy + Alembic; giao diện React + Vite + TypeScript + TailwindCSS **ba trang** (Nhận dạng ảnh — trang chủ, Nhận dạng video, Lịch sử) sau hai đợt thu gọn; tìm kiếm, lọc, tải về; thống kê ở tầng API (`GET /api/statistics`); Docker và Docker Compose. **(d) Kiểm thử, tài liệu**: unit test, integration test, kiểm thử độ chính xác AI, hiệu năng, chịu tải; tài liệu học thuật và kỹ thuật.

1.3.3. Phạm vi ngoài nghiên cứu

Danh sách này nhằm xác định rõ giới hạn của đề tài; việc loại trừ các hạng mục này là quyết định có chủ đích, không phải do giới hạn về thời gian. **Mười một hạng mục bao gồm**: (1)

xác thực, phân quyền — chạy nội bộ localhost/LAN (giả định A-04); (2) đa camera / đa luồng; (3) bám vết qua khung hình (SORT / DeepSORT) — thay bằng gộp trùng theo chuỗi ký tự; (4) phân loại loại xe — từ 01/01/2025 TT 79/2024 đã bỏ quy tắc suy loại xe từ chữ cái seri; (5) ước lượng tốc độ, phát hiện vi phạm — cần hiệu chuẩn camera riêng; (6) biển số nước ngoài; (7) barie / cổng tự động — cần thiết bị vật lý; (8) cloud, multi-tenant, CI/CD production — Docker Compose đã đủ; (9) ứng dụng di động — web responsive đã đáp ứng; (10) huấn luyện bộ nhận dạng ký tự từ đầu — dùng pre-trained rồi tinh chỉnh; tinh chỉnh nằm trong phạm vi (mục 2.4.3(f)); (11) suy luận thời gian thực trên GPU — máy phát triển không có GPU CUDA (CON-02) ⇒ mọi số liệu là số liệu CPU.

1.3.4. Ranh giới hệ thống



Hình 1.1. Ranh giới hệ thống — phần bên trong là hệ thống bàn giao, Colab/Kaggle nằm ngoài

Colab/Kaggle nằm **ngoài** ranh giới khi vận hành — chỉ là công cụ ngoại tuyến sản xuất best.pt; hệ thống khi chạy **không phụ thuộc dịch vụ ngoài nào** (mục 1.2.3). Sau khi trang webcam bị gỡ, client gửi khung hình trực tiếp qua POST /api/detect/frame.

1.4. Phương pháp nghiên cứu

Đề tài dùng **ba phương pháp bổ trợ nhau**: nghiên cứu lý thuyết (khảo sát tài liệu có trích dẫn, đối chiếu văn bản pháp quy hiện hành); nghiên cứu thực nghiệm (**mọi khẳng định về hiệu năng và độ chính xác đều phải có số đo tái lập được**, kèm cấu hình phần cứng và cỡ mẫu); và quy trình phát triển theo giai đoạn, mỗi giai đoạn khép lại bằng một bộ tài liệu và một mốc kiểm chứng.

1.4.1. Phân định phần tự xây dựng và phần dùng lại

Để tránh mọi nhập nhằng khi đánh giá, bảng dưới nêu rõ với từng thành phần: nguồn gốc của nó và **phần việc nhóm thực hiện đã làm**.

Bảng 1.3. Phân định công việc theo từng thành phần

Thành phần	Nguồn gốc	Nhóm thực hiện đã làm gì
Bộ phát hiện biển số	Kiến trúc YOLO11n có sẵn, trọng số khởi đầu từ COCO	Tự huấn luyện trên dữ liệu Việt Nam do nhóm hợp nhất; chọn siêu tham số; đánh giá
Bộ nhận dạng ký tự	Mô hình PP-OCRV5 mobile tiền huấn luyện	Tích hợp; tự đo so với hai bộ nhận dạng khác; thử tinh chỉnh và báo cáo cả kết quả âm
Khối xử lý ảnh vùng biển	—	Tự thiết kế và cài đặt toàn bộ : nắn hình, phân loại bố cục, tách hai nửa, ghép ngang
Khối hậu xử lý theo quy chuẩn	—	Tự thiết kế và cài đặt toàn bộ : mặt nạ vị trí, tập mã tình, bảng ánh xạ nhầm lẫn
Bộ dữ liệu	7 bộ ảnh công khai, giấy phép ở Phụ lục C	Tự hợp nhất, khử trùng lặp chéo bộ, chia tập có kiểm soát rò rỉ ; gán nhãn chuỗi cho tập con
Máy chủ, giao diện, đóng gói	Thư viện mã nguồn mở (FastAPI, React, Docker)	Tự thiết kế kiến trúc và cài đặt ; viết bộ kiểm thử
Quy trình đo và báo cáo	—	Tự xây dựng toàn bộ : công cụ đo, giao thức, phân tích lỗi

Hai khối in đậm ở giữa bảng là phần **không có sẵn trong bất kỳ thư viện nào** và là đóng góp kỹ thuật chính của đề tài.

1.5. Đóng góp của đề tài

1.5.1. Tuyên bố trung thực về mức đóng góp

Đề tài này không tạo ra kết quả state-of-the-art.

Các kết quả trên 99% trong tài liệu ALPR quốc tế thường dựa trên hạ tầng GPU và dữ liệu riêng. Nhóm thực hiện làm việc trên máy không có GPU CUDA nên không đặt mục tiêu tương tự. Đóng góp tập trung ở sáu nội dung có thể kiểm chứng.

Sáu đóng góp.

(a) Hệ thống hoàn chỉnh, có kiến trúc phần mềm — không phải tập script rời rạc: đường ống AI tách hoàn toàn khỏi tầng API (NFR-M1), interface trừu tượng cho phép thay bộ nhận dạng ký tự mà không sửa tầng API (NFR-M5), REST API có tài liệu tự sinh, giao diện web ba

màn hình, cơ sở dữ liệu có migration, Docker một lệnh. Trạng thái đã đo: bao phủ kiểm thử tăng nghiệp vụ **87,7%, 1.004 test thu thập / 1.004 đạt / 0 thất bại**. Khảo sát cho thấy mã nguồn mở ALPR Việt Nam chủ yếu là script rời rạc **không công bố số liệu độ chính xác** — đây là **khoảng trống kỹ nghệ**, không phải khoảng trống thuật toán, nhưng vẫn có thật.

(b) Bộ luật hậu xử lý ràng buộc theo VỊ TRÍ cho biển số Việt Nam, khai thác ba ràng buộc đặc thù: tập hợp lệ **khác nhau theo từng vị trí** — mã địa phương thuộc **81 giá trị** chứ không phải $\setminus d^2$, seri **thứ nhất** thuộc 20 chữ cái có G không có R [7], seri **thứ hai** của biển xe mô tô thuộc **20 chữ cái KHÁC** có R không có G; cấu trúc chuỗi và độ dài theo quy chuẩn; và bảng ánh xạ nhầm lẫn ký tự **không đối xứng**.

Ghi chú về mức độ của đóng góp này. Luận điểm dự kiến ban đầu — "*khai thác bộ 20 chữ cái, loại trừ 6 chữ I J O Q R W*" — **sai và đã bị bác bỏ**: tập loại trừ toàn hệ thống chỉ có **5 chữ**, còn R **hợp lệ** ở vị trí seri thứ hai của biển xe mô tô. Sửa lại **làm yếu đi** phần đóng góp nếu tính theo "số ký tự loại trừ được". Đổi lại, phần có giá trị nằm ở ràng buộc **phụ thuộc vị trí**: một hệ thống dùng danh sách phẳng 20 chữ cái sẽ sai hệ thống trên mọi biển xe máy có R.

(c) Đo được ĐỊNH LƯỢNG đóng góp của bước hậu xử lý. Phần lớn công trình mô tả bước này ở mức định tính, không trả lời được *nó đóng góp bao nhiêu*. Đề tài giải quyết ở tầng dữ liệu — **lưu đồng thời chuỗi OCR thô và chuỗi đã sửa** — nên hiệu số giữa **NFR-A5** (trước) và **NFR-A6** (sau) là một **con số đo được**.

(d) Đánh giá tách riêng biển một dòng và biển hai dòng. **NFR-A8** biến phép tách này thành **nghĩa vụ báo cáo bắt buộc** chứ không phải phân tích tùy chọn, kèm **NFR-A9** — báo cáo theo điều kiện ảnh, nếu bộ dữ liệu có nhãn phù hợp.

(e) Công bố hiệu năng kèm cấu hình phần cứng CPU cụ thể — mọi số liệu kèm model CPU, số luồng, kích thước ảnh đầu vào, nền tảng suy luận và cỡ mẫu đo. FPS không kèm phần cứng thì không tái lập được, cũng không so sánh được.

(f) Đo trên chính ảnh biển số Việt Nam. Khảo sát xác định **không tồn tại benchmark công khai** nào so sánh các bộ nhận dạng ký tự trên riêng ảnh biển số xe máy Việt Nam hai dòng, và hai số liệu thường được viện dẫn để chứng minh ưu thế của một bộ nhận dạng đã **bị bác bỏ khi truy ngược về nguồn gốc** (mục 3.3). Đề tài đã chạy ba phép so sánh trên chính ảnh biển số Việt Nam, cùng máy và cùng ngữ liệu: **PP-OCRv5_mobile ↔ PP-OCRv6_medium** (mục 3.3.2), **bộ nhận dạng gốc ↔ bản tinh chỉnh** (mục 5.5), và **PaddleOCR ↔ EasyOCR ↔ Tesseract trên toàn bộ 2.801 biển** (mục 3.3.3) — kết quả PaddleOCR **68,87%**, hơn EasyOCR 54,59 điểm và hơn Tesseract 58,59 điểm, **bác bỏ** tài liệu công khai vốn nghiêng về EasyOCR. Một kết quả **khác với dự đoán ban đầu**: kỹ thuật tách và ghép ngang giúp độ chính xác của PaddleOCR tăng **34,92%** nhưng chỉ cải thiện **0,03%** đối với Tesseract, nên đây **không** phải kỹ thuật độc lập bộ nhận dạng như giả định ban đầu.

1.5.2. Những gì đề tài KHÔNG tuyên bố

Bốn điều loại trừ. **Không** tuyên bố vượt các con số độ chính xác cao nhất trong nước — chúng đo trên tập dữ liệu riêng không công khai, **không có cơ sở so sánh công bằng**. **Không** đề xuất kiến trúc mạng nơ-ron mới; đề tài **tích hợp và tinh chỉnh**. **Không** giải quyết các thách thức mở — độ phân giải rất thấp, tổng quát hoá xuyên tập dữ liệu, che khuất nặng (**Hướng phát triển, Chương 6**). Mọi số liệu hiệu năng là **số liệu CPU**, **không so sánh trực tiếp được** với FPS đo trên GPU.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

Chương đặt nền lý thuyết và tư liệu cho phần thiết kế. Nguyên tắc xuyên suốt: **mọi con số gắn nguồn tại chỗ, mọi cảnh báo về phạm vi áp dụng giữ nguyên** — lĩnh vực này hay công bố số trên 99% nhưng đo trên tập dữ liệu và giao thức rất khác nhau.

2.1. Phạm vi và bố cục cơ sở lý thuyết

Một hệ thống ALPR gồm bốn khối nối tiếp — **phát hiện vùng biển, nắn chỉnh và tiền xử lý, nhận dạng ký tự, hậu xử lý theo quy chuẩn** — và độ chính xác cuối cùng là **tích** của độ chính xác từng khối, nên một khối yếu kéo cả chuỗi xuống. Đề án đi theo hướng **two-stage** (phát hiện rồi nhận dạng riêng) kết hợp bộ nhận dạng **segmentation-free**; căn cứ của lựa chọn đó trình bày ở Chương 3.

Chương này chỉ giữ phần lý thuyết **ràng buộc trực tiếp một quyết định của hệ thống**: quy chuẩn biển số Việt Nam (2.2) — cơ sở của bộ luật hậu xử lý; kiến trúc YOLO11 và các chỉ số đánh giá khối phát hiện (2.3); kiến trúc CRNN/CTC cùng **giới hạn của nó trên văn bản nhiều dòng** (2.4) — nền tảng lý thuyết của rủi ro R-04 và của đóng góp kỹ thuật lõi; và khảo sát công trình liên quan cùng sáu khoảng trống nghiên cứu (2.5).

2.2. Quy chuẩn biển số xe Việt Nam

Quy chuẩn biển số Việt Nam — bốn văn bản căn cứ, cấu trúc chuỗi ký tự và bảng mã tình — đã trình bày ở **mục 1.1.3(b)**; danh sách 81 mã đang dùng ở **Phụ lục I**. Mục này chỉ khai triển ba đặc điểm mà thiết kế hệ thống dựa trực tiếp vào: tập ký tự sê-ri phụ thuộc vị trí, màu nền, và tỉ lệ khung hình.

2.2.1. Tập ký tự seri và các chữ cái bị loại trừ

Đây là nội dung dễ gây nhầm lẫn. Biển trắng và vàng chữ đen dùng seri gồm **một trong 20 chữ cái** [7]; khi đối chiếu với 26 chữ cái Latin, sẽ vắng mặt I, J, O, Q, R, W. Tuy nhiên, **suy luận "26 – 20 = 6 chữ bị loại trừ" là chưa chính xác**: danh sách 20 chữ cái này **chỉ áp dụng cho vị trí thứ nhất** của seri; ở **vị trí thứ hai** của seri xe máy lại sử dụng một tập hợp khác — **có chữ R, không có chữ G**. Kết hợp cả hai vị trí, tập chữ cái hoàn toàn không xuất hiện trên hệ thống biển số Việt Nam chỉ bao gồm **5 chữ: I, J, O, Q, W**; chữ R vẫn xuất hiện ở các ký hiệu đặc biệt như R hay RM của rơ moóc.

Bảng 2.1. Tổng hợp các tập ký tự seri

Tập	Số lượng	Nội dung
Chữ cái thứ nhất của seri	20	A B C D E F G H K L M N P S T U V X Y Z
Chữ cái thứ hai của seri xe máy	20	A B C D E F H K L M N P R S T U V X Y Z
Seri biển nền xanh	11	A B C D E F G H K L M
Bị loại trừ khỏi toàn hệ thống	5	I, J, O, Q, W
Tập ký tự an toàn tối thiểu cho OCR	21	20 chữ ở vị trí thứ nhất, hợp thêm R

2.2.2. Màu nền và ý nghĩa

Bảng 2.2. Màu nền biển số và đối tượng áp dụng [7]

Màu nền / màu chữ	Đối tượng	Ghi chú cho ALPR
Trắng / đen	Tổ chức, cá nhân trong nước, xe không kinh doanh vận tải	Phổ biến nhất
Vàng / đen	Xe kinh doanh vận tải	Tín hiệu phân loại duy nhất còn hợp lệ
Xanh dương / trắng	Cơ quan Đảng, Nhà nước, công an	Seri chỉ dùng 11 chữ cái
Trắng / đỏ	Xe ngoại giao (NG) và tổ chức quốc tế (QT)	Cấu trúc chuỗi khác hẳn
Đỏ / trắng	Xe quân đội và doanh nghiệp quân đội	Ngoài phạm vi TT 79/2024, thuộc TT 169/2021/TT-BQP [8]

QCVN 08:2024/BCA chỉ quy định **4 tổ hợp màu, không có nền đỏ** [6] — biển quân đội do Bộ Quốc phòng quản lý riêng [8]. **Xe điện không có biển riêng:** xe năng lượng sạch **không được cấp biển xanh lá**, dùng biển thường kèm biểu tượng — không phát hiện được xe điện qua màu biển. Màu nền là tín hiệu phân loại duy nhất còn hợp lệ; nhưng module chuẩn hoá làm việc trên chuỗi ký tự, phân loại theo màu ngoài phạm vi của nó.

2.2.3. Kích thước vật lý và tỷ lệ khung hình

Cơ sở định lượng phân biệt biển một dòng với hai dòng — then chốt với rủi ro R-04 (mục 2.4.3). Ô tô được cấp **02** biển: 01 ngắn (**2 dòng**), 01 dài (**1 dòng**); xe mô tô, xe gắn máy, rơ moóc được cấp **01** biển **2 dòng** — **một ô tô mang cùng chuỗi ký tự trên hai biển hình dạng hoàn toàn khác nhau.**

Bảng 2.3. Kích thước và tỷ lệ khung hình của các loại biển số [6]

Loại biển	Kích thước (dài × cao)	Tỷ lệ khung hình	Số dòng
Ô tô — biển dài	520 × 110 mm	4,727	1 dòng
Ô tô — biển ngắn	330 × 165 mm	2,000	2 dòng
Xe mô tô, xe gắn máy	190 × 140 mm	1,357	2 dòng

Ghi chú về mốc hiệu lực. Cần lưu ý rằng bộ số liệu kích thước trên **chỉ đúng từ 01/01/2025**; tiêu chuẩn trước đó quy định biển ô tô ngắn **200 × 280 mm**, biển dài **110 × 470 mm**, và rất nhiều tài liệu thứ cấp — kể cả bài báo năm 2023 — vẫn dùng bộ số cũ. Mọi trích dẫn kích thước biển số **bắt buộc ghi kèm mốc hiệu lực**; nếu không, người phản biện đối chiếu văn bản hiện hành sẽ kết luận là sai.

2.2.4. Ý nghĩa đối với thiết kế hệ thống nhận dạng


Bảy dữ kiện kéo theo bảy quyết định thiết kế: **81 mã tỉnh trong dải 89 số** biến lỗi OCR hai ký tự đầu thành sai phát hiện được; **tập seri khác theo vị trí** buộc ràng buộc **theo vị trí** và tập huấn luyện OCR đủ 36 ký tự; **hai kiểu seri xe máy, nhóm thứ tự 4 hoặc 5 chữ số** buộc biểu thức chính quy đa nhánh; **chuỗi 8 ký tự khớp hai loại biến** nên phải lưu số dòng độc lập; **seri không còn cho biết loại xe** nên cấm heuristic suy loại phương tiện; **khoảng trống tỷ lệ khung hình 2,727** là cơ sở ngưỡng phân loại bố cục; **khung pháp lý đổi ba lần trong hai năm** buộc hậu xử lý tách rời mô hình để cập nhật độc lập.

Về mức đóng góp: luận điểm dự kiến ban đầu — "loại trừ 6 chữ I J O Q R W" — là **sai**, và việc sửa làm **yếu đi** đóng góp theo tiêu chí thu hẹp không gian tìm kiếm; đổi lại phần giá trị chuyển sang ràng buộc **phụ thuộc vị trí trong chuỗi**: danh sách phẳng sẽ sai hệ thống trên toàn bộ lớp biển xe máy có R ở vị trí thứ hai — lỗi mà bộ luật của đề án ngăn được. Đóng góp là **đúng dẫn về pháp lý và cấu trúc**, không phải cải thiện lớn về không gian tìm kiếm.

2.3. Cơ sở lý thuyết về phát hiện đối tượng

2.3.1. Kiến trúc YOLO: nguyên lý one-stage và anchor-free

Họ two-stage (Faster R-CNN) sinh vùng đề xuất rồi phân loại từng đề xuất — độ trễ cao; **họ one-stage** (YOLO, SSD, RetinaNet) hồi quy trực tiếp trong một lần lan truyền xuôi — thời gian thực. Ràng buộc CPU loại họ two-stage từ đầu; một nghiên cứu ALPR trên 50.000 ảnh và 10.000 video clip kết luận nhóm YOLO (v5–v10) vượt trội Faster R-CNN và SSD cả độ chính xác lẫn thời gian suy luận [12].



Hình 2.1. Kiến trúc tổng quát backbone – neck – head của YOLO11 (theo [13], [9])

Ba phần: **backbone** trích đặc trưng, kết thúc bằng SPPF gộp đa tỷ lệ; **neck** hợp nhất đặc trưng nhiều tầng; **head** sinh dự đoán — từ YOLOv8 dùng **anchor-free split head** [13]. Anchor-free có ý nghĩa riêng với biến số: anchor-based hồi quy theo tập hợp mẫu thiết kế theo phân bố COCO — biến số nằm ngoài phân bố đó (một dòng $\approx 4,7:1$, hai dòng $\approx 1,4:1$); anchor-free hồi quy **trực tiếp khoảng cách tâm đến bốn cạnh**, xử lý cả hai chế độ tỷ lệ bằng một cơ chế [9].

2.3.2. YOLO11: các cải tiến kiến trúc

Ba thành phần chính của YOLO11 là **C3k2**, **SPPF** và **C2PSA**; phần dưới đối chiếu trực tiếp mã nguồn Ultralytics [14], tức nguồn sơ cấp thay vì mô tả thứ cấp. **a) C3k2 — là C2f có thể hoán đổi khối con:** C3k2 kế thừa trực tiếp từ C2f của YOLOv8; khác biệt duy nhất là một cờ — tắt thì **giống hệt C2f**, bật thì dùng khối C3k tùy chỉnh kích thước nhân [14]. YOLO11 giảm tham số mà giữ độ chính xác vì không đối triết lý CSP, chỉ cấu hình linh hoạt hơn. **b) C2PSA — thành phần YOLOv8 hoàn toàn không có**, khác biệt kiến trúc thực sự; đặt **ngay sau SPPF** để attention tái phân bổ trọng số theo vị trí không gian. Ultralytics khẳng định cơ chế này cải thiện phát hiện **đối tượng nhỏ** và **che khuất phức tạp** so với YOLOv8 [9].

Lưu ý về mức độ chứng minh. Phát biểu về đối tượng nhỏ là **định tính**: Ultralytics không công bố AP_small/AP_medium/AP_large theo chuẩn COCO cho từng biến thể, nên không thể chứng minh định lượng YOLO11 hơn YOLOv8 bao nhiêu trên đối tượng nhỏ [9]. Đồ án phải **tự đo trên dữ liệu của mình**; kết quả ở Chương 5.

Bảng 2.4. So sánh khác biệt kiến trúc giữa các phiên bản YOLO gần đây

Phiên bản	Khối backbone	Cơ chế attention	Đầu dự đoán	NMS	Điểm mới chính
YOLOv8 [13]	C2f	Không có	Anchor-free, tách nhánh	Có	Chuyển sang anchor-free
YOLOv10	Rank-guided blocks	Partial self-attention	Hai đầu song song	Không	Consistent dual assignments
YOLO11 [9]	C3k2 (kế thừa C2f)	C2PSA sau SPPF	Anchor-free, tách nhánh	Có	C2PSA cải thiện đối tượng nhỏ
YOLO26	Kế thừa dòng Ultralytics	Kế thừa dòng Ultralytics	Bỏ DFL	Không (mặc định)	Bỏ DFL, dễ xuất và lượng tử hoá

Bảng chỉ giữ bốn phiên bản có khác biệt kiến trúc đáng kể với bài toán biến số; **danh sách đầy đủ bảy thế hệ đã xét** và luận cứ chọn YOLO11 trình bày ở mục 3.2.

2.3.3. Các chỉ số đánh giá khối phát hiện

a) Precision, Recall và F1. Với TP dự đoán đúng, FP dự đoán sai, FN đối tượng bỏ sót:

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

Với ALPR, **recall của bước phát hiện quan trọng hơn precision**: biến bỏ sót là mất vĩnh viễn, vùng báo nhầm bị hậu xử lý loại vì chuỗi không khớp cú pháp.

b) AP và mAP. AP là diện tích dưới đường cong Precision–Recall; mAP là trung bình AP trên N lớp — đồ án có $N = 1$ nên mAP trùng AP:

$$AP = \int_0^1 p(r) dr, \quad mAP = \frac{1}{N} \sum_{i=1}^N AP_i$$

c) **mAP@0.5** và **mAP@0.5:0.95** — hai chỉ số khác nhau, không được so sánh chéo. **mAP@0.5** tính tại một ngưỡng IoU cố định 0,5; **mAP@0.5:0.95** lấy trung bình trên 10 ngưỡng từ 0,5 đến 0,95 bước 0,05:

$$mAP@0.5:0.95 = \frac{1}{10} \sum_{t \in \{0.50; 0.55; \dots; 0.95\}} mAP@t$$

Trên cùng một mô hình và cùng một tập dữ liệu, **mAP@0.5:0.95** LUÔN nhỏ hơn hoặc bằng **mAP@0.5** — vì **mAP@0.5** là một trong mười số hạng của phép trung bình ở (2.4), và là số hạng lớn nhất.

Khoảng cách giữa hai chỉ số với biến số thường rất lớn do hộp bao dẹt. Nhóm thực hiện đối chiếu ba công trình đã công bố; giá trị được quy về cùng đơn vị phần trăm để so sánh được.

Bảng 2.5. Khoảng cách giữa **mAP@0.5** và **mAP@0.5:0.95** ở ba công trình về biến số

Công trình	Bộ dữ liệu · quốc gia	mAP@0.5	mAP@0.5:0.95	Chênh (điểm %)
Batra và cộng sự (2022) [15]	biển số Ấn Độ	87,2%	46,5%	40,7
Một nghiên cứu YOLOv11 (2025) [16]	không nêu rõ	90,6%	63,1%	27,5
Biển xe máy Indonesia (2025) [17]	Indonesia	99,5%	80,7%	18,8

Cả ba xác nhận cùng một điều: **biến số dễ phát hiện nhưng khó khớp hộp bao chính xác.**

Ghi chú phương pháp luận. Cần lưu ý một cách trình bày phổ biến nhưng thiếu cơ sở khoa học: đặt **mAP@0.5** của một nghiên cứu ALPR (khoảng 0,90 – 0,99) cạnh **mAP@0.5:0.95** trên tập dữ liệu COCO của cùng lớp mô hình (khoảng 0,395 ở phân khúc nano [9]) rồi kết luận "bài toán biển số dễ hơn bài toán COCO". Đây là **so sánh giữa hai chỉ số có định nghĩa hoàn toàn khác nhau**, và chênh lệch giữa chúng **không phản ánh** độ khó tương đối. Phép đối chiếu hợp lệ duy nhất là so sánh các chỉ số cùng loại (**mAP@0.5** với **mAP@0.5**, hoặc **mAP@0.5:0.95** với **mAP@0.5:0.95**) **trên cùng một tập dữ liệu**. Việc đối chiếu chéo tập dữ liệu chỉ có giá trị tham khảo, không thể dùng làm luận cứ cho quyết định kỹ thuật.

d) **Chỉ tiêu của đề án.** Vì mục tiêu phát hiện là cắt vùng biển đủ tốt để OCR đọc, nhóm thực hiện chọn **mAP@0.5** làm **chỉ tiêu chính**, **mAP@0.5:0.95** vẫn báo cáo nhưng không đặt ngưỡng chấp nhận; giá trị ở Chương 5. e) **mIoU**. Một số công trình dùng IoU trung bình toàn tập; đây là chỉ số khác mAP nên không so sánh chéo được, và đề án không dùng.

2.4. Cơ sở lý thuyết về nhận dạng ký tự

2.4.1. Bài toán OCR và đặc thù khi áp dụng cho biển số

OCR (*Optical Character Recognition*) chuyển văn bản trong ảnh thành chuỗi, thường gồm **text detection** khoanh vùng rồi **text recognition** đọc từng vùng. Sai lầm phổ biến: lấy thẳng bảng xếp hạng OCR phổ thông làm căn cứ chọn bộ nhận dạng cho ALPR.

Bảng 2.6. So sánh OCR văn bản tài liệu và OCR biển số xe

Chiều so sánh	OCR văn bản tài liệu	OCR biển số xe
Nguồn ảnh	Ảnh quét hoặc chụp tài liệu, gần chính diện	Ảnh cảnh ngoài trời, phối cảnh nghiêng, chói sáng, nhoè do chuyển động
Độ dài chuỗi và tập ký tự	Hàng trăm đến hàng nghìn ký tự; tập lớn, mở, kèm dấu	7 – 9 ký tự; tập đóng — chỉ A–Z và 0–9
Bố cục	Nhiều dòng, đa cột, ngắt dòng tùy ý	Cố định: 1 hoặc 2 dòng theo quy chuẩn nhà nước
Ràng buộc cú pháp và vai trò hậu xử lý	Gần như không có; hậu xử lý phụ trợ	Rất chặt, kiểm tra được bằng biểu thức chính quy; hậu xử lý bắt buộc , là lớp sửa lỗi chính
Tiêu chí đánh giá	CER / WER — chấp nhận sai lẻ tẻ	Khớp chuỗi tuyệt đối — sai 1 ký tự là hỏng cả bản ghi
Giá trị của thông tin ngôn ngữ	Cao — mô hình ngôn ngữ sửa lỗi hiệu quả	Thấp — không có từ vựng để dựa vào


2.4.2. Kiến trúc CRNN và hàm mất mát CTC

CRNN gồm ba tầng: **tầng tích chập** trích đặc trưng và — điểm mấu chốt — downsample chiều cao về **1**, biến bản đồ đặc trưng thành **chuỗi vector theo chiều rộng**; **tầng hồi quy** (Bi-LSTM) mô hình hoá ngữ cảnh hai chiều; **tầng phiên mã** giải mã thành chuỗi, thường bằng CTC. EasyOCR dùng đúng kiến trúc này; PaddleOCR dùng SVTR-LCNet kết hợp GTC [10], vẫn thuộc họ CTC.

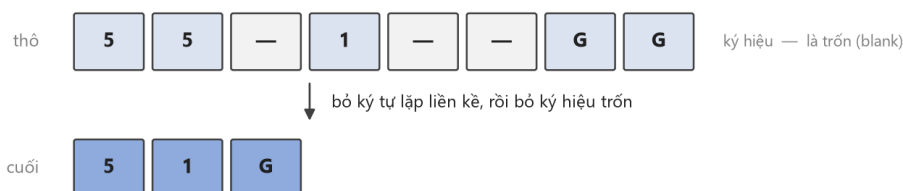
Hàm mất mát CTC giải vấn đề: biết chuỗi nhãn đúng nhưng **không biết mỗi ký tự nằm ở cột đặc trưng nào**. CTC thêm ký hiệu trống ε , định nghĩa ánh xạ $\mathcal{B}$ gộp ký tự lặp rồi xoá ε — ví dụ $\mathcal{B}(3\varepsilon 00\varepsilon A) = 30A$ — và tính xác suất chuỗi nhãn $\mathbf{l}$ bằng tổng xác suất **mọi** đường đi thô $\boldsymbol{\pi}$ ánh xạ về nó:

$$p(\mathbf{l} \mid \mathbf{x}) = \sum_{\boldsymbol{\pi} \in \mathcal{B}^{-1}(\mathbf{l})} \prod_{t=1}^T y_{\pi_t}^t, \quad \mathcal{L}_{\text{CTC}} = -\log p(\mathbf{l} \mid \mathbf{x})$$

Tổng ở (2.3) tính hiệu quả bằng quy hoạch động tiến–lùi. Ưu điểm quyết định: **không cần nhân vị trí từng ký tự** — lý do CTC là mặc định của hầu hết bộ nhận dạng ký tự mã nguồn mở.



Cách CTC gộp chuỗi thô — ví dụ đọc biển 51G



Nhờ ký hiệu trống, CTC không cần nhân vị trí từng ký tự — chỉ cần chuỗi nhân đúng. Đó là lý do nó thành chuẩn cho nhận dạng chuỗi, và cũng là lý do nó gặp khó với văn bản nhiều dòng (mục 2.4.3).

Hình 2.2. Kiến trúc CRNN và cách CTC gộp chuỗi thô. Điểm mấu chốt nằm ở tầng tích chập: nó hạ **chiều cao về 1**, biến bản đồ đặc trưng hai chiều thành một chuỗi vector — nhờ đó bài toán đọc ảnh trở thành bài toán đọc chuỗi.

2.4.3. Vì sao kiến trúc CTC gặp khó với văn bản nhiều dòng

Mục kỹ thuật quan trọng nhất của chương: nền tảng lý thuyết cho rủi ro **R-04** ("khả năng Cao, ảnh hưởng Cao") — ở Việt Nam nơi xe máy áp đảo, biển hai dòng là dạng phổ biến chứ không phải ngoại lệ.



Hình 2.3. Cơ chế sụp đổ của CTC trên ảnh văn bản hai dòng

Ghi chú về phạm vi áp dụng. Cặp số liệu 94,3% / 45,7% được đo trên bộ **RodoSol-ALPR của Brazil, không phải trên dữ liệu Việt Nam**. Nó được dẫn ở đây như một *analogue* định lượng về độ khó vượt trội của biển hai dòng xe máy tại một quốc gia cũng có tỷ lệ xe máy cao. Trích dẫn nhằm cặp số này thành số liệu Việt Nam là lỗi trích dẫn nghiêm trọng.

Bảng 2.7. Các phương pháp phân biệt biển một dòng và biển hai dòng

Phương án	Cơ chế	Ưu điểm và hạn chế
PA-1. Lấy lớp từ	YOLO xuất thêm một lớp: $\theta =$	Chính xác nhất, chi phí gần 0 khi tự

Phương án	Cơ chế	Ưu điểm và hạn chế
chính detector	một dòng, 1 = hai dòng	gán nhãn; phải gán nhãn hai lớp từ đầu
PA-2. Cắt đôi theo tỷ lệ hình học	Bổ nửa ảnh hoặc chia theo ngưỡng heuristic	Nhanh; sai nếu biển cong, che khuất hoặc góc nghiêng lớn
PA-3. Chiếu ngang tìm điểm trùng	Tổng cường độ pixel theo hàng; biển hai dòng có điểm trùng sâu ở giữa	Vị trí cắt thích nghi từng ảnh; điểm trùng biến mất khi biển nghiêng
PA-4. Phân cụm hộp bao theo tọa độ dọc	Dùng text detection của bộ nhận dạng ký tự, gom nhóm theo tâm dọc [10]	Tái dùng kết quả sẵn có; phụ thuộc chất lượng text detection trên vùng cắt nhỏ
PA-5. Kiểm tra tính thẳng hàng của ký tự	Nối tâm ký tự trái nhất và phải nhất, đo độ lệch các ký tự còn lại	Trực quan, dễ gỡ lỗi; cần phát hiện từng ký tự, ngưỡng pixel phụ thuộc độ phân giải

Lưu ý cách đọc số liệu này. Tài liệu gốc ghi recognition pre-trained 0,00%, nhưng con số đó **không** nghĩa là PaddleOCR không đọc được biển: mô hình pre-trained sinh thêm một ký tự đặc biệt khiến chuỗi trượt tiêu chí khớp tuyệt đối; hậu xử lý loại ký tự đó là đạt 90,97%. Luận điểm đúng là **tinh chỉnh nâng 90,97% → 94,54%**; số liệu đo trên **biển Trung Quốc một dòng**, không chứng minh điều gì về biển hai dòng Việt Nam.

2.4.4. Chỉ số CER và độ chính xác mức chuỗi

a) CER (*Character Error Rate*) dựa trên khoảng cách Levenshtein, với S thay thế, D xóa, I chèn, N tổng ký tự chuỗi thực; độ chính xác mức ký tự là $1 - \text{CER}$:

$$\text{CER} = \frac{S + D + I}{N}$$

CER **có thể vượt 1** khi chuỗi dự đoán dài hơn chuỗi thực rất nhiều — đúng tình huống CTC gặp ảnh hai dòng. **b) WER** tương tự nhưng đơn vị là từ; đề án không dùng chỉ số này vì biển số không có ranh giới từ. **c) Độ chính xác mức chuỗi** (*plate-level accuracy, exact match*) là chỉ số nghiêm ngặt nhất:

$$\text{Acc}_{\text{plate}} = \frac{\#\{\text{biển số có TOÀN BỘ chuỗi ký tự khớp chính xác}\}}{\#\{\text{tổng số biển số trong tập kiểm thử}\}}$$

Độ chính xác mức chuỗi đếm số biển có **toàn bộ** chuỗi khớp chính xác. Đây là chỉ số phản ánh đúng giá trị sử dụng, và quan hệ của nó với CER là **bất lợi phi tuyến tính**: với biển 8 ký tự, nếu xác suất đọc đúng mỗi ký tự là p thì xác suất đúng cả chuỗi là p^8 . Với $p = 0,99$ con số này chỉ còn khoảng 0,923; với $p = 0,95$ nó tụt xuống khoảng 0,663. Đây là lý do một bộ nhận dạng có CER rất tốt trên văn bản tài liệu vẫn có thể thất bại trên biển số. **d) End-to-end Recognition Rate** — tỷ lệ biển đọc đúng hoàn toàn trên **toàn bộ đường ống** — là chỉ số duy nhất phản ánh lỗi tích lũy, chỉ tiêu quan trọng nhất của đề án; cuộc thi ICPR 2026 về

biến độ phân giải thấp dùng chỉ số này làm chính, đội vô địch đạt 82,13% [18]. Kèm theo là chỉ số vận hành: **độ trễ** p50, p95, p99 (bắt buộc kèm cấu hình phần cứng), **kích thước mô hình, bộ nhớ thường trú, số tham số**; giá trị ở Chương 5.

2.5. Các công trình liên quan

2.5.1. Công trình quốc tế tiêu biểu

Nhiều công trình quốc tế gần đây (2018-2026) tập trung vào nhận dạng đầu cuối bằng học sâu, cải thiện độ phân giải thấp và sử dụng siêu mô hình ngôn ngữ lớn để khắc phục hạn chế của các hệ thống cũ. Tuy nhiên, ít nghiên cứu nào bóc tách số liệu cho riêng biến hai dòng phức tạp giống như ở Việt Nam.

2.5.2. Công trình về biển số Việt Nam

Nghiên cứu ALPR cho biển Việt Nam chủ yếu công bố tại hội nghị, tạp chí khu vực, **không xuất hiện trên các benchmark quốc tế lớn**, phần lớn đánh giá trên tập tự thu thập không công khai — so sánh công bằng gần như bất khả thi.

2.5.3. Các bộ dữ liệu chuẩn trong lĩnh vực

Khảo sát đối chiếu **chín bộ dữ liệu chuẩn** của lĩnh vực theo quy mô, đặc điểm và **giấy phép sử dụng** — cột giấy phép quyết định bộ nào dùng được cho đề án này.

2.5.4. Khoảng trống nghiên cứu và định vị đề tài

Bảng 2.8. Sáu khoảng trống nghiên cứu và cách nhóm thực hiện lấp

#	Khoảng trống được xác định từ khảo sát	Cách nhóm thực hiện lấp
1	Chưa có nghiên cứu Việt Nam nào công bố bảng so sánh tách riêng độ chính xác biển một dòng và biển hai dòng trên cùng một hệ thống (mục 2.5.2)	Nhóm thực hiện báo cáo tách bạch hai con số này
2	Chưa có nghiên cứu Việt Nam nào mô tả có hệ thống bộ luật hậu xử lý ràng buộc theo VỊ TRÍ trong chuỗi — các mô tả hiện có dừng ở danh sách phẳng, phần lớn dùng nhầm con số 20 chữ cái cho toàn chuỗi (mục 2.2.4)	Thiết kế hậu xử lý theo từng vị trí, đo tách bạch trước và sau hậu xử lý ; hiệu số là đóng góp định lượng
3	Hầu hết công trình trong nước chỉ báo cáo mAP của bước phát hiện , không báo cáo end-to-end mức chuỗi (mục 2.5.2)	Báo cáo cả hai, end-to-end là chỉ tiêu quan trọng nhất
4	Không tồn tại benchmark công khai nào so sánh các bộ nhận dạng ký tự trên riêng ảnh biển số xe máy Việt Nam hai dòng (mục 3.3)	 Đã lấp — đo ba bộ nhận dạng trên 2.801 biển, cùng tăng bao quanh: PaddleOCR 68,87% · EasyOCR 14,28% · Tesseract 10,28% (mục 3.3.3)

#	Khoảng trống được xác định từ khảo sát	Cách nhóm thực hiện lấp
5	Số liệu hiệu năng thường công bố không kèm phần cứng (mục 2.5.1)	Mọi số liệu hiệu năng kèm: model CPU, số luồng, kích thước ảnh vào, nền tảng suy luận, cỡ mẫu đo
6	Hầu hết kho mã nguồn mở Việt Nam không công bố số liệu và không có kiến trúc phần mềm (mục 2.5.2)	Công bố đầy đủ giao thức đo, tập kiểm thử, toàn bộ chỉ số; bàn giao hệ thống có API, giao diện, cơ sở dữ liệu, kiểm thử, đóng gói

Sáu khoảng trống đều thuộc loại **kỹ nghệ và báo cáo**, không phải thuật toán: đề án không đặt mục tiêu vượt các con số trên 99% đã khảo sát — trong đó 99,28% của nhóm Học viện Kỹ thuật Quân sự đo trên tập riêng không công khai — và mọi số liệu hiệu năng của đề án là **số liệu CPU**, không so trực tiếp với FPS đo trên GPU.

Tuyên bố trung thực đầy đủ về mức đóng góp, cùng bốn điều đề án **không** tuyên bố, đặt ở **mục 1.5.1 và 1.5.2** (Chương 1) — nơi chính danh để tuyên bố đóng góp.

CHƯƠNG 3. KHẢO SÁT CÔNG NGHỆ VÀ LỰA CHỌN MÔ HÌNH

3.1. Phương pháp khảo sát và tiêu chí lựa chọn

Một nguyên tắc chi phối toàn chương. Mọi bảng dưới đây phân biệt rõ hai loại bằng chứng: **số tự đo trên máy thực nghiệm** và **số trích từ tài liệu của người khác**. Loại thứ hai luôn kèm tên bộ dữ liệu và quốc gia, vì một con số đo trên ngữ liệu khác không nói được điều gì chắc chắn về ngữ liệu này. Chỗ nào chưa đo thì ghi thẳng là chưa đo, chứ không mượn số của người khác làm kết luận cho đề án.

Mỗi lựa chọn trình bày theo cùng một khuôn: phương án đã xét, tiêu chí, kết luận, **đánh đổi phải chấp nhận**. Khi bằng chứng không đủ phân định, mục này nói rõ là không đủ.

3.1.1. Bốn ràng buộc chi phối mọi lựa chọn

Bốn ràng buộc sau thu hẹp không gian phương án **trước khi** so sánh — vì sao một số ứng viên mạnh bị loại sớm.

#	Ràng buộc	Hệ quả trực tiếp lên việc chọn
1	Suy luận trên CPU, không có GPU CUDA (CON-02, mục 4.3.1)	Phương án không công bố tốc độ CPU đều không có căn cứ để đánh giá ; mô hình hàng trăm triệu tham số loại từ đầu
2	Biến số Việt Nam có biến hai dòng	Bộ nhận dạng giả định văn bản một dòng sẽ hỏng ở đây; tiêu chí phân loại, không phải điểm cộng
3	Phải đóng gói và bàn giao được	Giấy phép, dung lượng mô hình, số phụ thuộc là tiêu chí thật
4	Ngân sách thời gian CPU hữu hạn	Một số phép so sánh đã thiết kế nhưng không chạy được — mỗi bảng dưới đây ghi thẳng ô nào là chưa đo

3.2. Mô hình phát hiện: YOLO11

Các phương án đã xét. Các thể hệ YOLO từ YOLOv8 trở về sau — mốc chuyển sang anchor-free, có ý nghĩa trực tiếp với bài toán biến số (mục 2.3.1). Bốn thể hệ có khác biệt kiến trúc đáng kể với bài toán này được đối chiếu ở Bảng 2.4: YOLOv8 [13], YOLOv10 [19], YOLO11 [9] và YOLO26 [20]. Họ two-stage (Faster R-CNN, Mask R-CNN) loại từ đầu vì chi phí tính toán không hợp ràng buộc CPU.

3.3. Bộ nhận dạng ký tự

Đây là lựa chọn trình bày **trung thực nhất về mức độ chắc chắn**: chọn *họ bộ nhận dạng* theo khảo sát tài liệu (3.3.1), rồi chọn *bậc mô hình* theo phép đo tự chạy (3.3.2).

3.3.1. PaddleOCR, EasyOCR, Tesseract — khảo sát tài liệu

Các phương án đã xét: tám bộ nhận dạng — PaddleOCR, EasyOCR, Tesseract, TrOCR, docTR, MMOCR, fast-plate-ocr và RapidOCR/OnnxTR.

3.3.2. PP-OCRv5 mobile so với PP-OCRv6 — đo trên máy đồ án

Mục này chọn **bậc mô hình** bên trong họ đã chọn, dựa trên số liệu **tự đo**.

Bảng 3.2. PP-OCRv6_medium_rec so với PP-OCRv5_mobile_rec, đo trên 200 vùng cắt biến số của đồ án

Mô hình	Đúng chuỗi	Trung vị	p95
PP-OCRv5_mobile_rec — đang dùng	134/200 = 67,0%	23,0 ms	31,9 ms
PP-OCRv6_medium_rec	145/200 = 72,5%	386,9 ms	429,0 ms

Ghi chú: kết quả này dựa trên phép chiếu, không phải phép đo trực tiếp. Khi cộng thêm 364 ms vào độ trễ p95 hiện tại, tổng thời gian ước tính là khoảng **1.507 ms, vượt qua giới hạn tối đa 1.500 ms** và khiến chỉ tiêu NFR-P1 chuyển từ trạng thái Đạt ngưỡng tối thiểu (●) sang Không đạt (✗). Con số này được nội suy từ độ trễ của riêng nhánh nhận dạng và **chưa được đo lường lại trên toàn bộ đường ống xử lý**; để công bố chính thức, cần phải đo đạc thực tế. Tuy nhiên, dù có tính đến sai số, kết luận cốt lõi vẫn không thay đổi: khi NFR-P2 đã không đạt yêu cầu ban đầu, độ trễ tăng thêm sẽ làm chỉ tiêu này càng khó được đáp ứng.

Lưu ý bắt buộc khi trích bài PP-OCRv6. Cặp "+5,1 / +4,6 điểm" mà bài v6 công bố được tính trên **mốc so sánh của chính nó** (v5_server 78,1% / 81,6%), không phải trên mốc so sánh trong tài liệu PaddleX (86,38% / 83,8%). Ghép hai nguồn sẽ **đảo chiều kết luận**. Trích thì phải trích kèm mốc so sánh gốc.

3.3.3. Benchmark ba bộ nhận dạng trên 2.801 biến số Việt Nam

Mục 3.3.1 kết thúc bằng một hạng mục chưa giải quyết: giữ PaddleOCR dựa trên lý do kỹ thuật, **không** dựa trên bằng chứng độ chính xác, trong khi tài liệu công khai nghiêng về EasyOCR. Mục này trả nợ đó.

a) Thiết lập phép đo. Bốn lượt chạy đầu không hợp lệ do thiếu điều kiện cần: truyền tên mô hình tường minh, tắt thư viện tăng tốc oneDNN (mục 4.6.3), khôi phục tỷ lệ khung hình và lọc mảnh nhiễu ở mép dài ghép. Hiệu năng phụ thuộc vào cả bộ nhận dạng ký tự lẫn tiền xử lý, hậu xử lý; vì vậy, so sánh các bộ nhận dạng phải dùng cùng một tầng bao quanh.

b) Thiết kế. Cả ba bộ nhận dạng chạy trong **đúng một tầng bao quanh** — sao đúng chuỗi bước của bộ nhận dạng bản bàn giao — trên **cùng một mảng NumPy đã chuẩn bị xong**; khác biệt duy nhất còn lại là bộ nhận dạng. Đây cũng là bằng chứng thực nghiệm cho NFR-M5. Một chỗ cố ý không cào bằng: Tesseract chạy kèm whitelist A-Z0-9, vì giới hạn tập ký tự là **năng lực gốc** của nó; cắt bỏ "cho công bằng" mới là làm sai.

Kiểm chứng công cụ đo: nhánh có tách đôi của PaddleOCR đạt **63,73%**, khớp NFR-A5 = 0,6373 đã công bố.

Bảng 3.3. So sánh ba bộ nhận dạng ký tự trên 2.801 biển số Việt Nam (567 một dòng, 2.234 hai dòng)

Bộ nhận dạng	Nhánh	Toàn bộ	1 dòng	2 dòng	CER	Rỗng	p50
PaddleOCR	tắt tách đôi	28,81%	94,2%	12,2%	0,588	6	295 ms
PaddleOCR	có tách đôi	63,73%	94,2%	56,0%	0,094	11	405 ms
PaddleOCR	+ hậu xử lý	68,87%	94,9%	62,3%	0,089	11	402 ms
EasyOCR	tắt tách đôi	6,53%	15,3%	4,3%	0,647	4	84 ms
EasyOCR	có tách đôi	10,35%	15,3%	9,1%	0,282	1	248 ms
EasyOCR	+ hậu xử lý	14,28%	28,6%	10,7%	0,269	1	249 ms
Tesseract	tắt tách đôi	9,57%	47,3%	0,0%	0,777	960	101 ms
Tesseract	có tách đôi	9,60%	47,3%	0,0%	0,565	700	108 ms
Tesseract	+ hậu xử lý	10,28%	50,4%	0,1%	0,567	700	106 ms

c) Kết quả so sánh trong cấu hình của đề án. Ở cấu hình bản bàn giao, PaddleOCR đạt **68,87%**, cao hơn EasyOCR **54,59 điểm** và Tesseract **58,59 điểm**. Kết luận "*tài liệu công khai không cho thấy PaddleOCR vượt EasyOCR trên ảnh biển số*" ở mục 3.3.1 vẫn đúng đối với các tài liệu đã khảo sát. Tuy nhiên, phép đo trên biển số Việt Nam trong cùng tầng bao quanh của đề án cho kết quả khác; do đó, quyết định giữ PaddleOCR có thêm căn cứ thực nghiệm **trong phạm vi cấu hình đánh giá này**.

d) Bước tách rời ghép ngang không độc lập với bộ nhận dạng.

Bộ nhận dạng	tắt tách đôi → có tách đôi	Mức tăng
PaddleOCR	28,81% → 63,73%	+34,92 điểm
EasyOCR	6,53% → 10,35%	+3,82 điểm
Tesseract	9,57% → 9,60%	+0,03 điểm

Nếu cả ba bộ nhận dạng đều có sự gia tăng đáng kể về độ chính xác, có thể kết luận kỹ thuật của đề án mang tính độc lập với bộ nhận dạng. Tuy nhiên, **kết quả thực nghiệm không ủng hộ giả định này**. Thực tế cho thấy, kỹ thuật tách và ghép ngang chỉ là điều kiện **cần** để xử lý biển hai dòng bằng cách chuyển đổi bài toán đa dòng về một dòng, nhưng **chưa đủ**; nó đòi hỏi bộ nhận dạng ký tự phải có đủ năng lực để trích xuất thông tin từ dải ảnh đã ghép hiệu quả.

Ngược lại, **bộ luật hậu xử lý giúp cả ba** (+5,14 · +3,93 · +0,68 điểm). Đóng góp (b) của đề án vì vậy **là đóng góp độc lập bộ nhận dạng**, khác với tách rời ghép ngang.

e) Tesseract không đọc được biển hai dòng. 0,0% trên 2.234 biển hai dòng, kể cả sau khi đã ghép thành một dòng, trong khi đọc được 47,3% biển một dòng. Đã kiểm bằng mắt để

loại khả năng lỗi công cụ: nó **có** đọc ra chữ nhưng luôn kèm ký tự rác, và 700/2.801 lần trả chuỗi rỗng. Dự đoán *"Tesseract hỏng khi vùng cắt nhiều dòng"* ở mục 3.3.1 được xác nhận, ở mức nghiêm trọng hơn.

Hai điều phép đo này không trả lời. Thứ nhất, nó đo trên **vùng biển đã cắt sẵn**; báo cáo 31 cho thấy thứ tự xếp hạng có thể **đảo ngược** trên ảnh toàn cảnh qua bộ phát hiện thật, nên kết luận chỉ áp cho tầng nhận dạng. Thứ hai, nó **không** kết luận bộ nhận dạng nào tốt hơn nói chung — chỉ kết luận bộ nhận dạng nào đọc biển số Việt Nam tốt hơn *bên trong tầng bao quanh của đồ án*; một hệ thống thiết kế quanh EasyOCR, với tiền xử lý riêng của nó, có thể cho số khác.

3.4. Nền tảng suy luận trên CPU: ONNX Runtime

Các phương án đã xét: chạy trực tiếp tệp trọng số PyTorch, ONNX Runtime, OpenVINO.
Tiêu chí: tốc độ CPU, mức đa nền tảng, độ nặng phụ thuộc khi đóng gói, khả năng cùng tồn tại với framework khác.

Ghi chú về cách trích dẫn. Chỉ được dùng **phần số liệu tốc độ** của bảng benchmark này. Các con số mAP đi kèm được đo trên tập coco8 chỉ gồm **8 ảnh**, nên **vô nghĩa về mặt thống kê** và không được trích dẫn dưới bất kỳ hình thức nào.

3.5. Các lựa chọn công nghệ nền tảng khác

Phần lớn quyết định còn lại là **ràng buộc của đề bài**; ghi lại kèm lý do và đánh đổi để Chương 4 tham chiếu.

Bảng 3.4. Tổng hợp quyết định công nghệ nền tảng

#	Hạng mục	Lựa chọn (phương án thay thế)	Lý do chính	Đánh đổi phải chấp nhận
1	Nền tảng web phía máy chủ	FastAPI (Django, Flask)	Tự sinh đặc tả OpenAPI — tạo sẵn một sản phẩm bàn giao; có sẵn WebSocket và tác vụ nền	Phải biết khi nào không dùng hàm bất đồng bộ; nguy cơ tranh chấp với luồng suy luận
2	ORM và migration	SQLAlchemy 2.0 + Alembic (Tortoise ORM, Peewee)	Tích hợp sâu kiểu tĩnh; lược đồ đã thay đổi nên nhu cầu migration là có thật	Đường cong học dốc nhất trong nhóm
3	Cơ sở dữ liệu	SQLite (PostgreSQL, MySQL)	Ghi có thể xếp hàng vì suy luận CPU mới là nút cổ chai; không thêm dịch vụ khi đóng gói	Chỉ một tiến trình ghi tại một thời điểm ; vượt ngưỡng tải phải chuyển PostgreSQL

#	Hạng mục	Lựa chọn (phương án thay thế)	Lý do chính	Đánh đổi phải chấp nhận
4	Giao diện	React + TypeScript + Vite + TailwindCSS (Vue, Angular, Svelte)	Hệ sinh thái lớn nhất; công cụ build tiên nhiệm ngưỡng bảo trì; kiểu tĩnh nối tiếp từ máy chủ	Tự lắp ghép routing, quản lý trạng thái, thành phần giao diện
5	Framework học sâu	PyTorch (TensorFlow)	Ultralytics khai báo PyTorch là phụ thuộc lõi — chọn YOLO11 là chọn PyTorch	Kéo theo framework học sâu thứ hai (PaddlePaddle) do lựa chọn OCR — giải bằng mục 3.4
6	Đóng gói	Docker + Compose	Yêu cầu tái lập và khởi động bằng một lệnh	Kích thước image là rủi ro do có framework học sâu

3.6. Độ phân giải đầu vào: 640 thay vì 416

Đồ án có sẵn hai mô hình để đối chiếu — `baseline-416-v1.pt` và `best.pt` — nhưng **phép so sánh giữa chúng không quy kết được nguyên nhân**: giữa hai lượt huấn luyện có **ba biến thay đổi đồng thời và ngược chiều nhau** (độ phân giải 416 → 640, bộ dữ liệu v1 → v3 đã khử rò rỉ, số epoch), nên chênh lệch chỉ số **không gán được cho riêng biến nào**. Cần nêu rõ điều này để tránh kết luận sai: ở tầng phát hiện, `best.pt` **vượt mọi ngưỡng đã đặt ra** (mục 5.4.1).

Lựa chọn **640** vì vậy đứng trên căn cứ khác: đó là độ phân giải mà chỉ tiêu NFR-A1/A2 đặt ra và là độ phân giải mọi số liệu tốc độ CPU chính thức của Ultralytics được đo. Muốn quy kết nguyên nhân cần một ma trận thí nghiệm cô lập từng biến (E1 – E3), ước tính **≈ 33 giờ CPU** — vượt ngân sách còn lại, ghi nhận là **chưa thực hiện** ở mục 6.3.

CHƯƠNG 4. THIẾT KẾ VÀ CÀI ĐẶT HỆ THỐNG


Trên cơ sở lý thuyết ở Chương 2 và lựa chọn công nghệ ở Chương 3, chương này trình bày thiết kế và hiện thực của hệ thống trong cùng một mạch. Nguyên tắc trình bày: mọi mô tả đều phản ánh đúng mã nguồn thực tế; các chức năng chưa hoàn thiện và các số liệu chưa được đo lường đều được ghi chú rõ ràng. Chương gồm phân tích yêu cầu (4.1), kiến trúc (4.2), môi trường phát triển (4.3), bộ dữ liệu (4.4), huấn luyện mô hình (4.5), tầng AI (4.6), máy chủ và cơ sở dữ liệu (4.7), giao diện (4.8), Docker (4.9) và bảng đối chiếu cài đặt lịch thiết kế (4.10).

Trạng thái bản này: hệ thống chạy ALPRPipeline với mô hình chính thức models/best.pt (/health báo model_loaded: true, bộ nhận dạng yolo:best.pt+paddleocr-PP-OCRv5-mobile, mAP@0.5 = 0,9829); StubPipeline đã ra khỏi đường chạy chính. Mọi kết quả thực nghiệm trình bày ở Chương 5.

4.1. Phân tích yêu cầu

4.1.1. Sơ đồ use case và ba use case chính

Ba use case chính — nhận dạng từ ảnh (UC-01), từ video (UC-02) và tra cứu lịch sử (UC-05) — đều được đặc tả theo cùng một khuôn: tác nhân, tiền điều kiện, luồng chính, luồng thay thế và hậu điều kiện.



Hình 4.1. Sơ đồ use case — hai tác nhân và bốn use case. Ba use case tô đậm là use case chính được đặc tả đầy đủ theo khuôn tác nhân · tiền điều kiện · luồng chính · luồng thay thế.

4.1.2. Yêu cầu chức năng

Hệ thống có **34 yêu cầu chức năng** chia sáu nhóm, phân mức theo MoSCoW: 22 *Must*, 5 *Should*, 3 *Could*, 4 *Won't*. Sáu yêu cầu mức *Won't* đến từ ba đợt thu gọn phạm vi: bốn yêu

cầu thuần giao diện chuyển mức ở đợt thu gọn giao diện, và hai yêu cầu của nhóm video — xuất video đã chú thích cùng huỷ tác vụ đang chạy — chuyển mức ở đợt thu gọn nhóm video. Bốn yêu cầu mức *Must* từng chuyển sang *Won't*, nhưng **hai trong số đó đã quay lại**: FR-3.1 và FR-3.4 được cài đặt lại cùng chế độ quét trực tiếp (4.8.1). **Còn lại hai yêu cầu *Must* nằm ngoài phạm vi: FR-4.1 và FR-2.5** — FR-4.1 chỉ mất màn hình hiển thị (thống kê vẫn phục vụ ở tầng API và vẫn có kiểm thử), riêng **FR-2.5 mất chính năng lực**. Nêu rõ ở mục 6.2. Bảng đầy đủ từng mã yêu cầu ở **Phụ lục H.2**.

4.1.3. Yêu cầu phi chức năng

Các chỉ tiêu phi chức năng chia bảy nhóm — độ chính xác (NFR-A), hiệu năng (NFR-P), độ tin cậy (NFR-R), khả năng chịu tải (NFR-SC), khả năng bảo trì (NFR-M), bảo mật (NFR-S) và khả dụng (NFR-U) — mỗi chỉ tiêu kèm **ngưỡng tối thiểu, mục tiêu và phương pháp đo**. Hai ràng buộc chi phối toàn bộ nhóm hiệu năng: suy luận **chỉ trên CPU** (CON-02) và ngân sách độ trễ đầu cuối. Bảng đầy đủ ở **Phụ lục H.3**; kết quả đối chiếu từng chỉ tiêu ở mục 5.7.

4.2. Kiến trúc hệ thống

4.2.1. Nguyên tắc kiến trúc


Kiến trúc sạch và quy tắc phụ thuộc: phụ thuộc chỉ hướng vào trong, từ chi tiết dễ thay đổi (framework web, CSDL, giao diện) về quy tắc nghiệp vụ ổn định. Ở bài toán này, thứ ổn định là thuật toán nhận dạng biến số — phát hiện, cắt, đọc, chuẩn hoá theo quy chuẩn Việt Nam; thứ dễ đổi là FastAPI hay Flask, SQLite hay PostgreSQL. Do đó **đường ống AI nằm ở vòng trong cùng**, tầng web phụ thuộc nó chứ không ngược lại. SOLID vận dụng: *trách nhiệm đơn nhất* — detector chỉ trả bounding box, recognizer chỉ trả chuỗi, normalizer chỉ chuẩn hoá — cho phép đo từng khối riêng; *thay thế Liskov* — dùng theo nghĩa đen khi hệ thống chạy đường ống giả lập đúng hợp đồng đường ống thật; *đảo ngược phụ thuộc* — tầng nghiệp vụ phụ thuộc hợp đồng trừu tượng, cài đặt tiềm từ ngoài.

Bảng 4.2. Bốn ràng buộc kiến trúc và cách kiểm chứng từng ràng buộc

#	Ràng buộc	Mã chỉ tiêu	Cách hiện thực	Kiểm chứng bằng gì
1	Không trộn mã AI với mã API	NFR-M1	ai/ là gói Python độc lập, không import framework web	Kiểm thử tự động quét <code>sys.modules</code> lúc chạy
2	Mọi thành phần AI thay thế được	NFR-M5	Ba lớp trừu tượng, đường ống chỉ giữ tham chiếu tới lớp cha (Hình 4.6)	Đổi bộ nhận dạng không phải sửa nơi khác
3	Không gán cứng đường dẫn	NFR-M4	Mọi đường dẫn qua đối tượng cấu hình đọc từ biến môi trường	Đổi ALPR_MODEL_PATH là đổi được mô hình
4	Chạy được không cần GPU	CON-02 · NFR-C2	Thiết bị suy luận là tham số, mặc định cpu	Toàn bộ số liệu Chương 5 đo trên CPU

Ràng buộc thứ tư phát biểu là **cấu hình mặc định**, không phải "chế độ dự phòng" — nên đường chạy CPU là đường được kiểm thử thường xuyên nhất, chứ không phải nhánh ít ai đụng tới.

4.2.2. Kiến trúc phân tầng



Hình 4.2. Kiến trúc phân tầng năm tầng và chiều phụ thuộc

Năm tầng: **1 — Trình bày** (giao diện, chỉ biết hợp đồng HTTP của tầng 2); **2 — API** (định tuyến, kiểm tra hợp lệ, ánh xạ ngoại lệ thành mã HTTP, sinh OpenAPI); **3 — Nghiệp vụ** (điều phối: tạo tác vụ, gọi đường ống, lưu tệp, ghi CSDL, gộp trùng, thống kê); **4 — AI** (phát hiện, nhận dạng, chuẩn hoá — **chỉ biết NumPy, OpenCV và thư viện học sâu**); **5 — Dữ liệu**

(CSDL, kho tệp). **Điểm mấu chốt:** khối tầng AI **không có mũi tên nào đi lên**. Sau hai đợt thu gọn, tầng trình bày còn **ba trang** nhưng **tầng 2–5 không đổi một dòng**: POST /detect/frame, GET /statistics, GET /health vẫn phục vụ và vẫn có kiểm thử tích hợp — phép thử ngoài dự kiến cho nguyên tắc phụ thuộc một chiều.

4.2.3. Tách tầng AI khỏi tầng API và cách kiểm chứng ràng buộc

Ba lợi ích. *Kiểm thử độc lập:* test chỉ cần nạp mảng NumPy, không phải dựng ứng dụng web. *Tái sử dụng trong script huấn luyện và đánh giá:* nếu logic tiền xử lý nằm lẫn trong hàm HTTP thì script đánh giá phải sao chép, hai bản sẽ lệch nhau, dẫn tới hệ quả nghiêm trọng nhất có thể xảy ra: **con số công bố không phản ánh đúng kết quả thực tế của hệ thống**. Mục 4.6.4g và 4.10 phân tích một trường hợp thuộc loại này. *Thay thế bộ nhận dạng mà không cần sửa mã tầng API* đã được **kiểm chứng trên thực tế**: trong suốt giai đoạn xây dựng phần mềm và kiểm thử, hệ thống chạy với StubPipeline, toàn bộ tầng API, nghiệp vụ, cơ sở dữ liệu và giao diện đã được xây dựng và kiểm chứng **trước khi mô hình được huấn luyện**; khi trọng số đã sẵn sàng, việc chuyển sang ALPRPipeline chỉ là thao tác đổi thành phần phụ thuộc được tiêm vào, **không cần sửa đổi** router, service hay schema. Để tránh nhầm lẫn giữa trạng thái mô phỏng và vận hành thực tế, endpoint /health sẽ báo degraded khi StubPipeline còn đang hoạt động.

4.2.4. Luồng xử lý của đường ống AI và nhánh biến hai dòng



Hình 4.3. Luồng xử lý của đường ống AI, các khối tô đỏ là nhánh biến hai dòng

Nhánh biến hai dòng là phần khó nhất của đề án và là rủi ro đã xác định từ khâu lập kế hoạch (R-04). Bộ OCR dựng sẵn giả định văn bản một dòng ngang, nên với biến hai dòng chúng đọc theo thứ tự không xác định, ghép lẫn hoặc bỏ sót một dòng — cơ chế đứng sau chênh lệch 48,6 điểm phần trăm **đo trên bộ RodoSol-ALPR của Brazil** đã dẫn ở 4.1.1 [2]. Giải pháp: **tách vùng biến thành hai nửa, nhận dạng từng nửa, ghép theo thứ tự trên trước dưới sau** — mỗi nửa lúc này là một dòng ngang đúng giả định của bộ OCR (cài đặt ở 4.6.4).

4.2.5. Bảng tổng hợp các quyết định kiến trúc

Mỗi quyết định ghi kèm lý do và **đánh đổi phải chấp nhận** — một quyết định trình bày như không có nhược điểm là quyết định chưa cân nhắc đủ.

Bảng 4.3. Tám quyết định kiến trúc — mỗi dòng kèm đánh đổi phải chấp nhận

Mã	Quyết định	Lựa chọn	Đánh đổi phải chấp nhận
AD-01	Tách tầng AI khỏi tầng API	Gói Python độc lập	Thêm một lớp gián tiếp
AD-	Xử lý video	Bất đồng bộ, trả job_id ngay	Giao diện phải hỏi tiến độ định

Mã	Quyết định	Lựa chọn	Đánh đổi phải chấp nhận
02			kỳ
AD-03	Nhận dạng thời gian thực	Client gửi từng khung qua HTTP	Muốn FPS cao hơn phải chuyển WebSocket
AD-04	Gộp trùng biến số	Theo chuỗi ký tự + cửa sổ thời gian	Kém chính xác khi hai xe cùng biến đi gần nhau
AD-05	Nền tảng suy luận	PyTorch trước, ONNX/OpenVINO nếu cần	Có thể phải làm lại bước xuất mô hình
AD-06	Thiết bị	Cấu hình được, mặc định cpu	—
AD-07	Lưu trữ ảnh	Tệp trên đĩa, chỉ lưu đường dẫn trong CSDL	Phải giữ đồng bộ giữa tệp và bản ghi
AD-08	Đặt tên tệp	UUID, không dùng tên gốc	Cần lưu tên gốc riêng nếu muốn hiển thị

Tám quyết định kiến trúc được ghi thành hồ sơ AD-01 ... AD-08, mỗi hồ sơ nêu **bối cảnh, phương án đã cân nhắc, quyết định và hệ quả phải chấp nhận** — dạng ghi chép này khiến một quyết định về sau có thể bị lật lại mà người lật hiểu được vì sao nó từng đúng. Các mục 4.2.1 – 4.2.4 trình bày bốn quyết định có ảnh hưởng rộng nhất.

Ghi chú: AD-03 không đổi sau khi gỡ trang Webcam vì ở ~5 FPS trên CPU, điểm nghẽn là suy luận chứ không phải giao thức. AD-04 cố ý **không** chọn tracking vì phức tạp hơn đáng kể và thêm một họ siêu tham số. AD-05 là quyết định duy nhất **đã thay đổi** so với phác thảo ("PyTorch trước, ONNX nếu cần") — ghi nhận tường minh thay vì lặng lẽ sửa bảng. AD-06 kéo theo hai quyết định phái sinh đã cài đặt: yolov11n và **PP-OCrv5 mobile** — ràng buộc CPU thay đổi *lựa chọn mô hình*, không chỉ tốc độ.

4.3. Môi trường và công cụ phát triển

4.3.1. Cấu hình máy thực hiện và hệ quả của ràng buộc CPU


Toàn bộ cài đặt, kiểm thử và đo đạc chạy trên một máy trạm duy nhất: Windows 11 Pro; Intel Core i5-14600K, 14 nhân / 20 luồng; RAM 31,77 GiB; Intel UHD 770 — **không có GPU CUDA**; Python 3.13.12; Node.js 18.20.8; Docker 29.4.3. Cấu hình này **mâu thuẫn với mô tả môi trường ban đầu** (macOS Apple Silicon, Python 3.12), và ghi nhận sai lệch thành văn bản là bước đầu của giai đoạn phân tích yêu cầu.

Ràng buộc CPU để lại dấu vết cụ thể: NFR-P1 phát biểu thẳng cho CPU; AD-06 kéo theo yolov11n và PP-OCrv5 mobile; và vì huấn luyện trên CPU mất 1–3 ngày mỗi lượt, quy trình huấn luyện chạy được cả trên máy cá nhân lẫn nền tảng đám mây với toàn bộ siêu tham số trong một tệp cấu hình duy nhất. Ở cấu hình giao hàng, p95 đầu cuối là **509,76 ms**, đạt cả

ngưỡng tối thiểu 1.500 ms lần mục tiêu 800 ms; phân rã suy luận thuần cho thấy OCR chiếm **60,8%**, phát hiện **38,0%** (đối chiếu NFR-P1 ở 4.10).

4.4. Xây dựng bộ dữ liệu

4.4.1. Đường ống sáu bước và thành phần bộ dữ liệu



Hình 4.4. Đường ống sáu bước xây dựng bộ dữ liệu

Mỗi bước là một kịch bản độc lập có giao diện dòng lệnh riêng và sinh báo cáo dạng dữ liệu có cấu trúc; một kịch bản điều phối chạy toàn chuỗi bằng một lệnh. **Kết quả: 15.133 ảnh** hợp nhất từ **7 bộ công khai** (Roboflow, HuggingFace, Kaggle), còn **6 nguồn nguyên tố** sau khi loại **11.978 ảnh (44,2%)** bản sao từ **27.111 ảnh**; tổng 9 bộ tải về, 2 bộ nhận mức ký tự tách riêng cho đánh giá OCR. Chia 70/20/10 thành **10.592 / 3.027 / 1.514 ảnh**. Bảng dưới **phải trích khi nói về dữ liệu của đề án**; nguồn và giấy phép từng bộ ở **Phụ lục C.1**.

Bảng 4.4. Đóng góp của từng bộ dữ liệu trước và sau khử trùng lặp

#	Bộ (slug)	Vào gộp	Còn lại	Bị loại
1	roboflow_school_fuhih	8.357	6.868 (45,38%)	17,8%
2	hf_vn_plates_segment	4.578	4.375 (28,91%)	4,4%
3	roboflow_traffic_camera	3.843	3.162 (20,89%)	17,7%
4	roboflow_eric_nguyen	840	353 (2,33%)	58,0%
5	roboflow_demo_tracking	236	235 (1,55%)	0,4%
6	roboflow_cuong_ta	8.254	140 (0,93%)	98,3%
7	roboflow_tran_ngoc_xuan_tin	1.005	0	100%
Tổng		27.113	15.133	44,2%

Ghi chú về phạm vi của mọi số liệu OCR. Phân loại màu nền trên 2.801 ảnh cho: **2.736 biển trắng (97,68%)**, 20 vàng, 4 xanh, **0 đỏ, 0 ngoại giao**. Phát biểu đúng là *"1 – CER = 0,9483 trên một tập gồm 97,7% biển trắng"*, **không phải** *"trên biển số Việt Nam"*.

Hai tỉ lệ khử trùng lặp, hai mẫu số khác nhau. Hợp nhất bảy bộ cho **27.113 ảnh thô**; sau khi loại ảnh gần trùng còn **15.133**, tức bỏ **44,2%**. Con số này đo bằng băm tri giác ở ngưỡng Hamming 5. **Giới hạn của cách làm phải nêu kèm:** băm tri giác rút ảnh thành 64 bit mô tả cấu trúc tần số thấp của *toàn khung*, nên hai xe khác nhau qua cùng một camera vẫn cho khoảng cách rất nhỏ — ngưỡng thấp bỏ sót cặp cùng xe khác ngày, ngưỡng cao gộp nhầm hàng nghìn ảnh khác xe. Vì vậy

vẫn còn rò rỉ tồn dư không khử được bằng bấm tri giác, ghi thành hạn chế số 3 ở mục 6.2 và đo lại ở 5.3.1.


4.5. Huấn luyện mô hình

4.5.1. Siêu tham số và chi phí huấn luyện bộ phát hiện

Cấu hình lượt huấn luyện chính thức trích từ tệp tham số do thư viện tự sinh — bản ghi *đã thực thi* chứ không phải *dự định*. Các giá trị chịu lực: YOLO11n tiền huấn luyện COCO (**2.590.035** tham số, biến thể nhỏ nhất do ràng buộc CPU), độ phân giải **640** theo NFR-A1/A2, **20 epoch** lô 8, AdamW với tốc độ học 0,001 theo lịch cosine, thiết bị CPU, hạt giống cố định 42 kèm chế độ tắt định. Phép lật ngang **tắt hoàn toàn** — lệch có chủ ý so với mặc định, vì nó sinh ký tự đối xứng gương, một phân bố không bao giờ xuất hiện thật.

Giới hạn thời gian CPU chỉ cho phép **một lượt huấn luyện duy nhất**, nên không có nhiều hạt giống để ước lượng phương sai; cố định hạt giống ít nhất bảo đảm lượt này tái lập được, và mọi chỉ số phải đọc là **kết quả một lần chạy, không có khoảng tin cậy** (5.9.3). **Chi phí:** mô hình đối chứng 40 epoch @416 trên bộ v1 mất **156 phút**; mô hình chính thức 20 epoch @640 trên bộ v3 mất **30,2 phút mỗi epoch, tổng 10,05 giờ** trên CPU. Ba yếu tố cùng đổi (số ảnh $\times 3,3$, diện tích $\times 2,37$, epoch giảm nửa) nên so sánh ở mục 3.6 **không quy kết được nguyên nhân cho từng biến**.

4.5.2. Tiến triển của quá trình huấn luyện



Hình 4.5. Đường cong huấn luyện theo epoch — ba hàm mất mát và bốn chỉ số trên tập kiểm định

Ba hàm mất mát giảm đơn điệu và **không có dấu hiệu quá khớp**: mất mát hộp bao 1,252 $\rightarrow$ 0,809, mất mát phân lớp 0,833 $\rightarrow$ 0,313, mất mát phân phối 1,154 $\rightarrow$ 0,987; đường validation bám sát đường train suốt 20 epoch. Chỉ số trên tập validation đi lên rồi bão hòa sớm:

mAP@0,5 đạt **0,9684** ngay ở epoch 1 và chỉ nhích lên **0,9830** ở epoch 20, trong khi mAP@0,5:0,95 — chỉ số nhạy với độ khít của hộp — tăng đáng kể hơn, **0,6526 → 0,7688**.

Bảng 4.5. Tiến triển chỉ số trên tập validation theo mốc epoch


Epoch	Mất mát hộp bao	Mất mát phân lớp	Mất mát phân phối	mAP@0.5	mAP@0.5:0.95	Precision	Recall
1	1,1705	0,6858	1,1513	0,9684	0,6526	0,9552	0,9410
2	1,1861	0,5554	1,1307	0,9726	0,6653	0,9700	0,9450
3	1,1647	0,5651	1,1098	0,9723	0,6770	0,9731	0,9449
5	1,1074	0,4977	1,0863	0,9754	0,6950	0,9765	0,9525
10	1,0548	0,4168	1,0686	0,9808	0,7248	0,9850	0,9584
15	0,9420	0,3619	1,0205	0,9824	0,7609	0,9846	0,9686
20	0,9204	0,3331	1,0105	0,9830	0,7688	0,9846	0,9697
Epoch tốt nhất (= 20)	0,9204	0,3331	1,0105	0,9830	0,7688	0,9846	0,9697

4.6. Tầng AI — thiết kế và cài đặt

4.6.1. Tổ chức gói suy luận và ba lớp trừu tượng

Tầng AI là một gói Python độc lập, không phụ thuộc bất kỳ thành phần nào của tầng API; ràng buộc được kiểm chứng tự động (mục 4.2.3) để gói vận hành được trong môi trường notebook, kịch bản đo đạc và nền tảng huấn luyện đám mây.

Kiến trúc dựa trên ba lớp trừu tượng có hợp đồng thống nhất. Lớp phát hiện trả về danh sách vùng biển đã lọc ngưỡng và khử chồng lấn, trong đó danh sách rỗng là kết quả hợp lệ chứ không phải trạng thái lỗi. Lớp nhận dạng trả về chuỗi thô kèm độ tin cậy; việc sửa lỗi ký tự và kiểm tra hợp lệ không thuộc trách nhiệm của lớp này, và chính sự tách biệt đó cho phép định lượng đóng góp của khối hậu xử lý (mục 5.5.2). Lớp chuẩn hoá trả về cả chuỗi không hợp lệ, vì loại bỏ chúng sẽ làm mất đúng các trường hợp mà chương đánh giá cần thống kê. Hợp đồng chung là trả kết quả rỗng thay vì ném ngoại lệ, nhất quán với NFR-R2: không tìm thấy đối tượng và lỗi hệ thống là hai trạng thái khác nhau.



Hình 4.6. Ba lớp trừu tượng và cài đặt tương ứng. Đường ống chỉ giữ tham chiếu tới cột trái, nên thay một cài đặt — ví dụ đổi bộ nhận dạng ký tự — không đụng tới phần còn lại của hệ thống. Đây là bằng chứng cài đặt cho NFR-M5.

4.6.2. Bộ phát hiện

Bộ phát hiện là lớp thích ứng mỏng bao quanh thư viện Ultralytics: không thành phần nào ngoài lớp này tiếp xúc với cấu trúc dữ liệu nội bộ của thư viện. Phiên bản mô hình được ghim tường minh trong định danh mà lớp công bố, để mọi kết quả đo truy được về đúng bộ trọng số và việc nâng cấp thư viện không thay đổi ngầm mô hình đứng sau một kết quả đã công bố. Trọng số nạp ngay khi khởi tạo, nên lỗi thiếu tệp bộc lộ lúc khởi động thay vì lúc phục vụ yêu cầu đầu tiên. Lớp chấp nhận cả tệp trọng số đơn lẻ lẫn thư mục mô hình đã tối ưu cho CPU, do giới hạn ở một dạng sẽ loại bỏ cấu hình suy luận nhanh nhất trên phần cứng mục tiêu. Mọi hộp bao được kẹp về biên ảnh và hộp suy biến bị loại, nên tầng trên không nhận toạ độ ngoài khung.

4.6.3. Bộ nhận dạng ký tự

Bộ nhận dạng tuân theo cùng mô hình lớp thích ứng và cũng ghim phiên bản mô hình tường minh. Các mảnh văn bản được lọc theo tiêu chí hình học thay vì ngưỡng tin cậy, do bước nâng tương phản có thể sinh mảnh nhiễu được đọc thành chuỗi vô nghĩa ở độ tin cậy cao; độ tin cậy của cả chuỗi tổng hợp bằng trung bình có trọng số theo độ dài mảnh, vì trung bình cộng cho phép một mảnh một ký tự che lấp mảnh dài mang danh tính thực của biển số.

Cần lưu ý một giới hạn kỹ thuật ảnh hưởng trực tiếp đến hiệu năng: trên nền tảng mục tiêu, thư viện nhận dạng không cho phép kích hoạt thư viện tăng tốc oneDNN do khiếm khuyết phía thư viện, nên thư viện này bị vô hiệu hoá bằng một hằng số cấu hình có tài liệu kèm theo. Đây là tham số hiệu năng chứ không phải tham số độ chính xác, và giải thích một

phần kết quả NFR-P1 ở mục 5.6: một hướng tăng tốc suy luận CPU thông dụng hiện không khả dụng vì lý do nằm ngoài phạm vi kiểm soát của đề án.

4.6.4. Mô-đun xử lý biển hai dòng

a) Cơ sở của bài toán. Bộ nhận dạng dựa trên kiến trúc CRNN kết hợp hàm mất mát CTC, vốn giả định căn chỉnh đơn điệu giữa cột ảnh và chuỗi ký tự — giả định chỉ đúng với văn bản một dòng. Chồng lên đó, mô-đun nhận dạng chuẩn hoá mọi ảnh về chiều cao cố định 48 điểm ảnh [21]. Biển xe máy Việt Nam 140×190 mm theo QCVN 08:2024/BCA [6] có tỉ lệ khung hình xấp xỉ 1,36; sau chuẩn hoá, mỗi hàng ký tự chỉ còn khoảng 24 điểm ảnh, thấp hơn ngưỡng mà nét chữ còn tách rời. Mức nghiêm trọng đã được định lượng: trên bộ RodoSol-ALPR của Brazil, OpenALPR đạt 94,3% trên biển ô tô một dòng nhưng chỉ 45,7% trên biển xe máy hai dòng [2]. Cần lưu ý cặp số liệu này do trên dữ liệu Brazil, chỉ được trích như dẫn chứng tương đương về định lượng chứ không phải số liệu Việt Nam.

b) Ước lượng số dòng. Số dòng suy từ tỉ lệ chiều rộng trên chiều cao của vùng biển, ngưỡng phân loại 2,5: tỉ lệ nhỏ hơn ngưỡng được xếp vào nhóm hai dòng. Đây là đề xuất của đề án, không phải quy định pháp lý — quy chuẩn chỉ cung cấp ba tỉ lệ vật lý 4,727, 2,000 và 1,357. Ngưỡng được chọn lệch về phía hai dòng vì đường xử lý hai dòng suy giảm êm khi gặp đầu vào một dòng, chiều ngược lại thì không. Dải 2,5–3,0 vẫn là vùng bất định do biển một dòng chụp nghiêng lớn có thể cho tỉ lệ rơi vào khoảng này; định lượng tần suất thuộc Chương 5.

c) Phân tách hai nửa có chồng lấn. Vùng biển được cắt thành hai nửa theo chiều dọc, nửa trên kết thúc tại $5/12$ chiều cao và nửa dưới bắt đầu tại $1/3$, tạo vùng chồng lấn bằng $1/12$ chiều cao biển. Thiết kế xuất phát từ tính bất đối xứng của chi phí sai sót: cắt cụt chân hoặc đỉnh ký tự phá huỷ thông tin không phục hồi được, trong khi lọt vài hàng điểm ảnh của nửa còn lại chỉ được xử lý như nền.

d) Ghép ngang. Hai nửa được ghép theo chiều ngang bằng phép hstack, chiều cao chung lấy bằng giá trị lớn nhất trong ba đại lượng: chiều cao nửa trên, chiều cao nửa dưới và 48 điểm ảnh — đúng bằng chiều cao đầu vào cố định của mô-đun nhận dạng. Nửa trên đặt bên trái để bảo toàn thứ tự đọc. Sau khi ghép, một hàng ký tự duy nhất nhận trọn ngân sách 48 điểm ảnh thay vì hai hàng chia nhau, vô hiệu hoá đúng nguyên nhân đã phân tích ở mục a.

e) Tiền xử lý ảnh biển. Ba bước độc lập, mỗi bước bật tắt riêng để phục vụ thí nghiệm bóc tách đóng góp. **Chuyển thang xám** vì ký tự không mang thông tin phân biệt trong kênh màu. **CLAHE** hệ số 2,0 trên ô 8×8 , vì bề mặt phản quang tạo mảng chói cục bộ mà cân bằng toàn cục không xử lý được [22]. **Lọc song phương** thay cho làm mờ Gauss, vì nó bảo toàn biên — yếu tố quyết định để phân biệt các cặp đồng hình như 8 và B. Ảnh biển do bộ phát hiện sinh ra thường chỉ cao 20–40 điểm ảnh nên được phóng về 64 trước khi đọc.

f) Bước phục hồi dòng trên. Chế độ hồng quan sát được: 29E-015.66 chỉ đọc ra 015.66, vì sau khi ghép, bộ phát hiện văn bản chỉ xác định một vùng chữ và bỏ qua cụm mã tình cùng ký tự sê-ri. Giả thuyết ban đầu — bỏ phép ghép, đọc riêng từng nửa rồi nối chuỗi — đã kiểm

chứng trên 200 biển hai dòng có nhãn và **bị bác bỏ dứt khoát: 64,5% xuống 3,5%, không thắng ở trường hợp nào** (5.5.6). Nguyên nhân nằm ở chính vùng chồng lấn tại mục c: đọc riêng thì dải chồng lấn bị nhận dạng hai lần và sinh ký tự thừa giữa chuỗi, còn trên dải liền mạch vùng lặp nằm giữa hai cụm ký tự nên bị bộ phát hiện văn bản loại bỏ.

Thiết kế cuối cùng vì vậy giữ nguyên chiến lược ghép và chỉ thêm một bước phục hồi có cổng chặt: **chỉ kích hoạt khi đồng thời** vùng biển được phân loại hai dòng, chuỗi sau chuẩn hoá không hợp lệ, và chuỗi thô khác rỗng. Khi đó hệ thống đọc thêm một lượt trên riêng nửa trên, ghép với chuỗi thô rồi chuẩn hoá lại; kết quả mới chỉ được nhận nếu vượt kiểm tra định dạng. **Tính không làm hỏng mang bản chất cấu trúc** — cổng chỉ mở khi kết quả đã không hợp lệ, nên tập bị can thiệp và tập đang đúng là hai tập rời nhau. Đo được **+1,86 và +0,50 điểm** trên hai mẫu độc lập, **0 trường hợp bị làm hỏng**, chi phí 15–21 ms mỗi biển hai dòng.

g) Một giới hạn về phương pháp đo. Kịch bản sinh NFR-A4...A7 ban đầu gọi thẳng bộ nhận dạng và bộ chuẩn hoá thay vì đi qua tầng điều phối, nên logic đặt tại tầng điều phối không được phản ánh trong số công bố. Khắc phục bằng cách tách bước phục hồi thành hàm độc lập cấp mô-đun để cả đường chạy sản phẩm lẫn công cụ đo cùng gọi một cài đặt. Bài học vượt ra ngoài phạm vi biển hai dòng: **một công cụ đo đi tắt qua tầng điều phối sẽ đo một hệ thống khác với hệ thống được bàn giao** — và biện pháp này về sau vẫn chưa đủ, cùng loại sai lệch đã tái diễn (5.5.6).

4.6.5. Bộ luật hậu xử lý theo vị trí

Bộ phát hiện và bộ nhận dạng đều dùng mô hình có sẵn; khối hậu xử lý là thành phần do nhóm thực hiện tự thiết kế và là đóng góp kỹ thuật chính. Khối tuân ba nguyên tắc: thuần khiết về mặt hàm số, không vào/ra và không giữ trạng thái toàn cục khả biến; biểu thức chính quy sinh tự động từ các tập ký tự thay vì viết tay, loại trừ khả năng mẫu lệch khỏi bảng dữ liệu mà nó mã hoá; mọi lớp ký tự là hằng số có tên.

a) Tập mã tình. Khối lưu 81 mã tình đang sử dụng theo phụ lục Thông tư 51/2025/TT-BCA [5], song song tập 8 mã không bao giờ được cấp: 13, 42, 44, 45, 46, 87, 91 và 96. So với biểu thức tổng quát chấp nhận mọi cặp chữ số, ràng buộc này bác bỏ được các chuỗi không tồn tại trên thực tế; lưu tường minh cả tập không sử dụng cho phép kiểm thử khẳng định hai tập phủ đúng dải 11–99.

b) Các lớp ký tự sê-ri. Bốn lớp được định nghĩa: tập 20 chữ cái cho sê-ri ô tô và ký tự thứ nhất của sê-ri xe máy; tập 20 chữ cái cho ký tự thứ hai của sê-ri xe máy; tập 11 chữ cái cho biển nền xanh; và tập mở rộng 21 chữ cái. Hai tập đầu là ảnh gương của nhau tại đúng hai ký tự — tập thứ nhất chứa G không chứa R, tập thứ hai ngược lại — nên 29-AR 123.45 hợp lệ còn 29-AG 123.45 thì không.

Tập mở rộng tồn tại vì một bộ nhận dạng chỉ biết 20 chữ cái **sẽ không bao giờ dự đoán được R**, gây sai sót có hệ thống trên mọi biển xe máy mang ký tự này ở vị trí sê-ri thứ hai — loại sai sót hậu xử lý không cứu được vì thông tin đã mất ở tầng mô hình. Nguyên tắc rút ra: **một mô hình được phép dự đoán ký tự bất hợp lệ tạo sai lầm quan sát được và sửa**

được, còn một mô hình không thể dự đoán ký tự đó về mặt kiến trúc tạo sai lầm không quan sát được.

Nguyên tắc này áp vào đâu, nói cho chính xác. Nó là quyết định thiết kế cho **lượt tinh chỉnh bộ nhận dạng**, hiện thực hoá bằng tệp dict36.txt gồm đủ 0–9 và A–Z. Lượt tinh chỉnh ấy **đã chạy và đã đo bốn cấu hình, nhưng không được đưa vào bản giao hàng** vì ở đúng chế độ production nó thua 7,50 điểm (5.5). **Bản giao hàng chạy model gốc PP-OCRv5** — ocr_rec_model_dir để trống — và charset của model gốc còn rộng hơn 36 ký tự nhiều. Nguyên tắc vì vậy vẫn đúng, thậm chí đúng hơn: khả năng model đọc ra ký tự ngoài tập hợp lệ càng lớn, nên **ràng buộc về 31 ký tự hợp lệ ở tầng hậu xử lý chính là chỗ bắt chúng**. Hằng số OCR_TRAINING_CHARSET giữ trong mã nguồn cùng kiểm thử cạnh giữ, để lượt tinh chỉnh sau không vô tình thu hẹp lại còn 20 chữ.

Tập bị loại trừ toàn hệ thống gồm năm chữ I, J, O, Q, W; chính việc loại I, O, Q làm việc sửa lỗi nhận dạng trở nên khả thi.


c) Mặt nạ vị trí và ký tự đại diện. Ba mặt nạ tương ứng ba độ dài chuỗi hợp lệ, trong đó D bắt buộc chữ số, L bắt buộc chữ cái, ? là ký tự đại diện không áp đặt kiểu:

- chuỗi 8 ký tự (ô tô, sê-ri 5 chữ số): DDLDDDDD
- chuỗi 7 ký tự (ô tô, sê-ri 4 chữ số kiểu cũ): DDLDDDD
- chuỗi 9 ký tự (xe máy): DDL?DDDDD

Ký tự đại diện tại chỉ số 3 của chuỗi 9 ký tự là chi tiết thiết kế then chốt. Hai kiểu biển xe máy cùng 9 ký tự nhưng khác nhau đúng tại vị trí này: kiểu mới dùng sê-ri hai chữ cái, kiểu cũ dùng một chữ cái kết hợp một chữ số và vẫn lưu hành hợp pháp. Nếu tách thành hai mặt nạ riêng thì việc áp kiểu tại chỉ số 3 trở thành bắt buộc, và kiểm chứng bằng chạy thật cho thấy một trong hai kiểu sẽ bị phá huỷ. Chỉ số 3 của chuỗi 9 ký tự là vị trí duy nhất trong toàn hệ thống biển số Việt Nam mà cả chữ cái lẫn chữ số đều hợp lệ.

d) Bảng ánh xạ nhằm lẫn và tính không đối xứng. Hai bảng riêng biệt áp tại vị trí bắt buộc chữ số và vị trí bắt buộc chữ cái, và **phát hiện trung tâm là chúng không đối xứng**: $0 \rightarrow \emptyset$ tại vị trí chữ số là hợp lý, nhưng $\emptyset \rightarrow 0$ thì không bao giờ, vì 0 không thuộc tập sê-ri hợp lệ. Do cả O và Q đều bị loại, ứng viên đồng hình duy nhất còn lại ở vị trí chữ cái là D, nên chiều đúng là $\emptyset \rightarrow D$. Ký tự R không được ánh xạ trong mọi trường hợp vì nó hợp lệ ở vị trí sê-ri thứ hai của biển xe máy (2.2.1). Nguyên tắc an toàn: ký tự không có mục trong bảng thì giữ nguyên. Hai bảng này **suy từ hình dạng ký tự chứ không từ đo đạc** — thay chúng bằng bảng trích từ ma trận nhằm lẫn đo được thuộc Chương 5.

e) Thuật toán chuẩn hoá.



Hình 4.7. Thuật toán chuẩn hoá chuỗi biến số theo bộ luật ràng buộc vị trí

Thuật toán tuân ba nguyên tắc. Biểu thức chính quy được thử trước khi thực hiện bất kỳ chỉnh sửa nào, bởi với chuỗi vốn đã hợp lệ thì mọi can thiệp chỉ có thể làm sai đi. Không chuỗi nào bị loại bỏ: chuỗi không sửa được vẫn trả về kèm cờ không hợp lệ và vẫn được lưu. Chuỗi thô được giữ song song với chuỗi đã sửa. Kết quả là một cấu trúc bất biến chứa chuỗi thô, chuỗi cuối, cờ hợp lệ, kết quả phân loại họ biến và danh sách vị trí ký tự đã chỉnh sửa — dấu vết kiểm toán mà chương đánh giá dựa vào để định lượng đóng góp của khối.

f) Xử lý nhập bằng số dòng. Số dòng bằng một chứng minh chuỗi thuộc biển ô tô, do biển xe máy luôn hai dòng; ngược lại, số dòng bằng hai không chứng minh gì vì biển ô tô loại ngắn cũng hai dòng. Trong trường hợp thứ hai, hệ thống giữ cờ nhập bằng và trả về tập ứng viên thay vì suy đoán kết luận mà dữ liệu đầu vào không chứa. Thứ tự kiểm tra các mẫu sắp xếp theo mức đặc trưng giảm dần, trong đó biển quân đội đặt cuối vì đây là trường hợp nhận dạng nhằm loại trừ: chuỗi khớp mẫu biển quân đội không bao giờ được báo cáo là biển dân sự hợp lệ.

4.6.6. Tổ hợp đường ống bằng tiêm phụ thuộc

Đường ống suy luận là đối tượng tổ hợp: nó không sở hữu mô hình mà chỉ điều phối thứ tự giai đoạn, cắt vùng ảnh, đo thời gian từng giai đoạn và cô lập lỗi ở mức từng biến số; do không chứa logic học sâu, đường ống kiểm thử được đầy đủ bằng thành phần giả lập. Thời gian của cả năm giai đoạn luôn được ghi nhận, giai đoạn không thực thi báo giá trị 0 thay vì vắng mặt — cơ sở cho phép phân rã ngân sách độ trễ ở mục 5.6.2, theo đó khối nhận dạng chiếm 64,3% và khối phát hiện 34,0% tổng thời gian suy luận thuần.

Chính sách xử lý lỗi phân tầng theo mức ảnh hưởng: ảnh không chứa biến số trả kết quả rỗng; lỗi nhận dạng trên một biển chỉ vô hiệu hoá biển đó, các biển còn lại vẫn được xử lý; lỗi ở bộ phát hiện làm dừng toàn bộ yêu cầu; lỗi chuẩn hoá giữ nguyên kết quả thô. Thao tác cắt ảnh kẹp toạ độ **thêm một lần nữa** dù lớp phát hiện đã bảo đảm, vì cắt ảnh là nơi duy nhất mà sai lệch một đơn vị tạo mảng rỗng không kèm cảnh báo; ảnh cắt được tạo dưới dạng bản sao thay vì khung nhìn, tránh giữ toàn bộ khung hình gốc trong bộ nhớ khi xử lý video.

4.6.7. Nhận dạng họ biến và màu nền

a) Vấn đề đặt ra. Hệ thống ban đầu tính ra họ biến và chuỗi hiển thị có dấu phân cách nhưng loại bỏ chúng trước khi ghi vào cơ sở dữ liệu, nên một biển quân đội được nhận dạng chính xác ở độ tin cậy 0,999 vẫn bị hiển thị là sai định dạng — phát biểu không chính xác,

do biển quân đội là biển hợp lệ nằm ngoài hệ dân sự (mục 4.6.5f). Hướng khắc phục gồm hai phần: lưu giữ thông tin đã tính (mục 4.7.2), và bổ sung nguồn bằng chứng mà chuỗi ký tự về nguyên tắc không thể mang, đó là màu nền.

b) Cơ sở của bằng chứng bổ trợ. Hai nguồn bằng chứng bù trừ cho nhau. Theo Thông tư 79/2024/TT-BCA, biển vàng của xe kinh doanh vận tải mang đúng cùng cấu trúc ký tự với biển trắng của xe cá nhân nên không biểu thức chính quy nào phân biệt được; ngược lại, biển ngoại giao có nền trắng giống biển cá nhân nên riêng màu nền cũng không đủ. Chỉ cặp thuộc tính gồm chuỗi ký tự và màu nền mới định danh được loại phương tiện.

c) Thiết kế bộ phân loại màu. Bộ phân loại chuyển ảnh sang HSV, thống kê tỉ lệ điểm ảnh theo từng dải màu rồi chọn dải chiếm ưu thế, với ba quyết định đáng nêu. **Chỉ lấy mẫu vùng trung tâm**, biên thu vào 18% mỗi phía, vì khung phát hiện hiếm khi ôm sát mép biển và màu thân xe phía sau có thể lấn át. **Không loại điểm ảnh thuộc ký tự:** ký tự chiếm thiểu số diện tích, và thêm một bước phân đoạn ký tự là đưa vào khâu kém ổn định hơn chính khâu nó bảo vệ. **Trả không xác định khi dải ưu thế dưới 30%** — kết luận sai về màu tương đương khẳng định một loại phương tiện không chứng minh được, còn thừa nhận không xác định chỉ là ghi nhận một giới hạn.

d) Hợp nhất chuỗi ký tự và màu nền. Với chuỗi như 80A12345, bốn họ biển đều hợp lệ và bộ chuẩn hoá mặc định chọn họ phổ biến nhất — đúng với đa số nhưng sai ngầm với xe cơ quan nhà nước mang biển nền xanh. Cơ chế hợp nhất cho phép màu nền **nâng cấp một ứng viên mà bộ luật ký tự đã coi là hợp lý**, và ràng buộc an toàn quan trọng hơn chính tác dụng ấy: nếu phán quyết ban đầu không nằm trong tập ứng viên thì giữ nguyên, nên màu nền **không thể tạo ra họ biển mà bộ luật ký tự đã bác bỏ**. Khi họ biển ưu tiên có cả biến thể ô tô và xe máy thì phân định theo số dòng; mâu thuẫn cả hai thì giữ phán quyết ban đầu — đại lượng đo từ hình học ưu tiên hơn đại lượng suy từ thống kê điểm ảnh. Chỉ màu xanh nằm trong bảng ưu tiên vì đó là màu duy nhất chuỗi ký tự hoàn toàn không phân biệt được; màu vàng không đổi họ biển mà chỉ đổi mục đích sử dụng nên lưu thành trường độc lập.

e) Độ chính xác đo được. Bộ phân loại được đánh giá trên bộ dữ liệu ảnh biển cắt sẵn có nhãn màu do người gán và chưa từng được hiệu chỉnh theo bộ này — phép đo vì vậy nằm ngoài dữ liệu hiệu chỉnh.

Bảng 4.7. Độ chính xác bộ nhận màu nền trên bộ dữ liệu ngoài hiệu chỉnh

Lớp nhãn người gán	Số ảnh	Đúng	Độ chính xác
Biển vàng	694	684	98,56%
Biển trắng	808	787	97,40%
Biển xanh	63	61	96,83%
Tổng	1.565	1.532	97,89%

Ba giới hạn cần nêu kèm kết quả trên.

Bảng 4.8. Ba giới hạn của phép đo bộ nhận màu nền

#	Giới hạn	Chi tiết
1	542 ảnh bị loại khỏi phép đo	Toàn bộ lớp không xác định, cùng các ảnh chụp ban đêm hoặc hồng ngoại mà chính người gán nhãn cũng không xác định được màu
2	Dạng lỗi chủ đạo: biển trắng bị xếp thành biển xanh	21 trên 33 trường hợp sai, do một số điểm ảnh ám lạnh vượt ngưỡng bão hoà
3	Phạm vi phép đo hẹp hơn phạm vi mô-đun	Bộ dữ liệu không chứa biển đỏ và biển ngoại giao nên hai nhánh này chưa có số liệu đánh giá — ghi thành hạn chế số 10 ở mục 6.2

Cần lưu ý thêm rằng toàn bộ ảnh của bộ dữ liệu này đã bị biến đổi tỉ lệ về khung vuông trước khi công bố, nên bộ không dùng được để đánh giá độ chính xác nhận dạng ký tự — phép biến đổi phá huỷ tỉ lệ khung hình mà thuật toán ước lượng số dòng dựa vào. Màu nền không chịu ảnh hưởng, do đó bộ dữ liệu chỉ được dùng cho đúng câu hỏi về màu sắc.

4.6.8. Tối ưu tăng chạy cho suy luận trên CPU

Ba can thiệp dưới đây **không đổi trọng số, không đổi phép tính**, chỉ đổi cách phép tính được lập lịch trên CPU. Vì vậy chúng cải thiện độ trễ mà **không đụng tới bất kỳ chỉ số độ chính xác nào** — điều này đã được kiểm chứng bằng số ở mục 5.6.1.

Một — tắt ghi số đồ thị đạo hàm. Lệnh dự đoán của bộ phát hiện được bọc trong `torch.inference_mode()`. Ở chế độ mặc định, PyTorch vẫn dựng cấu trúc dữ liệu phục vụ lan truyền ngược cho mọi phép toán, kể cả khi không ai gọi `backward()`. Với suy luận thuần đó là chi phí trả không công. Lệnh gọi được bọc trong `try/except` và lùi về ngữ cảnh rộng nếu không nhập được `torch`, để tăng AI vẫn chạy khi thiếu thư viện.

Hai — ghim số luồng thay vì để thư viện tự đoán. Torch và OpenCV mặc định lấy toàn bộ số nhân sẵn có. Trên máy 14 nhân / 20 luồng, hai thư viện cùng làm vậy trong một tiến trình sẽ **tranh khoá lẫn nhau**, và tổng thời gian tăng chứ không giảm. Số luồng nay được ghim ở `min(8, số_nhân)` cho phép toán trong một toán tử, và `min(4, số_nhân)` cho phép toán giữa các toán tử.

Ba — truyền số luồng xuống bộ nhận dạng. PaddleOCR nhận `cpu_threads` từ biến môi trường `OMP_NUM_THREADS`. Trước đó tham số này không được truyền, và trong một số cấu hình OpenBLAS điều đó gây lỗi nghiêm trọng làm sập tiến trình chứ không chỉ chậm.

Kết quả đo ở 5.6.1: p95 giảm từ 1.143,10 xuống **509,76 ms**, trung vị từ 405,77 xuống **150,07 ms**, và phần OCR trong ngân sách độ trễ giảm từ 108,28 xuống **89,16 ms** mỗi biển.

4.7. Máy chủ và cơ sở dữ liệu

4.7.1. Kiến trúc phân tầng và tầng nghiệp vụ

Máy chủ tổ chức thành năm tầng với luồng phụ thuộc một chiều nghiêm ngặt: tầng lõi được mọi tầng khác dùng nhưng không phụ thuộc tầng nào. Kiến trúc và các thành phần cụ thể của từng tầng đã trình bày ở **Hình 4.2**; mục này nêu ba quy tắc riêng khiến tầng nghiệp vụ tách biệt được khỏi hai tầng kề nó.

Bảng 4.9. Ba quy tắc giữ cho tầng nghiệp vụ tách biệt

Quy tắc	Nội dung	Hệ quả
Tầng định tuyến không chứa truy vấn	Mọi truy cập dữ liệu đi qua tầng kho dữ liệu	Một thay đổi lược đồ có bán kính ảnh hưởng gói trong một mô-đun , không lan ra tầng định tuyến
Tầng kho không tự xác nhận giao dịch	Chỉ đẩy thay đổi xuống phiên làm việc; việc xác nhận thuộc về tầng gọi	Lưu một lượt nhận dạng cùng toàn bộ biến số thuộc lượt đó là một thao tác logic duy nhất — xác nhận giữa chừng sẽ để lại bản ghi nửa vời
Mỗi ngoại lệ mang hai mô tả	Thông điệp tiếng Việt kèm hành động khắc phục đi vào thân phản hồi HTTP; mô tả kỹ thuật chỉ đi vào nhật ký	Cây ngoại lệ ánh xạ thẳng sang mã trạng thái HTTP, kèm bộ xử lý bắt tất cả để ngoại lệ ngoài dự kiến không làm lộ vết ngăn xếp ra người dùng (NFR-S4)

Phần lớn sự cố gặp trong quá trình cài đặt nằm ở **ranh giới giữa mã nguồn và môi trường thực thi** — nguồn cấu hình, tầng lưu trữ, bảng mã đầu ra — và đều vượt qua được kiểm thử đơn vị. Đây là lập luận thực nghiệm cho việc bộ kiểm thử phải có kiểm thử tích hợp chạy trên đường dẫn thật, không chỉ kiểm thử đơn vị với thành phần giả lập.

4.7.2. Hợp nhất các biến thể đọc sai trong chuỗi khung hình video

Một xe đi qua khung hình xuất hiện ở hàng chục khung liên tiếp. Gom kết quả theo chuỗi ký tự là bước đầu tiên và chưa đủ, vì **cùng một biến ở hai khung liền nhau vẫn có thể cho hai chuỗi khác nhau**: khối nhận dạng không tất định ở mức một ký tự. Hệ quả là một video ngắn sinh ra nhiều dòng kết quả cho cùng một chiếc xe.

Tầng nghiệp vụ vì vậy có một lượt hợp nhất thứ hai. Hai chuỗi được coi là cùng một biến vật lý khi thoả **đồng thời**:

Điều kiện	Ngưỡng	Vì sao cần cả hai
Gần nhau về chuỗi	khoảng cách Levenshtein ≤ 2	Chỉ điều kiện này thì hai biến thật sự khác nhau cũng lọt
Gần nhau về thời gian	không quá 48 khung	Chỉ điều kiện này thì hai xe khác nhau đi liền nhau cũng lọt

Riêng ở khoảng cách bằng 2, hai điều kiện trên vẫn chưa đủ chặt, nên mức đó phải qua thêm một **rào ngữ nghĩa dựa trên cấu trúc biển số Việt Nam**: hai chuỗi phải cùng **mã tỉnh hai chữ số**, và **hoặc** cùng chữ cái sê-ri **hoặc** cùng ba chữ số cuối. Rào này khai thác đúng đặc điểm đã phân tích ở 4.6.5 — biển số Việt Nam không phải chuỗi tùy ý mà có cấu trúc theo vị trí.

Bản nào được giữ lại là quyết định về bằng chứng, không phải về thứ tự đến. Thứ tự ưu tiên: đúng quy chuẩn định dạng trước, rồi **số khung đã bỏ phiếu** cho cách đọc đó, cuối cùng mới tới độ tin cậy của khối nhận dạng. Đặt độ tin cậy xuống cuối là có lý do đo được: ở mức sai khác một ký tự, một lần đọc sai vẫn thường mang điểm tin cậy cao — mục 5.6.5 có ca cụ thể trong đó bản sai đạt 0,994 còn bản đúng 0,996.

4.7.3. Thiết kế cơ sở dữ liệu

a) Lược đồ. Cơ sở dữ liệu gồm hai bảng có quan hệ một–nhiều: bảng tác vụ ghi nhận mỗi lần sử dụng hệ thống, và bảng lịch sử ghi nhận mỗi biển số được phát hiện. Việc tách thành hai bảng là điều kiện để thống kê đếm đúng, bởi *lượt nhận dạng* và *biển số phát hiện được* là hai đại lượng khác nhau: một ảnh chứa ba phương tiện tạo ra một lượt và ba bản ghi. Gộp hai khái niệm sẽ làm số lượt sử dụng bị đánh giá cao hơn thực tế đúng bằng số biển số trung bình trên mỗi ảnh.

Bảng 4.10. Lược đồ cơ sở dữ liệu — hai bảng, quan hệ một–nhiều

Bảng	Cột	Kiểu	Ghi chú
detection_job (11 cột)	id	VARCHAR(36)	Khoá chính, UUID
	input_type · status	VARCHAR(16)	image video webcam; pending processing completed failed cancelled
	progress	FLOAT	0,0 – 1,0
	source_path · output_path	VARCHAR(512)	Cho phép rỗng
	error_message	TEXT	Chỉ phía máy chủ, không trả ra API
	total_frames · processed_frames	INTEGER	Dùng cho tác vụ video
detection_history (23 cột)	created_at · completed_at	DATETIME	
	id	INTEGER	Khoá chính
	plate_number · raw_ocr_text	VARCHAR(32)	Lưu song song chuỗi đã chuẩn hoá và chuỗi thô
	confidence · ocr_confidence	FLOAT	Của bộ phát hiện và của bộ

Bảng	Cột	Kiểu	Ghi chú
			nhận dạng — hai đại lượng khác nhau
	image_path · plate_image_path	VARCHAR(512)	Ảnh gốc và vùng biển đã cắt
	bbox_x · bbox_y · bbox_w · bbox_h	INTEGER	Hộp giới hạn
	is_valid_format	BOOLEAN	Có khớp quy chuẩn Việt Nam không
	plate_line_count · upper_char_count	INTEGER	1 hoặc 2 dòng; số ký tự dòng trên (3 hoặc 4)
	plate_kind · plate_color · plate_color_confidence	VARCHAR(16) · FLOAT	Họ biển và màu nền, cho phép rỗng
	video_time_seconds	FLOAT	Mốc thời gian trong video, rỗng với ảnh tĩnh
	processing_time · detected_time · created_at	FLOAT · DATETIME	
	source_job_id	VARCHAR(36)	Khoá ngoại trỏ detection_job.id

Ba cột đáng chú ý vì chúng là **hệ quả trực tiếp của các quyết định đã nêu**: raw_ocr_text cho phép đo đóng góp thuần của khối hậu xử lý (mục 5.5.2); source_job_id gom nhiều biển của cùng một lần tải lên về một nhóm, nếu thiếu thì thống kê đếm sai; và upper_char_count lưu *bằng chứng* để suy ra cách trình bày biển hai dòng lúc đọc, thay vì đoán từ chuỗi phẳng vốn nhập nhằng.

b) Hai quyết định thiết kế dữ liệu đáng chú ý. Thứ nhất, chuỗi ký tự thô do bộ nhận dạng trả về và chuỗi đã qua chuẩn hoá được lưu song song trong hai cột riêng biệt. Đây là điều kiện cần để định lượng đóng góp của khối hậu xử lý: hiệu số giữa độ chính xác tính trên hai cột này chính là chỉ số NFR-A6 trừ NFR-A5 báo cáo ở mục 5.5.2. Thứ hai, hệ thống lưu số ký tự thuộc dòng trên của biển hai dòng, nhằm giải quyết một trường hợp nhập nhằng về nguyên tắc: chuỗi tám ký tự của biển hai dòng có thể được nhóm theo hai cách đều hợp lệ, và ranh giới giữa hai dòng — thông tin duy nhất phân định được — bị chính bước ghép ngang loại bỏ. Giá trị này thu được không tốn thêm chi phí tính toán vì bộ nhận dạng trả về một mảnh kết quả cho mỗi nửa ảnh.

4.7.4. Giao diện lập trình

Hệ thống cung cấp giao diện theo phong cách REST với tài liệu đặc tả sinh tự động. Các điểm cuối nghiệp vụ nằm dưới một tiền tố chung, riêng điểm cuối kiểm tra tình trạng đặt ở gốc để hệ thống giám sát và cơ chế kiểm tra sức khoẻ của môi trường container không phụ thuộc vào phiên bản giao diện. Tổng cộng có mười thao tác HTTP trên chín đường dẫn; bảng đặc tả đầy đủ từng điểm cuối được trình bày ở **Phụ lục F.1**.

Bốn quyết định thiết kế đáng ghi nhận. Yêu cầu xử lý video trả về mã trạng thái chấp nhận thay vì mã thành công, do một video 60 giây cần khoảng 200 giây xử lý trên CPU và không client nào chờ được; mã chấp nhận phản ánh đúng ngữ nghĩa "đã tiếp nhận, đang xử lý". Trường hợp ảnh không chứa biển số trả về mã thành công kèm danh sách rỗng thay vì mã lỗi, vì kết quả nhận dạng vẫn tồn tại và là tập rỗng (NFR-R2); trả về mã lỗi sẽ loại toàn bộ trường hợp âm khỏi thống kê. Chức năng tìm kiếm đối chiếu đồng thời chuỗi đã chuẩn hoá và chuỗi thô, để người dùng nhớ dạng nào cũng tra được. Cuối cùng, hai chỉ số thống kê về số lượt và số biển số được trả về tách biệt, kèm mô tả tường minh trong tài liệu đặc tả nhằm ngăn việc gộp nhầm hai đại lượng đã phân tích tại mục 4.7.2a.

4.8. Giao diện người dùng

4.8.1. Cấu trúc và các màn hình

Giao diện là ứng dụng một trang xây dựng trên React và TypeScript, gồm bốn màn hình: nhận dạng ảnh, nhận dạng video, quét trực tiếp qua webcam và tra cứu lịch sử. Điều hướng được thiết kế phẳng có chủ ý — cả ba màn hình truy cập trực tiếp từ thanh điều hướng — còn chi tiết bản ghi và hộp xác nhận xoá hiển thị dưới dạng hộp thoại chồng lên trang lịch sử để không làm mất ngữ cảnh bộ lọc đang áp dụng.

Toàn bộ giao tiếp với máy chủ tập trung tại một tầng gọi API duy nhất, nơi duy nhất trong giao diện có hiểu biết về thư viện HTTP và mã trạng thái; các thành phần hiển thị chỉ nhận dữ liệu đã có kiểu hoặc đối tượng lỗi đã chuẩn hoá. Không địa chỉ máy chủ nào được viết cứng: gốc địa chỉ đọc từ biến môi trường tại thời điểm biên dịch và mặc định là rỗng, tương ứng cấu hình cùng nguồn gốc.

Hai màn hình sau cùng đáng nói riêng, vì cả hai đều sinh ra từ ràng buộc của tầng dưới. Giao diện có **chế độ quét trực tiếp qua webcam** và **hàng đợi tải lên nhiều ảnh**, cả hai đều sinh ra từ ràng buộc của tầng dưới chứ không phải từ mong muốn thêm tính năng.

Quét trực tiếp qua webcam. Trình duyệt lấy khung hình từ camera và gửi từng khung tới `POST /api/detect/frame`. Điểm thiết kế đáng nêu là **vòng lặp một khe**: tại mỗi thời điểm chỉ có đúng một khung đang được gửi đi, và mọi khung camera sinh ra trong lúc chờ đều bị **bỏ thẳng** chứ không xếp hàng. Lý do là một hàng đợi không giới hạn sẽ khiến độ trễ hiển thị tăng dần không giới hạn khi tốc độ camera vượt tốc độ xử lý — người dùng sẽ thấy khung hình cũ dần so với thực tế. Chấp nhận bỏ khung giữ cho kết quả hiển thị luôn thuộc về hiện tại. Phép đo ở 5.6.4 cho thấy tỷ lệ bỏ là đáng kể và **đó là hành vi đúng**: trong 60 giây, camera ảo 30 khung/giây chào 1.801 khung, hệ thống xử lý 338 và bỏ 1.463.

Hàng đợi tải lên nhiều ảnh. Người dùng chọn nhiều tệp một lần; giao diện xếp chúng thành một dải xem trước và xử lý tuần tự, hiển thị kết quả ngay khi từng ảnh xong thay vì chờ cả lô. Xử lý tuần tự chứ không song song là quyết định có chủ đích: máy chủ chạy suy luận trên CPU đã ghim số luồng (4.6.8), nên gửi song song chỉ làm các yêu cầu tranh nhau cùng một tài nguyên và kéo dài tổng thời gian.

Cần lưu ý rằng thiết kế ban đầu có năm màn hình. Màn hình tổng quan đã được đưa ra khỏi phạm vi trong hai đợt thu gọn giao diện, kéo theo bốn yêu cầu chức năng chuyển sang mức không thực hiện — trong đó có một yêu cầu ở mức bắt buộc, được nêu rõ tại mục 6.2. Các điểm cuối tương ứng ở phía máy chủ vẫn hoạt động và vẫn có kiểm thử tích hợp; điều bị loại bỏ là hàm gọi phía giao diện, không phải bản thân điểm cuối.

4.8.2. Nguyên tắc trải nghiệm người dùng

Mọi thành phần hiển thị dữ liệu đều cài đặt đủ bốn trạng thái: đang tải, có dữ liệu, rỗng và lỗi. Thiếu trạng thái đang tải khiến giao diện có biểu hiện như bị treo và người dùng thao tác lại, làm tăng tải không cần thiết; thiếu trạng thái rỗng khiến màn hình trống không phân biệt được với lỗi hệ thống. Trạng thái rỗng xuất hiện với ba ý nghĩa cần ba thông điệp khác nhau: chưa có lượt nhận dạng nào, bộ lọc không khớp bản ghi nào, và ảnh không chứa biển số. Ý nghĩa thứ ba là biểu hiện ở tầng giao diện của cùng một quyết định đã áp dụng tại tầng giao diện lập trình và tầng suy luận: không tìm thấy đối tượng không phải là lỗi.

Thông báo lỗi được viết bằng tiếng Việt theo cấu trúc ba phần — hiện tượng, nguyên nhân và hành động khắc phục (NFR-U3) — trong khi chi tiết kỹ thuật được chuyển hướng vào nhật ký phía máy chủ thay vì bị loại bỏ. Giao diện hiển thị đồng thời chuỗi thô và chuỗi đã chuẩn hoá khi hai chuỗi khác nhau, qua đó biến một cột dữ liệu phục vụ nghiên cứu thành bằng chứng quan sát được ngay trong quá trình trình diễn; do chỉ hiển thị khi có thay đổi, giao diện không bị rối bởi phần lớn trường hợp mà khối hậu xử lý không can thiệp.

Một nguyên tắc thiết kế đáng ghi nhận thuộc về client nhận dạng thời gian thực. Do tốc độ suy luận trên CPU chỉ đạt khoảng 5 khung hình mỗi giây, một vòng lặp gửi yêu cầu theo chu kỳ cố định sẽ khởi tạo yêu cầu mới trước khi yêu cầu trước đó hoàn tất, khiến hàng đợi tăng không giới hạn. Giải pháp là duy trì đúng một yêu cầu đang xử lý tại mỗi thời điểm; khung hình đến trong lúc kênh bận sẽ bị bỏ qua thay vì xếp hàng, do khung hình kế tiếp luôn cập nhật hơn khung hình bị bỏ. Màn hình tương ứng đã được đưa ra khỏi phạm vi, nhưng nguyên tắc này vẫn là khuyến nghị bắt buộc cho mọi client sử dụng điểm cuối nhận dạng theo khung hình.

4.9. Triển khai bằng Docker

Đóng gói phục vụ NFR-C1: môi trường chạy tái lập được, không phụ thuộc máy cá nhân. Ảnh Docker của máy chủ được dựng hai giai đoạn, cài **hai tệp khai báo phụ thuộc thành hai lớp riêng** để thay đổi một tầng không làm mất bộ đệm tầng kia (hệ quả trực tiếp của ràng buộc môi trường ở mục 4.3.1), chạy dưới người dùng không đặc quyền, giới hạn tường minh số luồng tính toán để hai container không cạnh tranh nhân CPU đến mức cùng chậm, và đặt thời gian chờ khởi động của cơ chế kiểm tra sức khoẻ đủ dài cho việc nạp trọng số. Ảnh Docker của giao diện được dựng rồi phục vụ tĩnh qua máy chủ web nhẹ — ảnh chạy không chứa Node hay mã nguồn. **Trọng số mô hình không nằm trong ảnh Docker** mà gắn từ ngoài, cùng một volume riêng cho bộ đệm mô hình PaddleOCR — không có volume này thì mỗi lần down && up phải tải lại vài trăm MB và không có mạng thì container không khởi động được. Bảng biến môi trường ở **Phụ lục F.2. Trạng thái kiểm chứng**: docker compose config hợp lệ; đo hiệu năng trong container thuộc Chương 5.

4.10. Những chỗ cài đặt lệch khỏi thiết kế, và lý do

Nguyên tắc: **mọi điểm lệch đều được nêu, kể cả những điểm chưa được giải quyết.**

Bảng 4.11. Tổng hợp chín điểm lệch giữa thiết kế và cài đặt

#	Thiết kế	Cài đặt thực tế	Loại lệch	Trạng thái
1	StubPipeline là phương án lùi khi thiếu mô hình	UnavailablePipeline là phương án lùi; stub chỉ chạy khi opt-in tường minh	Cải tiến so với thiết kế	Đã giải quyết
2	Một môi trường ảo Python	Ba môi trường ảo tách biệt	Bắt buộc bởi xung đột phụ thuộc	Đã giải quyết
3	FR-2.6: có nút huỷ tác vụ video	Đưa ra khỏi phạm vi; nút đã gỡ khỏi giao diện	Thu hẹp phạm vi	— Không áp dụng
4	Mô hình chính thức imgsz=640 trên phép chia tập sạch	Đã có models/best.pt (imgsz=640, phép chia tập v3, mAP@0.5 0,9829)	Đúng thiết kế	✅ Đã giải quyết
5	NFR-P1: độ trễ E2E p95 ≤ 800 ms	Đo được 509,76 ms sau đợt tối ưu tăng suy luận (4.4); từng là 1.143,10 ms	✅ Đạt mục tiêu	✅ Đã khép
6	FR-2.5: tác vụ video xuất video đã chú thích	Đưa ra khỏi phạm vi	Thu hẹp phạm vi	— Không áp dụng
7	Bật oneDNN để tăng tốc CPU	Buộc phải tắt do lỗi thư viện	Bắt buộc bởi lỗi thượng nguồn	Đã ghi nhận
8	Khử rò rỉ bằng phash	Còn rò rỉ tồn dư không khử được bằng phash	Giới hạn phương pháp	Đã ghi nhận
9	Bộ đo độ chính xác OCR đo hệ thống đang giao	Bộ đo gọi thẳng recognizer + normalizer, bỏ qua tầng điều phối	Lỗi phương pháp đo	✅ Đã phát hiện và sửa

CHƯƠNG 5. THỰC NGHIỆM VÀ ĐÁNH GIÁ

Chương 5 trình bày kết quả đánh giá hệ thống sau khi xây dựng. Chương này tập trung trả lời hai câu hỏi trọng tâm: hệ thống **đáp ứng yêu cầu kỹ thuật ở mức độ nào**, và **độ tin cậy của các số liệu đo lường**; do đó, mọi số liệu đều được trình bày kèm theo ngữ cảnh thực nghiệm cụ thể.

5.1. Mục tiêu và phương pháp đánh giá

5.1.1. Các câu hỏi nghiên cứu mà chương này trả lời


Chương này trả lời sáu câu hỏi từ đặc tả phi chức năng: **RQ1** — YOLO11n có đạt chỉ tiêu phát hiện biển số Việt Nam không (5.4; NFR-A1...A3)? **RQ2** — độ chính xác khác nhau thế nào giữa biển một dòng và hai dòng (NFR-A8; 5.4.2, 5.5.3)? **RQ3** — hậu xử lý đóng góp bao nhiêu vào độ chính xác chuỗi (NFR-A5 ↔ A6; 5.5.2)? **RQ4** — hệ thống có đạt chỉ tiêu độ trễ trên CPU không và điểm nghẽn ở đâu (5.6; NFR-P1...P7)? **RQ5** — bảng luật sửa ký tự có khớp các cặp nhầm lẫn đo được không (5.5.4)? **RQ6** — yếu tố nào đe dọa tính hợp lệ của kết quả (5.9.1)? RQ3 và RQ5 lần lượt lượng hoá đóng góp của hậu xử lý và thay giả định bằng dữ liệu đo được.

5.1.2. Hai nguyên tắc trình bày bắt buộc

Một — mọi số hiệu năng phải kèm cấu hình phần cứng: đề án suy luận hoàn toàn trên CPU nên so với các con số FPS đo trên GPU là không hợp lệ nếu không ghi rõ; cấu hình ở 5.2 là điều kiện diễn giải cho toàn mục 5.6. **Hai** — mọi số độ chính xác phải kèm tên tập dữ liệu và số mẫu, vì độ chính xác là thuộc tính của cặp (mô hình, tập đánh giá); hệ quả: NFR-A4...A7 chỉ đo được trên tập con có nhãn chuỗi, nhỏ hơn nhiều tập test phát hiện, mẫu số đó không được giấu. **Ký hiệu:**  đạt mục tiêu ·  chỉ đạt ngưỡng tối thiểu ·  không đạt ·  chưa đo ·  không áp dụng.

Ghi chú về cách trích dẫn. Cặp số **94,3%** (biển một dòng) ↔ **45,7%** (biển hai dòng), chênh **48,6 điểm phần trăm**, đo trên bộ dữ liệu **RodoSol-ALPR của Brazil** [2]. Đây **không phải** số liệu Việt Nam; mỗi lần dẫn, tên bộ dữ liệu và quốc gia phải xuất hiện **ngay trong câu**, và nó chỉ dùng như *analogue định lượng* về độ khó tương đối của biển hai dòng, không bao giờ như mốc chuẩn phải vượt.

5.1.3. Giao thức đo



Hình 5.1. Giao thức đo và ràng buộc phụ thuộc giữa các bước đánh giá.

Không bước đo nào chạy trước khi trọng số được đóng băng; tập test không được chạm vào trong huấn luyện lẫn chọn epoch — chọn epoch chỉ dựa vào validation. Ba quy ước: **kích thước lô = 1 khi đo độ trễ** (riêng mAP dùng lô lớn hơn vì không phụ thuộc kích thước lô); **bỏ 3 lượt khởi động nóng**; **báo cáo p50/p95/p99, không báo cáo trung bình**, vì trung bình che đuôi phân bố còn NFR-P1 phát biểu ở p95.

Bảng 5.1. Các lượt đo độ chính xác nhận dạng, và lý do phải đo lại

Lượt	Lượt này thêm gì so với lượt trước	A4	A6	Vì sao con số không còn dùng
1	Lượt đo đầu tiên	0,8734	0,6555	Ảnh trong bộ dữ liệu được xuất ra ở khung vuông , làm biến số bị kéo méo; hệ thống lúc đó chưa trả lại tỷ lệ đúng trước khi đọc
2	Trả lại tỷ lệ đúng cho ảnh biến trước khi đọc, và đọc lại dòng trên của biến hai dòng khi lần đầu thất bại (5.5.6)	0,8848	0,6730	Bốn đợt sửa độ chính xác sau đó làm mọi con số cũ mô tả một hệ thống không còn tồn tại
3	Bốn đợt sửa độ chính xác ở khối đọc ký tự	0,9416	0,7437	Công cụ đo bị sai. Nó tự dừng lại các bước xử lý thay vì gọi đúng đường mà hệ thống thật chạy, nên bỏ sót hẳn bước đọc lại khi thất bại — tức là đo một hệ thống <i>thiếu bước</i> so với bản giao hàng
4	Cho công cụ đo chạy đúng đường xử lý của bản giao hàng (5.5.7)	0,9454	0,7512	Bảng sửa ký tự đọc nhằm vẫn dựa trên hình dạng chữ giống nhau , chưa dùng số liệu nhằm lẫn thật đã đo được
5	Bảng sửa ký tự dựng từ số liệu nhằm lẫn đo được (5.5.4)	0,9483	0,7701	— đây là cấu hình bản giao hàng; mọi con số trong chương này thuộc lượt 5
X	(nhánh đối chứng) Thử dùng bộ đọc ký tự đã huấn luyện thêm trên biến số Việt Nam	0,9252	0,6762	Kém hơn bản gốc khi chạy đầy đủ như hệ thống thật; đã bác bỏ, không đưa vào bản giao hàng (4.5.3)

Ba lý do phải đo lại, khác hẳn nhau về tính chất. (a) **Hệ thống thật sự thay đổi** — lượt 2, 3, 5: mỗi lần cải tiến một khâu là mọi con số cũ mô tả một hệ thống không còn tồn tại, nên *không* đo lại mới là sai. (b) **Công cụ đo bị sai** — lượt 4, và đây là lý do đáng lo nhất: công cụ tự dừng lại các bước xử lý thay vì gọi đúng đường mà hệ thống thật chạy, nên hai bên trôi xa nhau trong khi công cụ vẫn in ra số đẹp. Lỗi cùng loại lặp **bốn lần** và được ghi thành một mối đe dọa tính hợp lệ ở mục 5.9.1. (c) **Điều kiện đo sai** — gặp một lần ở phép đo tốc độ khung hình, khi máy đang chạy chương trình nặng khác (mục 5.6.3).

Nguyên tắc rút ra và áp dụng từ đó: **một con số chỉ được đưa vào quyển khi công cụ đo đi qua đúng đường xử lý mà bản giao hàng đi**, và mọi tùy chọn cấu hình phải đọc từ cùng một nguồn với hệ thống đang chạy thật.

5.2. Môi trường thực nghiệm

Toàn bộ số liệu đo trên **một máy trạm cá nhân duy nhất: Windows 11 Pro 10.0.26200, Python 3.13.12, CPU Intel Raptor Lake (Family 6, Model 183) — 14 nhân vật lý / 20 nhân logic, không có GPU CUDA** nên mọi suy luận và huấn luyện chạy trên CPU; chế độ đo **lô = 1, bỏ 3 lượt khởi động nóng**. Đây là **tiền tố ngầm định của mọi con số hiệu năng ở 5.6**.

Phiên bản thư viện được trích từ môi trường thực thi đúng thời điểm chạy phép đo cuối cùng chứ không lấy từ tệp khai báo phụ thuộc, vì tệp khai báo ghi *ràng buộc phiên bản* chứ không ghi *phiên bản đã cài đặt*: ultralytics 8.4.101 · torch 2.13.0+cpu · torchvision 0.28.0+cpu · paddleocr 3.7.0 (PP-OCRv5 mobile) · paddlepaddle 3.3.1 · onnxruntime 1.27.0 · opencv-python 4.10.0.84 · numpy 2.4.5 · fastapi 0.139.2 · uvicorn 0.51.0 · sqlalchemy 2.0.51 · imagehash 4.7.2 · pytest 9.1.1.

5.2.1. Ràng buộc CPU-only: Quyết định thiết kế cốt lõi

Lập luận đầy đủ ở **4.3.1**. NFR-P1 phát biểu *kèm* ràng buộc CPU, nên kết luận "đạt sàn, không đạt mục tiêu" ở 5.6 là kết luận về hệ thống trong đúng bối cảnh vận hành thật, không phải con số chờ nâng cấp phần cứng. Cấu hình mô hình cũng do ràng buộc phần cứng quyết định — **YOLO11n** (2.590.035 tham số) [9] và **PP-OCRv5 mobile** [10]. Về quy mô: **30,2 phút mỗi epoch**, một lượt 20 epoch mất **10,05 giờ** liên tục, khiến **tìm kiếm siêu tham số bất khả thi**; chương này báo cáo *một* cấu hình huấn luyện, không phải kết quả của một quá trình tối ưu — giới hạn thật, ghi ở 5.9.1.

5.3. Bộ dữ liệu thực nghiệm

Lưu ý về cách đặt tên. Thư mục yolo_v2/ và yolo_v3/ chỉ **phiên bản của bộ dữ liệu**, không liên quan đến kiến trúc YOLOv2 hay YOLOv3. Mô hình dùng trong toàn đồ án là **YOLO11n**.

Bảng 5.2. Ba phiên bản bộ dữ liệu và số cặp ảnh gần trùng xuyên tập con theo ngưỡng Hamming

Thuộc tính / ngưỡng	v1	v2	v3
Tổng số ảnh	4.578	15.133	15.133
Ngưỡng Hamming gộp trùng lặp	5	5	10
Số ảnh train / val / test	—	—	10.592 / 3.027 / 1.514
Dùng cho	baseline-416-v1.pt	bị loại bỏ	best.pt
Cặp gần trùng xuyên tập con, Hamming 0	—	—	0 (thông tin mới)

Thuộc tính / ngưỡng	v1	v2	v3
Hamming 5	—	—	0 (= ngưỡng gộp v1, v2 — không mang thông tin mới)
Hamming 10	619	2.699	0 (= ngưỡng gộp v3 — không mang thông tin mới)
Hamming 12 · 15	—	—	791 · 3.529 (thông tin mới)
Hamming 20	—	—	137.506 (ngưỡng đã lỏng tới mức nhiều cặp là dương tính giả)

v1 quá nhỏ và chỉ một nguồn (1 bộ vào hợp nhất, 1 nguồn nguyên tố) — động cơ tải thêm **tám bộ** (tổng **9 bộ**), trong đó **sáu bộ** vào hợp nhất cho bài toán phát hiện cùng bộ gốc (v2, v3: **7 bộ vào hợp nhất, 6 nguồn nguyên tố**), hai bộ nhận mức ký tự tách riêng cho OCR. **v2 sửa được quy mô nhưng không sửa được rò rỉ**: lên 15.133 ảnh lại *tăng* cặp gần trùng xuyên tập con lên 2.699 vì các nguồn chứa ảnh có nguồn gốc chung. **v3 giữ nguyên dữ liệu** (cùng 15.133 ảnh), khác biệt duy nhất là ngưỡng khử trùng lặp 5 → 10 và phép chia tập sinh lại — cô lập biến có chủ ý, cho phép quy kết mọi thay đổi kết quả cho *chất lượng phép chia tập*, không cho *lượng dữ liệu*.

5.3.1. Khử trùng lặp: hai tỉ lệ, hai mẫu số khác nhau

Có **hai tỉ lệ khử trùng lặp trên hai mẫu số khác nhau**: **44,2%** (11.978/27.111, trước hợp nhất, trên 7 bộ vào hợp nhất cho bài toán phát hiện) và **47,8%** (7.227/15.133, sau hợp nhất). Hai số **không cộng dồn và không thay thế nhau**; cơ chế và cách đọc trình bày ở mục 4.4.1. Điểm phải nhớ khi trích: mẫu số 27.111 là tổng ảnh của **7 bộ vào hợp nhất cho bài toán phát hiện, không phải 9 bộ đã tải** — hai bộ còn lại mang **nhãn mức ký tự**, tách riêng cho tầng OCR.

5.3.2. Phân bố nguồn dữ liệu giữa các phép chia tập

Toàn tập chia **15.133 = 10.592 / 3.027 / 1.514**, tức **70,0% / 20,0% / 10,0%**. Hai đặc điểm cần lưu ý khi đọc mọi kết quả của chương. **Thứ nhất, tập test nghiêng về ảnh camera giao thông** — một nguồn ảnh camera giao thông có **20,3%** số ảnh rơi vào test, gấp đôi tỉ lệ tổng thể 10,0% — nên khi đọc mAP theo dải kích thước (5.4.3) phải nhớ rằng đối tượng nhỏ trong tập test tập trung ở một nguồn. **Thứ hai, một bộ dữ liệu dư thừa hoàn toàn**: một bộ vào hợp nhất với 1.005 ảnh và ra khỏi khử trùng lặp chéo bộ với **0 ảnh — loại 100,0%**, bằng chứng định lượng cho việc các bộ Roboflow tái sử dụng ảnh của nhau rất nặng và là lý do **không được cộng dồn số ảnh công bố của từng bộ để suy ra quy mô thật**.

5.4. Đánh giá bộ phát hiện biến số

Toàn bộ 5.4 đo trên **tập test v3: 1.514 ảnh, 1.611 đối tượng nhân thật**, imgsz=640, device=cpu; tập test chưa từng dùng trong huấn luyện hay chọn epoch.

5.4.1. Chỉ số tổng thể

Một điểm yếu lộ ra khi tách theo kích thước đối tượng. Bộ dữ liệu có **10,91% số hộp giới hạn chiếm dưới 0,5% diện tích ảnh**, và ở dải đó **mAP@0.5** rớt xuống **0,8553** so với 0,9913 ở dải trung bình. Biến ở xa là chỗ bộ phát hiện yếu nhất, và đây là căn cứ cho hướng phát triển siêu phân giải ở mục 6.3.

Cả bốn chỉ tiêu bắt buộc đều đạt mục tiêu, đo bằng công cụ đánh giá chuẩn của thư viện: **mAP@0.5 = 0,9829** (NFR-A1; sần 0,85, mục tiêu 0,90 ) , **mAP@0.5:0.95 = 0,7834** (NFR-A2; sần 0,55, mục tiêu 0,65 ) , **Precision = 0,9837** và **Recall = 0,9714** (NFR-A3; sần 0,88 / 0,85, mục tiêu 0,92 / 0,90 ) , **F1 = 0,9775** tại ngưỡng confidence 0,25; đối chiếu ở Bảng 5.13. Ba lưu ý: (1) **bài toán chỉ có một lớp**, mAP một lớp không so trực tiếp được với mAP nhiều lớp trên COCO nên giá trị cao là bình thường, **không phải bằng chứng về độ khó đã vượt qua**; (2) chỉ số quyết định là **mAP@0.5:0.95** vì độ khớp box ảnh hưởng trực tiếp đến chất lượng vùng cắt đưa sang OCR; (3) **chỉ số tổng thể che giấu phân bố**.

5.4.2. Tách theo biển một dòng và biển hai dòng (NFR-A8)

Bố cục xác định theo nhãn lớp khi bộ dữ liệu có khai báo, và theo **ngưỡng tỉ lệ khung hình 2,5** khi không có — nằm giữa tỉ lệ chuẩn của biển một dòng (4,727) và biển hai dòng (2,000 / 1,357) theo QCVN 08:2024/BCA.

Bảng 5.3. Kết quả phát hiện tách theo biển một dòng và hai dòng (NFR-A8)

Chỉ số	Biển một dòng	Biển hai dòng	Chênh (điểm %)
Số đối tượng nhãn thật (tổng 1.611)	286	1.325	n/a
mAP@0.5	0,9884	0,9675	2,09
mAP@0.5:0.95	0,7526	0,7649	-1,23
Precision · Recall · F1	0,9861 · 0,9895 · 0,9871	0,9735 · 0,9691 · 0,9713	1,26 · 2,04 · 1,65

5.5. Đánh giá khối OCR và hậu xử lý

Ràng buộc mẫu số. NFR-A4...A7 chỉ đo được trên **tập con có nhãn chuỗi ký tự — 2.801 biển**, không phải trên 1.514 ảnh test. Thiếu nhãn chuỗi cho phần lớn ngữ liệu là hạn chế thật, ghi ở 5.9.1.

Cấu hình khối OCR trong bản giao hàng, nói trước để mọi số dưới đây có nghĩa. Hệ thống chạy **model gốc PP-OCrv5 mobile**, đủ hai bước *phát hiện chữ* và *nhận dạng* (ocr_rec_model_dir để trống). Hai biến thể đã đo và **cả hai đều bị bác bỏ**.

Một, lượt tinh chỉnh bộ nhận dạng, đo đủ bốn cấu hình: thắng **+12,46 điểm** ở chế độ chỉ-nhận-dạng nhưng **thua 7,50 điểm** ở đúng chế độ vận hành — mà bản giao hàng chạy chế độ vận hành.

Hai, bỏ hẳn bước phát hiện chữ: trên 2.801 mẫu thắng **+12,46 điểm** và rẻ hơn ~290 ms mỗi ảnh, nhưng đo lại trên **ảnh toàn cảnh qua bộ phát hiện thật** thì thứ tự **đảo ngược**, 17/22 xuống 13/22. Cả 2.801 mẫu đều là vùng biển **cắt sẵn**, còn chế độ chỉ-nhận-dạng **không thể trả chuỗi rỗng** (0/1.606 khung, so với 173 của bản đang giao) nên nó **bị ra biển số** khi bộ phát hiện bắt nhầm. Công tắc ALPR_OCR_SKIP_DETECTION giữ trong mã, mặc định tắt. Số liệu đầy đủ ở báo cáo 31 và 30.

5.5.1. Độ chính xác mức ký tự (NFR-A4)

Chỉ số là **CER** theo khoảng cách Levenshtein, chuẩn hoá theo độ dài nhãn thật, với S ký tự thay thế, D bị xoá, I chèn thừa, N tổng ký tự nhãn thật; NFR-A4 phát biểu theo **1 – CER**.

5.5.2. Chuỗi đầy đủ: trước và sau hậu xử lý (NFR-A5 ↔ NFR-A6)

Khối hậu xử lý theo luật — chuẩn hoá ký tự, áp mặt nạ vị trí chữ số / chữ cái theo định dạng biển số Việt Nam, sửa cặp ký tự đồng hình, kiểm tra mã tỉnh — là **đóng góp kỹ thuật riêng** của đồ án, không có sẵn trong thư viện nào. Câu hỏi *khối đó đóng góp bao nhiêu?* chỉ trả lời được nếu **đo hai lần trên cùng một tập mẫu**: chuỗi thô PaddleOCR trả về (A5) và chuỗi sau khi áp toàn bộ luật (A6). Đây cũng là lý do kỹ thuật khiến hai cột riêng cho chuỗi thô và chuỗi đã chuẩn hoá cùng tồn tại trong lược đồ cơ sở dữ liệu — **điều kiện cần để phép đo này thực hiện được**, phải có từ giai đoạn thiết kế.

Bảng 5.4. Độ chính xác OCR trước và sau hậu xử lý, trên 2.801 biển có nhãn chuỗi

Chỉ số	Sàn	Mục tiêu	Trước hậu xử lý	Sau hậu xử lý	Chênh (điểm %)
1 – CER (NFR-A4)	0,92	0,95	0,9061	0,9483	n/a
CER	≤ 0,08	≤ 0,05	0,0939	0,0546	n/a
Chuỗi đầy đủ đúng (A5 → A6)	0,80 → 0,85	0,85 → 0,90	0,6373 ✗	0,7701 ✗	+13,28
$N / S / D / I$ trên chuỗi thô	—	—	23.855 / 862 / 1.272 / 107	(không đổi)	n/a
Biển sửa đúng / bị làm hỏng / sai cả trước lẫn sau	—	—	—	372 / 0 / 644	n/a

5.5.3. Tách theo biển một dòng và hai dòng cho OCR

Bảng 5.5. Độ chính xác nhận dạng tách theo biển một dòng và hai dòng

Chỉ số	Biển một dòng	Biển hai dòng	Chênh (điểm %)
Số mẫu có nhãn chuỗi (<i>tổng 2.801</i>)	567	2.234	n/a

Chỉ số	Biến một dòng	Biến hai dòng	Chênh (điểm %)
1 – CER (NFR-A4)	0,9925	0,9380	5,81
Chuỗi đúng trước hậu xử lý (A5)	0,9418	0,5600	38,18
Chuỗi đúng sau hậu xử lý (A6)	0,9541	0,7234	23,07
Cải thiện do hậu xử lý (A6 – A5)	+1,23	+16,34	n/a
Độ chính xác E2E (<i>giao thức cũ, đã rút — xem 5.5.5</i>)	0,6861	0,5219	—

Chênh lệch 2,09 điểm ở tầng phát hiện tăng lên ở tầng OCR: 5,45 điểm ở mức ký tự, **23,07 điểm** ở A6 và **38,18 điểm** ở A5. Biến một dòng đạt A6 = 0,9541, vượt mục tiêu 0,90; kết quả OCR chung chưa đạt chủ yếu do biến hai dòng, chiếm **2.234 / 2.801 = 79,8%** tập có nhãn chuỗi. Sau hai bậc cứu chữa (5.5.6, 5.5.7), khoảng cách A6 giảm từ 36,79 xuống **23,07 điểm**, tức giảm **13,72 điểm**. Phần còn lại thuộc về năng lực nhận dạng ký tự, không phải khâu cắt, ghép hoặc hiệu chỉnh hình học.

5.5.4. Ma trận nhầm lẫn ký tự 36×36

Bảng 5.6. Các cặp ký tự bị nhầm nhiều nhất, đối chiếu bảng luật hiện hành

Hạng	Ký tự thật → bị đọc thành	Số lần	Tỉ lệ trong tổng lỗi thay thế	Bảng luật có phủ không?
1	L → 1	90	10,44%	có — đúng chiều
2	E → F	73	8,47%	không
3	4 → L	53	6,15%	có — đã bổ sung
4	U → 1	38	4,41%	không
5	D → 0	34	3,94%	có — đúng chiều
6	Z → 7	32	3,71%	có — đã bổ sung
7	2 → 7	26	3,02%	không
8	X → Y	21	2,44%	không
9	B → R	20	2,32%	không
10	9 → 0	19	2,20%	không

Bảng luật ban đầu suy từ hình dạng ký tự chỉ phủ 2 trong 10 cặp, và một trong hai suy sai chiều. Cặp 4 → L là ví dụ rõ nhất: khi một vị trí bắt buộc là số mà bộ nhận dạng đọc ra L, sự thật là 4 **53 lần** và là 1 **đúng một lần** — bảng cũ lại sửa L thành 1. Trực giác hình dạng ghép **đúng cặp nhưng sai chiều**.

Nhóm thực hiện thay bằng bảng trích từ chính ma trận này, với ngưỡng thống kê: **một mục chỉ được đổi khi ứng viên đo được xuất hiện ít nhất 10 lần và ít nhất gấp đôi ứng viên đứng nhì**. Lấy argmax thô sẽ cho 23 mục, nhưng phần lớn dựa trên một đến ba lần xuất hiện — đó là nhiễu, không phải tín hiệu. Qua ngưỡng chỉ có **hai mục**: L → 4 và 7 → Z;

năm mục khác được số liệu **xác nhận** là đã đúng, phần còn lại giữ nguyên phỏng đoán cũ vì bằng chứng quá mỏng.

Hai mục đó nâng số cặp được phủ từ **2 lên 4 trên 10**, và đo lại trên toàn bộ 2.801 biển cho **A6 = 0,7701** so với 0,7512 — thêm **53 biển đọc đúng, làm hỏng 0 biển**, toàn bộ nằm ở biển hai dòng (Bảng 5.1, lượt 5).

Sáu cặp còn lại không sửa được bằng cơ chế này, và lý do đáng nói: $E \rightarrow F$, $X \rightarrow Y$, $B \rightarrow R$, $2 \rightarrow 7$ và $9 \rightarrow 0$ là những cặp mà **cả hai ký tự cùng loại** — cùng là chữ, hoặc cùng là số. Bộ luật hậu xử lý chỉ can thiệp khi loại ký tự đọc được mâu thuẫn với loại mà vị trí đó bắt buộc; hai chữ cái nhầm lẫn nhau thì không vị trí nào phát hiện được. Sửa chúng đòi hỏi mô hình nhận dạng đọc đúng ngay từ đầu, không phải thêm luật.

5.5.5. Độ chính xác đầu cuối toàn trình (NFR-A7)

NFR-A7 đo **ảnh đầu vào → phát hiện → cắt → OCR → hậu xử lý → chuỗi cuối**; khác A6 ở chỗ A6 đo trên **vùng biển cắt chuẩn theo nhãn thật** còn A7 đo trên vùng biển do **chính bộ phát hiện** tìm ra, nên A7 tích lũy cả hai nguồn sai số và theo lý thuyết luôn $\leq$ A6. Trên 2.801 mẫu, lượt 4 (Bảng 5.1) cho **A7 = 0,5552**; **E2E với điều kiện đã phát hiện được biển = 0,6306**; tỉ lệ biển **bỏ sót** ở tầng phát hiện **0,1196**; phát hiện đúng nhưng **đọc sai chuỗi 0,3694**; chênh **A6 – A7 = 19,60 điểm**.

E2 không áp dụng cho ngữ liệu này, và đó là kết luận chứ không phải khoảng trống. Cả 2.801 mẫu đều là **vùng biển đã cắt sẵn**, nên không có bước phát hiện nào chạy và một ca *phát hiện nhầm* về nguyên tắc không thể xuất hiện. Tỉ lệ phát hiện nhầm thật được đo ở **tầng bộ phát hiện**, trên 1.514 ảnh toàn cảnh của tập kiểm tra: **39 dương tính giả trên 1.606 phát hiện**, tương ứng precision **0,9757** (mục 5.4).

Con số 0,5552 bị rút, vì giao thức đo hỏng. Chạy lại trên **cùng 2.801 mẫu, cùng bộ phát hiện, cùng imgsz = 640** cho **A7 = 0,0000** — con số của lượt 4 **không tái lập được**. Đây không phải hệ thống tệ đi mà là **lỗi thiết kế phép đo**: cả 2.801 mẫu đều là **vùng biển đã cắt sẵn**, trong khi bộ phát hiện được huấn luyện trên ảnh giao thông đầy đủ, nên một tấm ảnh mà biển chiếm gần hết khung nằm **ngoài phân bố huấn luyện**. Phần lớn thất bại ở đó do bộ phát hiện không bắt được hộp giới hạn (bỏ sót 11,96%), **không** phải do OCR đọc sai. Trên đầu vào ngoài phân bố, một thay đổi nhỏ ở tầng suy luận đủ để lật hoàn toàn kết quả — dấu hiệu phép đo **không đo cái nó tưởng đang đo** ([báo cáo 41](#)).

A7 đo lại ở mức ảnh toàn cảnh. Phép đo đúng nghĩa đòi ảnh hiện trường **có nhãn chuỗi biển số**, và tập nhãn ấy đã được dựng: **608 khung biển có nhãn** trong tổng **1.606 khung** của **1.514 ảnh** hiện trường thuộc tập kiểm tra. Vì 1.232 khung (76,7%) rơi vào nhóm khó, dùng riêng nhóm ấy sẽ cho con số **bi quan sai lệch**, nên ước lượng được **phân tầng** theo Bảng 5.7: tầng đồng thuận gán nhãn **372/374** — gần như đếm hết chứ không còn là mẫu, nên sai số của ước lượng chỉ còn đến từ tầng bất đồng.

Bảng 5.7. NFR-A7 ở mức ảnh toàn cảnh — ước lượng phân tầng trên 1.606 khung biển

Tầng	Kích thước	Đã gán nhãn	Độ chính xác
Đồng thuận (<i>ca dễ</i>)	374	372 (99,5%)	96,8%
Bất đồng (<i>ca khó</i>)	1.232	236 (19,2%)	44,1%
A7 phân tầng	1.606	608 (37,9%)	56,3% (KTC 95% [52,0 ; 60,7])

NFR-A7 = 56,3%, không đạt ❌ — dưới cả ngưỡng tối thiểu 0,82. Kết quả nhất quán với hai quan sát độc lập: đường ống bản giao hàng đọc đúng **17/22 biển** trên bộ ảnh toàn cảnh dùng để trình diễn, gồm cả biển đỏ quân đội, hai biển ngoại giao, biển vàng kinh doanh và hai biển xanh nhà nước; và chênh lệch giữa A6 = 0,7701 (đo trên vùng biển cắt chuẩn) với A7 phản ánh đúng phần sai số mà tầng phát hiện đóng góp thêm.

Hạn chế phải nói kèm mỗi lần trích con số này: nhãn do một mô hình ngôn ngữ-thị giác đọc, không phải do người. Nhãn ấy **độc lập với cả bốn cấu hình được so sánh** nên phép đo không mắc lập luận vòng tròn — nếu lấy đồng thuận của chính các cấu hình làm nhãn thì mọi cấu hình sẽ tự động đúng trên mọi mẫu đồng thuận, kể cả khi tất cả cùng đọc sai. Nhưng một mô hình đọc nhãn vẫn có thể sai theo cách riêng của nó, và điều đó **không kiểm chứng được nếu không có người đọc lại**. Vì vậy 56,3% phải đọc là **ước lượng có nguồn nhãn máy sinh**, không phải con số nhãn vàng. Gán nhãn thủ công cho cùng tập này là **hướng phát triển số 3** ở mục 6.3.

5.5.6. Bước "phục hồi dòng trên" cho biển hai dòng — thiết kế, kiểm chứng A/B và kết quả trên toàn tập

Hồ sơ lỗi thiên về xoá ($D = 1.272 > S = 862$) trên biển hai dòng có cách giải thích tự nhiên: **mất hẳn một dòng**. Hệ thống đọc biển hai dòng bằng **ghép rồi đọc** (*split-then-hstack*): cắt vùng biển thành hai nửa chồng lấn, xếp cạnh nhau thành dải ngang, chạy OCR **một lần**. Phương án thay thế — đọc riêng từng nửa rồi nối chuỗi — đã được đo A/B chứ không bị loại bằng lập luận, trên 200 biển hai dòng với hạt giống ngẫu nhiên cố định: **A, ghép rồi OCR một lần** (*đang dùng*) đúng **129/200 = 64,50%**, 2 ca OCR trả chuỗi rỗng, 340,11 ms; **B, OCR từng nửa rồi nối** đúng **7/200 = 3,50%**, 9 ca chuỗi rỗng, 391,35 ms — B kém A **61,00 điểm phần trăm** và tốn thêm **51,24 ms**; **122 ca A thắng B, 0 ca B thắng A. Giả thuyết "đọc riêng từng dòng thì chính xác hơn" bị bác bỏ dứt khoát**. Nguyên nhân đọc được ngay trong dữ liệu: hai nửa **cố ý chồng lấn** để không cắt cụt ký tự, nên đọc riêng thì dải chồng lấn bị đọc **hai lần** và ký tự bị nhân đôi — 84G122593 thành 84-G124E009.01225.93. Một kết quả âm có giá trị: lựa chọn kiến trúc ở Chương 5 không tùy tiện.

Ghi chú về mốc thời gian. Số liệu toàn tập của riêng bước phục hồi dòng trên thuộc lượt 2 (Bảng 5.1) và được giữ nguyên mốc. Trên 2.801 ảnh có nhãn chuỗi (cùng mô hình và cùng độ phân giải đầu vào; cột "trước" là lượt đo trước đó trên đúng cùng tập mẫu và cùng mô hình): A4 0,8734 → **0,8848 (+1,14; sần 0,92 ❌)**; A5 0,6098 → **0,6098 (0,00; sần 0,80 ❌)**; A6 0,6555 → **0,6730 (+1,75; sần 0,85 ❌)**; A7 0,5227 → **0,5295 (+0,68; sần 0,82 ❌)**; A6 riêng biển **một dòng** 0,9489 → **0,9489 (0,00)**; A6 riêng biển **hai dòng** 0,5810 → **0,6030 (+2,20)**; biển bị can thiệp / thành

đúng hoàn toàn / bị làm hỏng = **89 / 2.801 · 49 · 0**. Bảng số này trả lời đúng một câu hỏi — *riêng bước phục hồi dòng trên đóng góp bao nhiêu* — và câu trả lời ấy không đổi theo thời gian; nhưng **các giá trị tuyệt đối đã bị vượt qua** (A6 hiện là 0,7701 chứ không phải 0,6730) nên **không được trích cột "sau bước cứu" như số hiện hành**. Trên lượt 2, bước phục hồi dòng trên cho câu trả lời cuối ở **209 biển**.

5.5.7. Bậc thang thử lại cho biển nghiêng/méo — chi phí, lợi ích và một quyết định tắt tính năng

Khi lần đọc đầu trả về chuỗi không hợp lệ, hệ thống thử lại trên các biến thể hình học của vùng biển thay vì chấp nhận thất bại. Bậc thang có ba bậc, và **chỉ hai bậc đầu được bật trong bản giao hàng**.

Bảng 5.8. Chi phí và lợi ích của từng bậc trong thang thử lại

Bậc	Chi phí độ trễ	Lợi ích đo được	Trong bản giao hàng
Nấn hình + giãn dọc	+244 ms p95	+34 biển đọc đúng	 bật
Siêu phân giải (FSRCNN)	+319 ms p95, +1.381 ms p99	0 biển	 tắt

Hai bậc đầu: một thoái lui có chủ ý và đã định lượng. Chúng đổi độ trễ đuôi lấy 34 biển đọc thêm. Điểm đáng chú ý là **trung vị thậm chí giảm nhẹ** (414,67 → 405,77 ms ở lượt đo khi ấy): bậc thang chỉ chạy **sau khi lần đọc đầu thất bại**, nên nó không chạm vào trường hợp thường; toàn bộ chi phí dồn vào đuôi phân bố.

Bậc thứ ba bị tắt mặc định. Một mình siêu phân giải đẩy p95 lên **1.514,26 ms** — vượt cả ngưỡng tối thiểu 1.500 ms — trong khi cứu được **0 biển**. Công tắc ALPR_SR_RETRY_ENABLED và toàn bộ mã vẫn giữ nguyên, chỉ đổi giá trị mặc định.

Nhưng số 0 ấy phải đọc cho đúng, và đây mới là điểm phương pháp luận. Cổng vào bậc siêu phân giải chỉ mở cho vùng cắt **nhỏ hơn 200 điểm ảnh**, và **0 trên 120 mẫu ngữ liệu lọt qua cổng đó**. Vậy nên đây là **số 0 cấu trúc**: chi phí đã đo được, còn lợi ích thì **chưa ai đo được** — khác hẳn "đã đo và thấy vô dụng". Một số 0 do *thiếu điều kiện quan sát* không được phép trình bày như một số 0 do *đã quan sát và thấy bằng không*. Đo lại bậc này trên ngữ liệu có biển thật sự nhỏ là hướng phát triển ở mục 6.3.

5.6. Đánh giá hiệu năng

Mọi số trong 5.6 phải đọc cùng cấu hình ở 5.2: **Intel Raptor Lake 14 nhân / 20 luồng, Windows 11, CPU-only, kích thước lô = 1**.

5.6.1. Độ trễ đầu cuối (NFR-P1)

Bảng 5.9. Độ trễ đầu cuối một ảnh, đối chiếu NFR-P1

Chỉ số	Sàn	Mục tiêu	Trước bậc thang	Sau bậc thang	Cấu hình giao hàng	Kết quả
p50 (ms)	—	—	414,67	405,77	150,07	n/a
p95 (ms)	≤ 1500	≤ 800	731,15	1.143,10	509,76	
p99 (ms)	—	—	947,83	1.420,07	1.124,13	n/a
Trung bình (ms)	—	—	400,74	447,38	222,34	n/a
Nhanh nhất (ms)	—	—	—	—	74,25	n/a
Số ảnh đo	—	—	100	100	100	n/a
Bội số so với sàn / mục tiêu	—	—	0,49× / 0,91×	0,76× / 1,43×	0,34× / 0,64×	n/a

NFR-P1 đạt mục tiêu. p95 = **509,76 ms**, dưới mục tiêu 800 ms với biên **290 ms**, và chỉ bằng **0,34×** ngưỡng tối thiểu. Đây là lần đầu chỉ tiêu này vượt mục tiêu chứ không chỉ đạt sàn.

Cột thứ tư kể phần còn lại của câu chuyện, và nó là một chuỗi hai bước ngược chiều nhau. **Bước lùi:** bậc thang thử lại (5.5.7) đẩy p95 từ 731,15 lên 1.143,10 ms — thoái lui **có chủ ý và đã định lượng**, đổi 412 ms ở đuôi lấy 34 biển đọc đúng thêm; trung vị gần như không đổi vì bậc thang chỉ chạy sau khi đọc hỏng. **Bước tiến:** đột tối ưu tăng suy luận (4.4) đưa p95 xuống 509,76 ms, tức **thấp hơn cả mốc 731,15 ms trước khi có bậc thang** — hệ thống nay vừa giữ 34 biển ấy vừa nhanh hơn điểm xuất phát.

Ba can thiệp làm nên bước tiến đó đều nằm ở tầng chạy, không đụng trọng số: `torch.inference_mode()` bỏ chi phí ghi số đồ thị đạo hàm, ghim số luồng cho torch và OpenCV để tránh tranh khoá, và truyền `cpu_threads` xuống PaddleOCR. **Không chỉ số độ chính xác nào đổi** — A4, A5, A6, mAP và bảng nhầm lẫn giữ nguyên, vì ba can thiệp ấy chỉ đổi cách tính toán được lập lịch chứ không đổi phép tính.

Về con số "sub-100 ms". Ảnh nhanh nhất trong lượt đo đạt **74,25 ms**, và một biển một dòng sạch có thể xuống dưới 100 ms. Nhưng đó là **cận dưới của một mẫu**, không phải chỉ số của hệ thống; số dùng để đối chiếu chỉ tiêu là trung vị 150,07 ms và p95 509,76 ms. Tương tự, **không được lấy 1/độ trễ làm thông lượng**: nghịch đảo của 81 ms là 12 khung/giây, trong khi thông lượng thật đo qua giao diện lập trình với hàng đợi một khe là **5,63 khung/giây** (5.6.3). Hai đại lượng đo hai thứ khác nhau.g**: tắt hẳn bậc thang thử lại đưa p95 về **866,3 ms**, tức toàn bộ **+277 ms** là của nó; nhưng vì bậc thang chỉ chạy **sau khi lần đọc đầu thất bại** nên nó không chạm vào trường hợp thường — **trung vị thậm chí giảm nhẹ** (414,67 → 405,77 ms), chi phí dồn hết vào đuôi. Với hệ thống mà 95% ảnh xong dưới 1,15 giây và một nửa xong dưới 0,41 giây, p50 mô tả trải nghiệm điển hình còn p95 mô tả trường hợp xấu; NFR-P1 phát biểu theo p95 nên kết luận chính thức là **đạt sàn, không đạt mục tiêu**. Ở lượt đo đầu với cả ba biến thể bật, p95 là **1.514,26 ms** — **vượt cả ngưỡng tối thiểu**; bóc tách chỉ ra bậc siêu phân giải chiếm hơn nửa chi

phí đó mà không cải thiện được biển nào đo được nên nó bị **tắt mặc định**, đưa p95 về 1.143,10 ms.

5.6.2. Phân rã ngân sách độ trễ theo từng bước

Bảng 5.10. Phân rã ngân sách độ trễ theo từng bước

Bước xử lý	Ước lượng ban đầu (ms)	Đo thật (ms)	Chênh (lần)	% tổng
Giải mã ảnh + tiền xử lý	50	1,78	0,04	1,2%
Suy luận YOLO11n @ 640px (CPU)	150	55,66	0,37	38,0%
Cắt + tiền xử lý vùng biển số	30	0,00	0,00	0,0%
PaddleOCR (mỗi biển)	120	89,16	0,74	60,8%
Hậu xử lý regex + kiểm tra hợp lệ	5	0,03	0,01	0,0%
Ghi CSDL + lưu ảnh	50	—	—	—
Tổng (một biển số)	405	146,63	0,36	100%

Ba phát hiện. **Một, ước lượng ở giai đoạn phân tích yêu cầu khá sát ở tổng nhưng lệch ở phân bố:** tổng suy luận thuần **146,63 ms/biển**, chỉ bằng 0,36 lần ước lượng ban đầu 405 ms. Sai lệch **không** tới một bậc độ lớn. **Hai, điểm nghẽn là PaddleOCR nhưng KHÔNG áp đảo như báo cáo cũ:** 60,8% so với 38,0% của bộ phát hiện, **thay thế** con số cũ "OCR 93,3% / detect 6,5%" vốn do trên hệ thống đang có lỗi cắt ảnh (~1.322 ms/ảnh); nguyên nhân OCR đắt vẫn đúng — PaddleOCR là **đường ống nhiều giai đoạn** (phát hiện văn bản → phân loại hướng → nhận dạng) thiết kế cho ảnh tài liệu tổng quát, nên hệ thống trả chi phí cho năng lực mà vùng biển đã cắt không cần. **Ba, chiến lược tối ưu đối hản:** theo định luật Amdahl, tăng tốc detector 2–3× có thể kéo E2E xuống quãng **15–23%**, khác hẳn kết luận cũ "chỉ giảm tối đa 6,7%". Dự đoán này **đã được kiểm chứng** bằng phép đo riêng (mục 3.4): OpenVINO nhanh 1,57× ở tầng bộ phát hiện và nâng thông lượng đầu cuối **+20,0%** — nằm trong khoảng dự đoán. Vì NFR-P1 mới đạt sàn, tối ưu hiệu năng vẫn nằm trên đường tới chỉ tiêu chứ không chỉ là *dự định cải thiện thêm*.

5.6.3. Chế độ webcam (tầng API) và xử lý video (NFR-P2, NFR-P3)

NFR-P2 đạt: 5,63 FPS (sàn 3, mục tiêu 5) — vượt cả mục tiêu, không chỉ sàn. Con số này đo **sau đợt tối ưu tầng suy luận** (4.4); trước đó là 5,257 FPS. Trong 60,0 giây, camera ảo 30 khung/giây chào **1.801 khung**, hệ thống nhận và trả kết quả cho **338 khung**, bỏ 1.463 khung ở hàng đợi, **0 lỗi**. Giao diện thời gian thực dùng **hàng đợi một khe**: chỉ một yêu cầu bay tại một thời điểm, khung sinh ra trong lúc chờ bị bỏ thay vì xếp hàng; ở kỷ luật đó thông lượng bị chi phối bởi những lần chậm nhất, nên phân vị đuôi mới là đại lượng quyết định. Đo được p50 = **164,08 ms**, p95 = **204,52 ms** — đuôi chỉ rộng gấp 1,25 lần trung vị. NFR-P3 cũng **đạt**: video 14,25 giây xử lý hết **16,4 giây** (sàn ≤ 95 s, mục tiêu ≤ 47,5 s), tức **0,8695×** thời gian thực, vid_stride = 5 — cũng đo sau đợt tối ưu, trước đó là 0,785×

Con số này thay thế một số liệu cũ đã công bố, và lý do phải kể ra. Một lượt đo trước đó cho **2,379 FPS — trượt sàn**, và quyền từng quy nguyên nhân cho bậc thang thử-lại. Đo lại trên **mã nguồn giống hệt từng byte** (git diff trên ai/ giữa hai thời điểm chỉ trả về một công cụ đo mới thêm), cùng cấu hình, cùng dãy ảnh phát lại, cho 5,257 rồi 5,213 FPS ở hai lần chạy độc lập.

Bảng 5.11. Sáu lần đo NFR-P2 trong các điều kiện máy khác nhau


Điều kiện	FPS hiệu dụng	p50	p95	p95/p50	Kết luận
Lượt đo cũ — máy đang tải nặng	2,379	180,05	1.247,70	6,93	✗
Máy rảnh, lần 1	5,257	164,08	204,52	1,25	✓
Máy rảnh, lần 2	5,213	165,13	199,33	1,21	✓
Ép tải 6 lõi	4,367	201,76	238,97	1,18	●
Ép tải 12 lõi	4,057	215,69	268,40	1,24	●
OpenVINO, máy rảnh	6,310	129,60	148,50	1,15	✓

Dòng cuối là một phương án đã đo, không phải bản giao hàng. Bản giao hàng chạy **PyTorch**. Xuất sang OpenVINO nhanh **1,57×** ở riêng bước phát hiện (33,09 → 21,12 ms) và **không suy giảm độ chính xác** (mAP 0,983 so với 0,9829), nhưng mặc định vẫn giữ nguyên vì **NFR-P2 đã đạt mà không cần đổi**, còn đổi thì mọi con số độ trễ trong chương này sẽ lệch khỏi hệ thống thực sự được bàn giao — đúng loại sai lệch đồ án đã ba lần trả giá. Bật lên chỉ cần đổi biến môi trường `ALPR_MODEL_PATH`.

Log lần đo cũ cho thấy máy khi đó đang công khoảng **560% CPU** của tiến trình khác (Explorer, VS Code, Visual Studio, một bản dựng đang chạy), và harness **đã in cảnh báo** rằng mọi số liệu bên dưới là *bì quan*. Giả thuyết đầu tiên vì thế là tải cạnh tranh. Nhóm thực hiện **kiểm chứng thay vì tin**: dựng tải tổng hợp 6 rồi 12 lõi và đo lại — và **thí nghiệm bác bỏ chính giả thuyết đó**. Tải cạnh tranh nâng cả phân bố một cách đều tay, giữ tỉ lệ p95/p50 quanh 1,2; còn lượt đo cũ có trung vị gần như của máy rảnh (180 ms) nhưng đuôi **gấp 6,93 lần trung vị**. Hai chữ ký khác hẳn nhau.

Quy kết cũ cho bậc thang thử-lại cũng không đứng vững: log máy chủ lần đó cho thấy bậc thang chỉ nổ **6 lần trên 144 khung**, và với giá trị chậm nhất đo được là 1.484,91 ms thì 6 lần nổ chỉ giải thích khoảng **52 ms** trong khoảng chênh 225 ms của trung bình. Nguyên nhân *chính xác* của đuôi hôm đó **không xác định được** — ứng viên còn lại là tranh chấp đĩa (tiến trình System chiếm 136% là thời gian nhân, thường đi kèm quét đĩa) mà tải tổng hợp thuần CPU ở đây không mô phỏng. Đây là **suy đoán có cơ sở, không phải kết luận đã đo**, và được ghi đúng như vậy.

Con số nên dùng khi nói về biên an toàn là 4,057 FPS — mức xấu nhất đo được, khi 12 trên 20 luồng bị tiến trình khác chiếm trọn, vẫn **trên sàn 35%**.



Hình 5.3. Sáu lần đo NFR-P2. Bên trái: trung vị của lượt đo cũ nằm ngang với các lần đo trên máy rảnh, nhưng đuôi p95 cao gấp sáu lần. Bên phải: cùng dữ liệu, biểu diễn bằng tỉ lệ p95/p50 — **ép tải tới 12 lõi cũng chỉ đẩy tỉ lệ này lên 1,24× trong khi lượt đo cũ là 6,93×**. Tải cạnh tranh nâng cả phân bố đều tay; thứ xảy ra ở lượt đo cũ thì không.

5.6.4. Khử trùng lặp mờ cho chuỗi khung hình video

Một xe đi qua khung hình xuất hiện trong hàng chục khung liên tiếp, và khối nhận dạng đọc lại nó ở mỗi khung. Nếu mọi lần đọc đều cho cùng một chuỗi thì gom theo chuỗi là đủ.

Thực tế không vậy: **cùng một biển, cùng một chất lượng ảnh, hai khung cách nhau vài phần trăm giây vẫn có thể cho hai chuỗi khác nhau**. Hệ quả trực tiếp là danh sách kết quả của một video ngắn phình ra thành nhiều dòng cho cùng một chiếc xe.

Cơ chế. Sau khi gom theo chuỗi, một lượt thứ hai hợp nhất các biến thể của cùng một biển vật lý. Hai chuỗi được coi là cùng một biển khi thoả **đồng thời** hai điều kiện:


1. **Gần nhau về chuỗi** — khoảng cách Levenshtein ≤ 2 ;
2. **Gần nhau về thời gian** — hai lần đọc cách nhau không quá 48 khung.

Riêng với khoảng cách bằng 2, chỉ điều kiện chuỗi là chưa đủ, vì hai biển **thật sự khác nhau** cũng có thể chỉ cách nhau hai ký tự. Vì vậy mức này còn phải qua một rào ngữ nghĩa: **cùng mã tỉnh hai chữ số**, và **hoặc** cùng chữ cái sê-ri **hoặc** cùng ba chữ số cuối. Bỏ rào ấy đi thì thuật toán sẽ gộp nhầm hai xe khác nhau đồ cạnh nhau.

Bản nào sống sót được quyết bằng bằng chứng, không bằng thứ tự đến. Thứ tự ưu tiên: đúng quy chuẩn định dạng trước, rồi tới **số khung đã bỏ phiếu** cho cách đọc đó, cuối cùng mới tới độ tin cậy OCR. Độ tin cậy một mình là trọng tài kém ở mức một ký tự — một lần đọc sai vẫn có thể mang điểm cao.

Kết quả đo. Chạy toàn bộ đường ống trên demo-video-giao-thong.mp4, lấy mẫu một khung trong mỗi bốn khung: khối nhận dạng trả về **44 chuỗi khác nhau**, sau khi hợp nhất còn **27** — **17 chuỗi được gom vào một bản ghi khác**, tức gần **bốn trên mười** dòng kết quả là trùng lặp của một biển đã có.

Khử trùng lặp mờ: 4 cách đọc sai được gom vào một bản ghi



Hình 5.4. Một ca khử trùng lặp thật, cắt trực tiếp từ video demo. Cùng một chiếc xe máy được đọc thành **năm chuỗi khác nhau** ở năm khung hình khác nhau; bốn bản viền đỏ bị gom vào bản viền xanh. Điều đáng chú ý là **năm vùng cắt gần như không phân biệt được bằng mắt** — khác biệt không đến từ loá sáng hay che khuất mà từ **tính không tất định của khối nhận dạng giữa các khung gần giống nhau**. Bản 51H14573 thắng nhờ **11 khung** bỏ phiếu, trong khi bốn bản còn lại mỗi bản chỉ có một khung; nếu xét riêng độ tin cậy thì 51H4573 (0,994) đã suýt vượt qua.

Phạm vi của kết quả này, nói cho đúng. Đây là cải thiện ở **tầng trình bày kết quả video**, không phải ở độ chính xác nhận dạng: nó không sửa được một ký tự đọc sai, chỉ chọn ra cách đọc được nhiều khung ủng hộ nhất. Vì vậy **các chỉ số NFR-A4...A6 ở mục 5.5 không đổi** — chúng đo trên ngữ liệu ảnh cắt sẵn, mỗi biển một lần, nên bước hợp nhất này không tham gia. Rủi ro còn lại cũng phải nêu: rào ngữ nghĩa thu hẹp chứ **không loại trừ** khả năng gộp nhầm hai biển thật sự khác nhau khi chúng cùng tỉnh, cùng ba số cuối và cùng xuất hiện trong một cửa sổ 48 khung. Trên bộ demo chưa gặp ca nào như vậy, nhưng đó là **chưa quan sát thấy**, không phải **đã chứng minh không xảy ra**.

5.6.5. Chịu tải, bộ nhớ và độ tin cậy (NFR-SC1, NFR-P4...P7, NFR-R4)

Mọi chỉ tiêu hiệu năng ngoài đường xử lý ảnh đều đạt với biên rất rộng.

Bảng 5.12. Các chỉ tiêu hiệu năng ngoài đường xử lý ảnh

Chỉ tiêu	Đo được	Ngưỡng	Biên
Nạp mô hình	6,41 s	≤ 30 s	4,7×
Khởi động tới khi /health sẵn sàng	8,36 s	≤ 30 s	3,6×
Overhead tầng API (p95)	19,01 ms	≤ 100 ms	5,3×
Truy vấn lịch sử 10.000 bản ghi (p95)	18,71 ms	≤ 500 ms	~27×
Bộ nhớ thường trú — đường ống · máy chủ	0,759 · 0,806 GB	≤ 4 GB	~5×
Yêu cầu đồng thời ổn định	10	≥ 5	2×
Chạy liên tục 15 phút	100,0% / 5.337 yêu cầu, 0 lỗi	≥ 99%	—
Khởi động lại cơ sở dữ liệu	0/7.977 bản ghi mất	0 mất	—

Hai dòng cuối là bằng chứng **không rò rỉ bộ nhớ** và **không mất dữ liệu**; đối chiếu đầy đủ từng mã chỉ tiêu ở Bảng 5.13.

Trên chính đường xử lý ảnh, cả ba chỉ tiêu độ trễ nay đều đạt mục tiêu: p95 một ảnh **509,76 ms** (mục tiêu 800), NFR-P2 **5,63 khung/giây** (mục tiêu 5) và NFR-P3 **0,8695×** thời gian thực (mục tiêu 0,3×). Bậc thang thử lại vẫn là một thoái lui có chủ ý đổi lấy 34 biển đọc thêm (5.5.7), nhưng đợt tối ưu tăng suy luận (4.4) đã bù lại và còn dư. **Kiến trúc phần mềm không còn là vấn đề** — tầng API, tầng dữ liệu, bộ nhớ, độ ổn định đều dư biên. Hai nhánh đi tiếp: nâng *độ chính xác* OCR biển hai dòng (5.5), và cắt *đuôi độ trễ* của chế độ ảnh tĩnh — đặt trần thời gian cho bậc thang, hoặc chuyển bộ phát hiện sang OpenVINO, hướng đã đo được **1,57×** ở mục 3.4.

5.7. Đối chiếu toàn bộ chỉ tiêu phi chức năng

NFR-A9 mang ký hiệu ☐, khác hẳn ☒. Chỉ tiêu này đòi báo cáo độ chính xác tách theo điều kiện ảnh (ban ngày, ban đêm, ngược sáng, mưa). Bộ dữ liệu **không có nhãn điều kiện chụp**, nên không phải hệ thống trượt mà là **thiếu điều kiện quan sát** — ☐ nghĩa là chưa đo được, ☒ nghĩa là đã đo và trượt; ghi nhầm loại này thành loại kia là vu cho hệ thống một thất bại chưa từng đo.

Bảng tổng hợp trình bày khi bảo vệ, liệt kê **đầy đủ mọi mã chỉ tiêu phi chức năng** đã đặt ra ở giai đoạn phân tích yêu cầu, không lọc bỏ mã nào — kể cả những mã không đạt.

Bảng 5.13. Đối chiếu chỉ tiêu phi chức năng, gom theo nhóm

Nhóm	Số chỉ tiêu	Kết quả	Con số quyết định
Độ chính xác — phát hiện (A1, A2, A3)	3	☒ đạt cả ba, biên rộng	mAP@0,5 = 0,9829 (mục tiêu 0,90); Precision · Recall = 0,9837 · 0,9714
Độ chính xác — nhận dạng chuỗi (A4 – A7)	4	☒ một, ☒ ba	A4 = 0,9483 (vượt sần 0,92, dưới mục tiêu 0,95); A5 · A6 = 0,6373 · 0,7701 , cả hai dưới sần; A7 ☒ 0,563 ở mức ảnh toàn cảnh (xem 5.5.5)
Đóng góp hậu xử lý (A6 – A5)	1	☒	+13,28 điểm — 372 sửa đúng, 0 làm hỏng , trên 2.801 biển
Báo cáo tách bạch (A8, A9)	2	☒ A8, ☐ A9	Chênh lệch bố cục: 2,09 điểm ở phát hiện so với 23,07 điểm ở nhận dạng. A9 không đo được — bộ dữ liệu không có nhãn điều kiện chụp
Hiệu năng — độ trễ (P1, P2, P3)	3	☒ đạt cả ba	p95 một ảnh 509,76 ms (sần 1.500, mục tiêu 800; p50 chỉ 150,07 ms). FPS thời gian thực 5,63 — vượt cả mục tiêu 5; xấu nhất đo được dưới tải nặng 4,057 , vẫn trên sần 3. Video 0,8695× — vượt mục tiêu 0,3×

Nhóm	Số chỉ tiêu	Kết quả	Con số quyết định
Hiệu năng — tài nguyên (P4 – P7)	5	✅ đạt cả năm	Nạp mô hình 6,41 s ; overhead API 19,01 ms ; truy vấn 10.000 bản ghi 18,71 ms ; RSS 0,806 GB
Độ tin cậy và chịu tải (R1 – R5, SC1 – SC3)	8	✅ đạt cả tám	100,0% thành công qua 5.337 yêu cầu soak 15 phút; 0/7.977 bản ghi mất sau khởi động lại; 10 yêu cầu đồng thời ổn định
Bảo trì, bảo mật, khả dụng, ràng buộc (M, S, U, C)	14	✅ đạt cả mười bốn	Bao phủ kiểm thử tăng nghiệp vụ 87,7% (sàn 70%); chạy không cần GPU; M6 đã sạch — ruff check trả về 0 cảnh báo trên toàn kho

5.8. Phân tích lỗi

Bảng 5.14. Tần suất từng loại lỗi

Mã	Loại lỗi	Số ca	Tỉ lệ trong tổng ca sai	Tỉ lệ toàn tập đánh giá	Một dòng	Hai dòng
E1	Bỏ sót biến	335	—	—	—	—
E2	Phát hiện nhầm	—	—	—	—	—
E3	Nhầm ký tự	445	63,85%	15,89%	17	428
E4	Thiếu ký tự	73	10,47%	2,61%	0	73
E5	Thừa ký tự	18	2,58%	0,64%	5	13
E6	Sai thứ tự	0	0,00%	0,00%	0	0
	Tổng số ca sai	697	100%	24,88%	—	—
	Tổng ca đánh giá (mẫu số)	2.801	n/a	100%	—	—

5.9. Bàn luận

5.9.1. Các mối đe dọa đến tính hợp lệ của kết quả

Nguyên tắc: **nêu mối đe dọa, đánh giá mức nghiêm trọng, nói rõ đã làm gì để giảm thiểu — kể cả khi biện pháp giảm thiểu là "không có".**

Bảng 5.15. Tám mối đe dọa đến tính hợp lệ của kết quả

#	Mối đe dọa	Mức	Biện pháp giảm thiểu đã áp dụng
1	Rò rỉ dữ liệu tồn dư không khử được	Cao	Nâng ngưỡng gộp 5 → 10 và đo ở nhiều ngưỡng cao hơn ngưỡng gộp. Vẫn còn 791 cặp ở Hamming 12; rò rỉ <i>ngữ nghĩa</i> (cùng một xe, góc khác) không ngưỡng phash

#	Mối đe dọa	Mức	Biện pháp giảm thiểu đã áp dụng
	bằng bấm tri giác		nào phát hiện được ⇒ mọi chỉ số ở 5.4 và 5.6 phải coi là cận trên lạc quan
2	Tập test không xuyên bộ dữ liệu	Cao	Không có — cách đúng là giữ lại một nguồn hoàn toàn không dùng để huấn luyện; chưa thực hiện
3	Mẫu số nhỏ cho các chỉ số OCR (2.801 / 15.133 ảnh có nhãn chuỗi)	Cao	Công bố mẫu số ở mọi bảng của 5.5; không rút kết luận về chênh lệch nhỏ
4	Đo trên một cấu hình phần cứng duy nhất	Trung bình	Công bố cấu hình đầy đủ ở 5.2; không ngoại suy sang CPU, hệ điều hành hay số nhân khác
5	Một lượt huấn luyện duy nhất , không ước lượng được phương sai	Trung bình	Cố định seed = 42 để tái lập; không phát biểu so sánh dựa trên chênh lệch nhỏ
6	Bộ dữ liệu không đạt tiêu chí Q6 về tỉ lệ đối tượng nhỏ (10,91%)	Trung bình	Báo cáo mAP tách theo dải kích thước : dải dưới 0,5% diện tích rơi về 0,8553 (5.4.1)
7	Nhãn bố cục suy ra từ tỉ lệ khung hình khi bộ dữ liệu không khai báo	Thấp – TB	Ưu tiên nhãn lớp tường minh khi có; ghi rõ tỉ lệ ô suy bằng heuristic
8	Ma trận nhầm lẫn ký tự phụ thuộc thuật toán căn chỉnh chuỗi	Thấp	Áp ngưỡng tần suất tối thiểu trước khi đưa một cặp vào bảng luật (5.5.4)

CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1. Kết quả đạt được

Nhóm thực hiện đã bàn giao một hệ thống nhận dạng biển số xe Việt Nam hoàn chỉnh, chạy đầu cuối trên máy **không có GPU**: bộ phát hiện tự huấn luyện, khối nhận dạng ký tự, bộ luật hậu xử lý theo quy chuẩn Việt Nam, REST API, giao diện web, cơ sở dữ liệu và đóng gói Docker. Trạng thái xác minh bằng HTTP thật — 10 thao tác trên 9 đường dẫn phản hồi đúng, **1.004/1.004** kiểm thử tự động đạt, bao phủ tầng nghiệp vụ 87,7%.

Bảng 6.1. Đối chiếu chỉ tiêu đặt ra ở giai đoạn phân tích yêu cầu với số đo trên models/best.pt

Mã	Chỉ tiêu	Mục tiêu	Đo được	
A1 · A2	mAP@0,5 · mAP@0,5:0,95 (phát hiện)	0,90 · 0,65	0,9829 · 0,7834	✓
A3	Precision · Recall (phát hiện)	0,92 · 0,90	0,9837 · 0,9714	✓
A4	1 – CER (mức ký tự)	0,95	0,9483	●
A5 · A6	Chuỗi trước · sau hậu xử lý	0,85 · 0,90	0,6373 · 0,7701	✗
A7	Toàn trình từ ảnh gốc	0,88	0,563 ✗	□ *
A8	Chênh lệch bố cục ở tầng phát hiện (điểm %)	—	2,09	—
P1	Độ trễ p95 một ảnh (ms)	≤ 800	509,76	✓
P4 · P5 · P6	Nạp mô hình (s) · Overhead API · Truy vấn 10.000 bản ghi (ms)	≤ 15 · ≤ 50 · ≤ 500	6,41 · 19,01 · 18,71	✓
P7 · R4 · SC1	RSS (GB) · Thành công khi chạy liên tục · Yêu cầu đồng thời	≤ 2 · ≥ 99% · ≥ 5	0,806 · 100% · 10	✓

* A7 đo ở **mức ảnh toàn cảnh** — ước lượng phân tầng trên 1.606 khung biển của 1.514 ảnh hiện trường, 608 khung có nhãn. **Nhãn do mô hình ngôn ngữ-thị giác đọc, không phải người**, nên phải đọc như ước lượng có nguồn nhãn máy sinh (mục 5.5.5). Con số cũ 0,5552 đo trên ảnh cắt sẵn đã bị rút vì không tái lập được.

Các chỉ tiêu về phát hiện, thông lượng, độ tin cậy và chịu tải đều đạt; các chỉ tiêu về độ chính xác chuỗi chưa đạt ngưỡng. Riêng NFR-P1 chỉ đạt ngưỡng tối thiểu do bậc thử lại tăng thêm 34 biển nhận dạng đúng nhưng làm tăng độ trễ p95 — một thoái lui có chủ ý.

Bốn đại lượng đo được mà khảo sát không tìm thấy tương đương trong tài liệu Việt Nam:

1. **Đóng góp thuần của khối hậu xử lý theo vị trí: +13,28 điểm** — sửa đúng 372 biển, làm hỏng 0 biển trên 2.801 mẫu.

2. **Chênh lệch giữa hai bố cục biển trên dữ liệu Việt Nam thật: 23,07 điểm** ở khối nhận dạng, so với chỉ 2,09 điểm ở khối phát hiện. Rủi ro R-04 vì vậy nằm trọn ở tầng đọc ký tự.
3. **Benchmark ba bộ nhận dạng ký tự trên 2.801 biển, cùng một tầng bao quanh:** PaddleOCR đạt **68,87%**, so với EasyOCR (14,28%) và Tesseract (10,28%). Phép đo bổ sung bằng chứng thực nghiệm trên biển số Việt Nam cho lựa chọn bộ nhận dạng trong cấu hình của đồ án; kết quả này không được suy rộng thành so sánh tuyệt đối giữa các bộ nhận dạng. Thực nghiệm cũng cho một kết quả khác với dự đoán ban đầu: kỹ thuật tách và ghép ngang giúp độ chính xác của PaddleOCR tăng 34,92% nhưng chỉ cải thiện 0,03% đối với Tesseract; do đó, đây là **điều kiện cần, nhưng chưa đủ**.
4. **Bộ nhận màu nền biển đạt 97,89%** trên 1.565 ảnh có nhãn, cung cấp nguồn bằng chứng mà chuỗi ký tự không mang được: phân giải nhập nhằng giữa biển xanh nhà nước và biển trắng cá nhân khi hai chuỗi giống hệt nhau.

Hai kết quả kỹ thuật bổ sung, thuộc loại kỹ thuật hệ thống hơn là nghiên cứu.

5. **Tối ưu tầng chạy đưa NFR-P1 từ chỉ-đạt-sàn lên vượt mục tiêu** — p95 giảm từ 1.143,10 xuống **509,76 ms**, trung vị từ 405,77 xuống **150,07 ms**, mà **không đụng một trọng số nào**: ba can thiệp đều ở tầng lập lịch tính toán (4.6.8). Điều đáng nói không phải mức giảm mà là **mọi chỉ số độ chính xác đứng yên tuyệt đối** — đó chính là bằng chứng cho thấy phép tối ưu không đánh đổi gì.
6. **Khử trùng lặp mờ cho chuỗi khung hình video** — gom **17 trên 44** cách đọc về đúng một bản ghi mỗi xe, dùng ngưỡng chuỗi kết hợp một rào ngữ nghĩa dựng từ chính cấu trúc biển số Việt Nam (4.7.2). Bản được giữ lại quyết bằng **số khung bỏ phiếu** chứ không bằng độ tin cậy — ở mức sai khác một ký tự, độ tin cậy là trọng tài kém.

Ngoài các con số, nhóm thực hiện để lại **một quy trình đánh giá có kiểm chứng**: mọi số liệu sinh lại được bằng một lệnh, mọi phép so sánh kèm điều kiện đo, và các kết quả âm — hai lượt tinh chỉnh bộ nhận dạng đều không thắng model gốc ở chế độ vận hành — được ghi lại thay vì bỏ đi.

6.2. Hạn chế

Bảng 6.2. Mười hạn chế của đồ án

#	Hạn chế	Mức	Hệ quả cần lưu ý
1	OCR biển hai dòng còn yếu, kéo độ chính xác toàn trình chưa đạt	Cao	A6 = 0,7701 dưới ngưỡng — điểm nghẽn lớn nhất. A7 không đo được vì giao thức đo không đại diện (5.9.2)
2	Bộ dữ liệu lệch nặng về biển trắng	Cao	97,68% mẫu thuộc một lớp, nên kết luận về độ chính xác OCR chỉ áp cho biển trắng
3	Rò rỉ dữ liệu tồn dư	Trung	phash chỉ bắt tương đồng bố cục sáng-tối, không bắt

#	Hạn chế	Mức	Hệ quả cần lưu ý
	không khử được bằng băm tri giác	bình	"cùng xe, khác ngày"
4	Tập test không xuyên bộ dữ liệu	Trung bình	mAP 0,9829 lạc quan hơn mức gặp khi triển khai với nguồn ảnh mới
5	Độ trễ chỉ đạt ngưỡng tối thiểu — đã khép	Thấp	p95 nay 509,76 ms, vượt mục tiêu 800 ms sau đợt tối ưu tăng suy luận (5.6.1); bậc thang thử-lại vẫn giữ nguyên cùng 34 biến đọc thêm
6	Hai yêu cầu mức <i>Must</i> (FR-4.1, FR-2.5) còn nằm ngoài phạm vi	Trung bình	FR-3.1 và FR-3.4 từng bị gỡ nhưng đã được dựng lại . FR-4.1 chỉ mất màn hình hiển thị — thống kê vẫn phục vụ ở tầng API và vẫn có kiểm thử; riêng FR-2.5 mất chính năng lực (không xuất được video đã chú thích). Nêu rõ cả hai khi bảo vệ
7	SQLite chỉ cho phép một tiến trình ghi tại một thời điểm	Thấp	Đủ cho quy mô đồ án, chặn ở triển khai đa người dùng
8	Xem trực tiếp và xử lý nền tranh chấp CPU với nhau	Thấp	Chạy video nền làm chậm luồng nhận dạng ảnh
9	NFR-A9 không đo được — độ chính xác theo điều kiện ảnh	Trung bình	Không bộ dữ liệu nguồn nào gán nhãn ban ngày, ban đêm, chụp nghiêng hay ảnh mờ. Đây là thiếu điều kiện quan sát , không phải phép đo bị bỏ quên: chỉ tiêu ghi ☐ chứ không ghi ✗ (mục 5.7)
10	Biển đỏ quân đội và biển ngoại giao không có mẫu đánh giá	Trung bình	Bộ dữ liệu không chứa hai loại này, nên hai nhánh phân loại tuy đã cài đặt và chạy đúng trên ảnh demo vẫn chưa có số liệu định lượng

6.3. Hướng phát triển

Bảng 6.3. Mười một hướng phát triển, xếp theo mức tác động

#	Hướng	Giải hạn chế	Ghi chú
1	Huấn luyện lại module nhận dạng riêng cho biển số Việt Nam	1	Hướng quan trọng nhất. Một lượt tinh chỉnh đã chạy và đo đủ bốn cấu hình (5.5): thua model gốc 7,50 điểm ở chế độ vận hành. Lượt thứ hai trên ngữ liệu biển hiếm đã dừng có chủ ý
2	Thu thập dữ liệu cho các loại biển hiếm	2, 10	Điều kiện để mở rộng kết luận ra ngoài biển trắng, và để hai nhánh biển đỏ · ngoại giao có số

#	Hướng	Giải hạn chế	Ghi chú
			liệu đánh giá
3	Bổ sung nhãn chuỗi cho toàn tập	1, 2	Hiện chỉ 2.801/15.133 ảnh có nhãn chuỗi
4	Xây dựng tập test xuyên bộ dữ liệu	3, 4	Giữ nguyên một nguồn hoàn toàn không dùng để huấn luyện
5	Tăng tốc suy luận: lượng tử hoá OCR, bật OpenVINO cho bộ phát hiện	5	Đã làm một phần. Tối ưu tăng chạy (4.6.8) đã đưa p95 xuống 509,76 ms và khép NFR-P1. OpenVINO đã đo (5.6.3): nhanh 1,57× , mAP không giảm — nhưng phép đo ấy chạy trước đợt tối ưu nên tỷ lệ cần đo lại. Còn lại là lượng tử hoá khối OCR — phần chiếm 64,3% ngân sách
6	Thí nghiệm cô lập biến độ phân giải · dữ liệu · số epoch	4	Ma trận E1–E3, ước tính $\approx$ 33 giờ CPU
7	Gán nhãn điều kiện chụp cho tập kiểm tra (ban ngày · ban đêm · nghiêng · mờ)	9	Điều kiện duy nhất để NFR-A9 đo được. Rẻ: gán nhãn bốn lớp trên một tập con, không cần huấn luyện lại gì
8	Bám vết đối tượng qua khung hình cho video (SORT/DeepSORT)	—	Gộp nhiều lần đọc cùng một biển thành một kết quả
9	Tách lịch chạy giữa xem trực tiếp và xử lý nền	8	Hàng đợi ưu tiên hoặc giới hạn luồng cho tác vụ nền
10	Chuyển sang PostgreSQL nếu triển khai đa người dùng	7	Chỉ cần khi vượt quy mô một tiến trình ghi
11	Khôi phục hai yêu cầu <i>Must</i> đã đưa ra khỏi phạm vi — trang Tổng quan và xuất video đã chú thích	6	Thuần giao diện, không đụng tăng AI. Cả hai endpoint phục vụ chúng (GET /api/statistics, worker video) vẫn chạy và vẫn có kiểm thử , nên chỉ còn phần hiển thị

6.4. Kết luận chung

Đề tài nhận dạng biển số xe Việt Nam, hỗ trợ biển một dòng, hai dòng và suy luận trên CPU. Hệ thống đạt các chỉ tiêu phát hiện nhưng chưa đạt chỉ tiêu độ chính xác nhận dạng ký tự; hạn chế chủ yếu nằm ở biển hai dòng.

Giá trị của đề án vì vậy không nằm ở một con số cao nhất. Nó nằm ở ba chỗ: **một hệ thống hoàn chỉnh chạy được trong đúng ràng buộc phần cứng đã tuyên bố; bốn đại lượng đo được mà tài liệu trong nước chưa công bố tách bạch**, trong đó có benchmark ba bộ nhận dạng ký tự trên chính ảnh biển số Việt Nam; và **lối trình bày trong đó phần chưa đạt được**

phản ánh với cùng mức chi tiết như phần đạt — kể cả khi điều đó có nghĩa là công bố rằng một đóng góp kỹ thuật lỗi không độc lập với bộ nhận dạng như đã kỳ vọng.

Hướng ưu tiên là thay module nhận dạng ký tự bằng mô hình huấn luyện riêng cho biển số Việt Nam. Kiến trúc NFR-M5 cho phép thay bộ nhận dạng mà không sửa phần còn lại của hệ thống.

TÀI LIỆU THAM KHẢO

- [1] S. Du, M. Ibrahim, M. Shehata, W. Badawy, "Automatic License Plate Recognition (ALPR): A State-of-the-Art Review," *IEEE Transactions on Circuits and Systems for Video Technology*, q. 23, s. 2, tr. 311–325, 2013. doi: 10.1109/TCSVT.2012.2203741.
- [2] R. Laroca, E. V. Cardoso, D. R. Lucio, V. Estevam, D. Menotti, "On the Cross-Dataset Generalization in License Plate Recognition," trong *International Conference on Computer Vision Theory and Applications (VISAPP)*, 2022. [Trực tuyến]. Địa chỉ: <https://arxiv.org/abs/2201.00267> (truy cập ngày 2026-07-19).
- [3] Bộ Công an, "Thông tư số 79/2024/TT-BCA quy định về cấp, thu hồi chứng nhận đăng ký xe, biển số xe cơ giới, xe máy chuyên dùng," 2024. [Trực tuyến]. Địa chỉ: <https://chinhphu.vn/?pageid=27160&docid=211945&classid=1&orggroupid=4> (truy cập ngày 2026-07-19).
- [4] Bộ Công an, "Thông tư số 13/2025/TT-BCA sửa đổi, bổ sung một số điều của Thông tư số 79/2024/TT-BCA," 2025.
- [5] Bộ Công an, "Thông tư số 51/2025/TT-BCA sửa đổi, bổ sung một số điều của Thông tư số 79/2024/TT-BCA đã được sửa đổi tại Thông tư số 13/2025/TT-BCA," 2025. [Trực tuyến]. Địa chỉ: <https://congbao.chinhphu.vn/van-ban/thong-tu-so-51-2025-tt-bca-45356.htm> (truy cập ngày 2026-07-19).
- [6] Bộ Công an, "Quy chuẩn kỹ thuật quốc gia về biển số xe QCVN 08:2024/BCA," 2024. [Trực tuyến]. Địa chỉ: <https://mps.gov.vn/chinh-sach-phap-luat/bai-viet/quy-chuan-ky-thuat-quoc-gia-ve-bien-so-xe-d1-t1592> (truy cập ngày 2026-07-19).
- [7] Bộ Công an, "Nhận diện màu sắc, seri, ký hiệu biển số xe của cơ quan, tổ chức, cá nhân từ 01/01/2025," Cổng Thông tin điện tử Bộ Công an, 2024. [Trực tuyến]. Địa chỉ: <https://bocongan.gov.vn/chinh-sach-phap-luat/bai-viet/nhan-dien-mau-sac-seri-ky-hieu-bien-so-xe-cua-co-quan-to-chuc-ca-nhan-tu-01012025-d1-t1617> (truy cập ngày 2026-07-19).
- [8] Bộ Quốc phòng, "Thông tư 169/2021/TT-BQP quy định về đăng ký, quản lý, sử dụng xe cơ giới, xe máy chuyên dùng trong Bộ Quốc phòng," 2021. [Trực tuyến]. Địa chỉ: <https://luatvietnam.vn/giao-thong/thong-tu-169-2021-tt-bqp-bo-quoc-phong-216143-d1.html> (truy cập ngày 2026-07-19).
- [9] G. Jocher, J. Qiu, "Ultralytics YOLO11," Ultralytics, 2024. [Trực tuyến]. Địa chỉ: <https://docs.ultralytics.com/models/yolo11/> (truy cập ngày 2026-07-19).
- [10] C. Cui, "PP-OCRv5: A Specialized 5M-Parameter Model Rivaling Billion-Parameter Vision-Language Models on OCR Tasks," *CVPR 2026 / arXiv:2603.24373*, 2026. [Trực tuyến]. Địa chỉ: <https://arxiv.org/html/2603.24373v1> (truy cập ngày 2026-07-19).

- [11] Cổng Thông tin điện tử Chính phủ, "Quy định ký hiệu biển số xe ô tô, xe máy tại các địa phương (theo Thông tư 51/2025/TT-BCA)," Xây dựng chính sách, pháp luật — Chinhphu.vn, 2025. [Trực tuyến]. Địa chỉ: <https://xaydungchinh sach.chinhphu.vn/quy-dinh-ky-hieu-bien-so-xe-o-to-xe-may-tai-cac-dia-phuong-119250704073354464.htm> (truy cập ngày 2026-07-19).
- [12] "Advanced deep learning techniques for automated license plate recognition," *Scientific Reports*, 2025. [Trực tuyến]. Địa chỉ: <https://pmc.ncbi.nlm.nih.gov/articles/PMC12639091/> (truy cập ngày 2026-07-19).
- [13] G. Jocher, A. Chaurasia, J. Qiu, "Ultralytics YOLOv8," Ultralytics, 2023. [Trực tuyến]. Địa chỉ: <https://docs.ultralytics.com/models/yolov8/> (truy cập ngày 2026-07-19).
- [14] Ultralytics, "ultralytics/nn/modules/block.py — định nghĩa C2f, C3k, C3k2, C2PSA, PSABlock, Attention," GitHub, 2026. [Trực tuyến]. Địa chỉ: <https://github.com/ultralytics/ultralytics/blob/main/ultralytics/nn/modules/block.py> (truy cập ngày 2026-07-19).
- [15] P. Batra và cộng sự, "A Novel Memory and Time-Efficient ALPR System Based on YOLOv5," *Sensors*, q. 22, s. 14, tr. 5283, 2022. doi: 10.3390/s22145283.
- [16] "Automatic License Plate Detection System with YOLOv11 Algorithm," *Journal of Applied Informatics and Computing (JAIC)*, 2025. [Trực tuyến]. Địa chỉ: <https://jurnal.polibatam.ac.id/index.php/JAIC/article/view/11484> (truy cập ngày 2026-07-19).
- [17] "Vehicle License Plate Number Detection with YOLO11," *Journal of Computer Science and Informatics Engineering (J-Cosine)*, 2025. [Trực tuyến]. Địa chỉ: <https://jcosine.if.unram.ac.id/index.php/jcosine/article/view/656> (truy cập ngày 2026-07-19).
- [18] R. Laroca và cộng sự, "ICPR 2026 Competition on Low-Resolution License Plate Recognition," trong *International Conference on Pattern Recognition (ICPR)*, 2026. [Trực tuyến]. Địa chỉ: <https://arxiv.org/abs/2604.22506> (truy cập ngày 2026-07-19).
- [19] A. Wang và cộng sự, "YOLOv10: Real-Time End-to-End Object Detection," *arXiv preprint arXiv:2405.14458*, 2024. doi: 10.48550/arXiv.2405.14458.
- [20] G. Jocher, J. Qiu, M. Liu, S. Lyu, F. C. Akyon, M. E. Kalfaoglu, "Ultralytics YOLO26," Ultralytics, 2025. [Trực tuyến]. Địa chỉ: <https://docs.ultralytics.com/models/yolo26/> (truy cập ngày 2026-07-19).
- [21] PaddlePaddle, "Text Recognition Module — PaddleOCR/PaddleX Documentation," PaddleOCR / PaddleX, 2026. [Trực tuyến]. Địa chỉ: http://www.paddleocr.ai/main/en/version3.x/module_usage/text_recognition.html (truy cập ngày 2026-07-19).

[22] Sutikno, A. Sugiharto, R. Kusumaningrum, "Enhanced Automatic License Plate Detection and Recognition using CLAHE and YOLOv11 for Seat Belt Compliance Detection," *Engineering, Technology & Applied Science Research*, q. 15, s. 1, tr. 20271–20278, 2025. doi: 10.48084/etasr.9629.

[23] Ultralytics, "Intel OpenVINO Export — Ultralytics Docs (ma nguon markdown, day du bang benchmark CPU/GPU/NPU)," GitHub / Ultralytics Docs, 2026. [Trực tuyến]. Địa chỉ: <https://raw.githubusercontent.com/ultralytics/ultralytics/main/docs/en/integrations/openvino.md> (truy cập ngày 2026-07-19).

[24] Microsoft ONNX Runtime, "Thread management — ONNX Runtime Performance Tuning (intra/inter op threads, spinning, NUMA)," Microsoft, 2025. [Trực tuyến]. Địa chỉ: <https://onnxruntime.ai/docs/performance/tune-performance/threading.html> (truy cập ngày 2026-07-19).

PHỤ LỤC

Phụ lục I. Mã vùng biển số

Bảng I.1. 81 mã vùng biển số đang sử dụng, dải 11–99

11	12	14	15	16	17	18	19	20
21	22	23	24	25	26	27	28	29
30	31	32	33	34	35	36	37	38
39	40	41	43	47	48	49	50	51
52	53	54	55	56	57	58	59	60
61	62	63	64	65	66	67	68	69
70	71	72	73	74	75	76	77	78
79	80	81	82	83	84	85	86	88
89	90	92	93	94	95	97	98	99

Dải 11–99 có 89 số; **8 mã chưa cấp**: 13, 42, 44, 45, 46, 87, 91, 96. Từ 01/7/2025 cả nước còn **34 tỉnh, thành phố**, và ký hiệu sau hợp nhất **giữ toàn bộ ký hiệu của các địa phương được hợp nhất** — nên số mã vẫn nhiều hơn số tỉnh. Danh sách này là nguồn sinh ra nhóm bắt mã tỉnh trong biểu thức kiểm tra hợp lệ (mục 4.6.5), nên nó không thể lệch khỏi mã đang chạy.

Phụ lục II. Ghi công giấy phép bộ dữ liệu

Bộ dữ liệu hợp nhất từ bảy nguồn công khai. **Năm bộ phát hành theo giấy phép CC BY 4.0**, giấy phép này **bắt buộc ghi công tác giả**: Roboflow school-fuhih/vietnamese-license-plate-tptd0, traffic-camera/vietnam-license-plate-hayn8, eric-nguyen-knfxn/vietnam-license-plate-curhr, demo-tracking/license-plate-vietnam-car, và tran-ngoc-xuan-tin-k15-hcm-dpuid/vietnam-license-plate-h8t3n. Bộ cuong-ta-ulxex/vietnamese-car-license-plate được người đăng tự khai Public Domain — đồ án **không khẳng định** điều đó vì ảnh nguồn có dấu hiệu là ảnh báo chí. Bộ hoanglvuit/Vietnam_License_Plate_Segment_Datasets trên HuggingFace **chưa xác nhận được giấy phép** và đóng góp 28,91% ngữ liệu; đây là rủi ro pháp lý được nêu ở mục 6.2 chứ không phải chi tiết bỏ qua được.

Phụ lục III. Nơi tra cứu phần chi tiết

Các bảng tra cứu dưới đây không lặp lại trong quyển vì chúng đã nằm trong thân bài hoặc trong bộ tài liệu đi kèm.

Nội dung	Nơi tra cứu
----------	-------------

Nội dung	Nơi tra cứu
Siêu tham số huấn luyện đầy đủ	Mục 4.5.1; nguyên văn tại <code>runs/final-640-v3/args.yaml</code>
Quy mô và tổ chức mã nguồn	Mục 4.2.2
Kết quả kiểm thử theo nhóm	Mục 5.7; chi tiết tại <code>docs/reports/07-testing-report.md</code>
Danh sách endpoint và cấu hình triển khai	Mục 4.7.4 và 4.9; OpenAPI tự sinh tại <code>/docs</code>
Đặc tả 34 yêu cầu chức năng và chỉ tiêu phi chức năng	<code>docs/00-requirements/</code>
Chỉ mục báo cáo đo dạng JSON chống lúng túng con số	<code>docs/reports/README.md</code>
Hướng dẫn cài đặt và vận hành	<code>docs/manuals/installation-guide.md</code>

